



## 【中泰电子】2026年度策略：沿主线，买缺口

分析师：

王芳 S0740521120002，杨旭 S0740521120001，李雪峰 S0740522080004，康丽侠  
S0740525040001，洪嘉琳 S0740524090003，刘博文 S0740524030001，丁贝渝 S0740524090001

中泰证券研究所  
专业 | 领先 | 深度 | 诚信

# 目 录

一、AI仍是所有主线

---

二、AI基建缺口扩大

---

三、端侧AI奇点已近

---

四、投资建议及风险提示

---


## 1.1 行业概述：Q3电子仓位新高，AI驱动多板块涨幅显著

- **电子行业涨跌幅：**25Q3 AI旺盛需求带动电子板块显著上涨，电子（中信）指数累计上涨44.5%，跑赢沪深300指数26.6%；25年初至12月5日，电子（中信）指数累计上涨39.5%，跑赢沪深300指数23.0%。
- **AI带动下PCB、消费电子、半导体等板块涨幅显著。**年初以来电子细分板块涨跌幅（基于自选股票池计算）：PCB+114%、消费电子+51%、半导体+40%、LED+20%、被动元件+12%、面板+1%；半导体细分板块来看，设计+51%、设备+45%、材料+33%、制造+33%、功率+12%、封测+10%。


图表：电子（中信）涨跌幅



图表：年初以来电子各板块  
累计涨跌幅




图表：年初以来半导体细分板块  
累计涨跌幅




# 1.1 行业概述：Q3电子仓位新高，AI驱动多板块涨幅显著

- **Q3电子仓位创历史新高：** 25Q3末主动权益基金电子行业仓位为23.64%，环比+5.42pct创历史新高，其中，半导体、消费电子、元器件（PCB+被动元件）仓位为12.77%、5.42%、4.28%，环比+2.38pct、+1.86pct、+1.25pct。
- **电子板块估值处于高位：** 截至12月5日，电子行业PE(TTM)为75x，高于2020/01以来75%分位数（73x），其中半导体PE(TTM)为132x，超过75%分位数（124x），消费电子PE(TTM)为43x，略低于中值（43x）。

图表：主动权益基金电子行业仓位



图表：电子（中信）PE（TTM）



# 1.1 行业概述： Q3电子仓位新高， AI驱动多板块涨幅显著


■ 受AI强劲需求拉动，海外半导体9月以来强势上涨。

- 费城半导体指数：25年9月初至12月5日费城半导体指数累计上涨28.7%，跑赢标普500指数22.3%；25年初至12月5日费城半导体指数累计上涨46.5%，跑赢标普500指数29.7%。
- 年初以来，数字&存储&设备&制造板块核心个股涨幅亮眼：1) 数字（英特尔+102%、英伟达+37%、高通+16%）；2) 存储（海力士+213%、美光科技+170%、三星+103%）；3) 设备（LAM+119%、KLA+93%、应用材料+67%、AMSL+62%）；4) 制造（台积电+38%、联电+21%）。

图表：费城半导体指数涨跌幅



图表：年初以来电子各板块涨跌幅





## ■ 25Q1-3业绩：

- 电子整体：25Q1-3电子整体营收同比增长19%，净利润同比增长35%，毛利率同比持平，净利率同比+1pct。
- 分板块看：1）各一级板块均实现营收与净利润同比增长，面板扭亏为盈；盈利能力方面，PCB、面板、半导体板块净利率同比+3pct、+2pct、+1.2pct，消费电子、被动元件、LED净利率同比持平；2）半导体板块中，功率受闻泰科技ODM业务剥离影响营收同比下滑，其余细分板块营收均实现同比增长；盈利能力方面，设计、材料、制造、功率净利率同比增长，封测净利率同比持平，设备、设备零部件受新品验证成本高、高投入拉高期间费用等因素影响净利率同比下滑。

图表：25Q1-3电子分板块业绩数据

|       |       | 营收（亿元） |       | 净利润（亿元） |       | 毛利率    |     | 净利率    |      |
|-------|-------|--------|-------|---------|-------|--------|-----|--------|------|
|       |       | 25Q1-3 | 同比    | 25Q1-3  | 同比    | 25Q1-3 | 同比  | 25Q1-3 | 同比   |
| 电子整体  |       | 32397  | 19%   | 1731    | 35%   | 17%    | 0%  | 5%     | 1%   |
| 半 导 体 | 整体    | 6836   | 15%   | 538     | 35%   | 24%    | 1%  | 8%     | 1.2% |
|       | 设计    | 2551   | 31%   | 196     | 75%   | 24%    | 2%  | 8%     | 2%   |
|       | 设备    | 836    | 17%   | 127     | 2%    | 40%    | 3%  | 15%    | -2%  |
|       | 设备零部件 | 105    | 12%   | 4       | -52%  | 25%    | 3%  | 4%     | -5%  |
|       | 封测    | 1050   | 9%    | 47      | 18%   | 14%    | 1%  | 5%     | 0%   |
|       | 材料    | 564    | 14%   | 53      | 27%   | 26%    | 1%  | 10%    | 1%   |
|       | 制造    | 768    | 19%   | 38      | 168%  | 21%    | 4%  | 5%     | 3%   |
|       | 功率    | 962    | -13%  | 72      | 28%   | 23%    | 5%  | 8%     | 2%   |
|       | 消费电子  |        | 18968 | 22%     | 892   | 22%    | 14% | -1%    | 5%   |
| PCB   |       | 2097   | 26%   | 208     | 67%   | 23%    | 3%  | 10%    | 3%   |
| 被动元件  |       | 390    | 18%   | 53      | 17%   | 27%    | 1%  | 14%    | 0%   |
| 面板    |       | 3494   | 8%    | 19      | -152% | 14%    | -1% | 1%     | 2%   |
| LED   |       | 612    | 7%    | 21      | 12%   | 23%    | 0%  | 4%     | 0%   |

注：面板25Q1-3扭亏为盈，制造净利润同比大增主因基数低（24Q1仍在亏损）

# 1.1 整体业绩：整体营收&利润同环比向上，整体盈利能力提升

## ■ 25Q3业绩：

- 电子整体：25Q3电子整体营收同比增长19%，净利润同比增长50%，毛利率同比持平，净利率同比+1pct。
- 分板块看：1) 各一级板块营收均实现同比增长，盈利能力方面，PCB、面板、半导体、LED净利率同比+3pct、+3pct、+2.6pct、+1pct，消费电子、被动元件净利率持平，LED板块净利率环比小幅下滑；2) 半导体板块，功率受闻泰科技ODM业务剥离影响营收同环比下滑，其余细分板块营收均实现同比增长；盈利能力方面，功率、设计、封测、材料、制造板块净利率同环比向上；设备、设备零部件受新品验证成本高、毛利压力大、高投入拉高期间费用等因素影响，毛利率、净利率均承压。

图表：25Q3电子分板块业绩数据

|       | 营收（亿元） |      |      | 净利润（亿元） |      |       | 存货（亿元） |     |     | 毛利率  |     |     | 净利率  |      |     |
|-------|--------|------|------|---------|------|-------|--------|-----|-----|------|-----|-----|------|------|-----|
|       | 25Q3   | 同比   | 环比   | 25Q3    | 同比   | 环比    | 25Q3   | 同比  | 环比  | 25Q3 | 同比  | 环比  | 25Q3 | 同比   | 环比  |
| 电子整体  | 12198  | 19%  | 13%  | 736     | 50%  | 29%   | 9236   | 22% | 13% | 17%  | 0%  | 0%  | 6%   | 1%   | 1%  |
| 整体    | 2420   | 11%  | 3%   | 237     | 51%  | 35%   | 3090   | 14% | 6%  | 26%  | 2%  | 2%  | 10%  | 2.6% | 2%  |
| 设计    | 933    | 30%  | 6%   | 96      | 154% | 47%   | 1061   | 20% | 9%  | 25%  | 1%  | 1%  | 10%  | 5%   | 3%  |
| 设备    | 335    | 24%  | 25%  | 53      | 9%   | 28%   | 945    | 19% | 1%  | 40%  | -2% | 0%  | 16%  | -2%  | 0%  |
| 设备零部件 | 40     | 8%   | 7%   | 1       | -74% | -50%  | 65     | -5% | 3%  | 23%  | -6% | -4% | 3%   | -8%  | -3% |
| 封测    | 361    | 5%   | -2%  | 22      | 36%  | 22%   | 155    | -6% | 11% | 15%  | 2%  | 1%  | 6%   | 1%   | 1%  |
| 材料    | 204    | 16%  | 8%   | 20      | 23%  | 12%   | 184    | 17% | 8%  | 27%  | 1%  | 0%  | 10%  | 1%   | 0%  |
| 制造    | 271    | 14%  | 9%   | 17      | 38%  | 95%   | 352    | 18% | 7%  | 23%  | 1%  | 4%  | 6%   | 1%   | 3%  |
| 功率    | 276    | -31% | -24% | 29      | 29%  | 25%   | 328    | -4% | 7%  | 26%  | 8%  | 5%  | 11%  | 5%   | 4%  |
| 消费电子  | 7404   | 23%  | 18%  | 384     | 33%  | 29%   | 4754   | 31% | 21% | 15%  | 0%  | 0%  | 5%   | 0%   | 1%  |
| PCB   | 782    | 27%  | 12%  | 83      | 77%  | 17%   | 469    | 21% | 9%  | 24%  | 3%  | 1%  | 11%  | 3%   | 0%  |
| 被动元件  | 138    | 16%  | 1%   | 19      | 17%  | 0%    | 107    | 18% | 5%  | 27%  | 2%  | 2%  | 14%  | 0%   | 0%  |
| 面板    | 1237   | 10%  | 6%   | 6       | 125% | 1833% | 608    | 7%  | 3%  | 13%  | -1% | 0%  | 1%   | 3%   | 1%  |
| LED   | 216    | 10%  | 1%   | 7       | 37%  | -12%  | 208    | 7%  | 5%  | 22%  | -1% | 0%  | 3%   | 1%   | -1% |

注：面板净利润同环比大增主因25Q2及24Q3板块总体仅略微盈利，基数过小

- 电子各板块：25Q3电子各一级板块库存均环比上升，消费电子下游备货旺季拉动消费电子与PCB板块库存环比提升，半导体板块库存环比上升主要由设计、制造、封测板块贡献。
- 半导体：受下游需求拉动，25Q3各细分板块库存均环比上升，设计、制造、封测板块贡献较大增量。

图表：电子各板块库存趋势变化

| 板块   | 存货（亿元） |      |      |      |      |      |      |      |      |  |
|------|--------|------|------|------|------|------|------|------|------|--|
|      | 23Q4   | 24Q1 | 24Q2 | 24Q3 | 24Q4 | 25Q1 | 25Q2 | 25Q3 | 趋势图  |  |
| 电子整体 | 6473   | 6686 | 7081 | 7594 | 7186 | 7760 | 8182 | 9236 |      |  |
| 半导体  | 整体     | 2392 | 2489 | 2622 | 2711 | 2735 | 2760 | 2917 | 3090 |  |
|      | 设计     | 755  | 812  | 854  | 882  | 947  | 926  | 975  | 1061 |  |
|      | 设备     | 681  | 716  | 795  | 797  | 797  | 833  | 933  | 945  |  |
|      | 设备零部件  | 63   | 68   | 68   | 69   | 63   | 63   | 64   | 65   |  |
|      | 封测     | 149  | 147  | 144  | 165  | 139  | 138  | 139  | 155  |  |
|      | 材料     | 140  | 143  | 152  | 157  | 154  | 160  | 171  | 184  |  |
|      | 制造     | 282  | 282  | 288  | 300  | 308  | 317  | 329  | 352  |  |
|      | 功率     | 322  | 321  | 320  | 342  | 327  | 322  | 307  | 328  |  |
| 消费电子 | 2974   | 3071 | 3271 | 3641 | 3290 | 3754 | 3943 | 4754 |      |  |
| PCB  | 319    | 325  | 352  | 388  | 374  | 398  | 429  | 469  |      |  |
| 被动元件 | 80     | 83   | 86   | 91   | 94   | 99   | 102  | 107  |      |  |
| 面板   | 526    | 536  | 566  | 569  | 512  | 558  | 592  | 608  |      |  |
| LED  | 182    | 183  | 186  | 194  | 182  | 191  | 198  | 208  |      |  |




- 25Q3全球智能手机销量同比继续增长，26年预计维持弱复苏，重点关注端侧AI落地进展和存储涨价影响。
- 全球智能手机销量自21Q3开始经历连续9个季度同比下滑，从23Q4开始销量同比转正，之后保持复苏增长趋势。2024年全球/中国智能机销量达12.4/2.9亿部，同比+6.1%/+5.6%；25Q3全球智能机销量达3.2亿部，同比+2.6%，中国智能机销量约6840万部，同比基本持平。9月中下旬开始各品牌旗舰新品集中上市，25Q4销量有望环比向上。展望26年，若苹果等大厂端侧AI应用逐步升级落地，有望缩短换机周期推升销量，但25Q3以来存储成本上涨幅度较大，部分品牌通过涨价传导成本压力，对终端销量的影响尚需观察，IDC预测未来数年全球/中国手机市场维持弱复苏，2024-29 CAGR分别为1.5%/0.8%。

图表：全球智能手机年度销量及预测（百万台）




图表：中国智能手机年度销量及预测（百万台）



- 25Q3全球PC销量同比+10.3%，预计2025年全球PC销量同比增长5.6%。
- 据IDC统计，2024年全球PC销量达到2.63亿台，同比+1.0%；25Q1-Q3继续保持增长趋势，25Q3全球PC销量7590万台，同比+10.3%，25Q1-3全球PC销量约2.1亿部，yoy+7.0%。2025年10月，微软不再为 Windows 10 提供来自 Windows 更新的免费软件更新、技术支持或安全修复程序，受益向Windows11过渡带来的更新需求，25年全球PC销量有望加速增长，IDC预计销量将达到2.78亿台，同比+5.6%。未来数年全球&中国PC市场预计维持低个位数增速，IDC预计2024-29年全球/中国PC市场CAGR达1.4%/2.1%。

图表：全球PC年度出货量及预测（百万台）



图表：中国PC年度出货量及预测（百万台）



## 1.1.2 汽车：总量弱复苏，电动&智能化双轮驱动

- **全球&中国汽车市场弱复苏**：2018-2020年全球汽车销量逐年下滑，2021年得益于电动智能化销量回升，2022年受疫情和供应链冲击销量下滑，此后维持增长趋势。2024年全球/中国汽车销量9060/3143万台；2025年预计全球/中国汽车销量9223/3400万台，yoy+1.8%/8.2%；预计2026年全球/中国汽车销量弱复苏，yoy+2.1%/3.0%。
- **新能源渗透率持续提升**：2025年全球/中国新能源汽车渗透率达18%/41%，预计2025年渗透率增长至20%/47%，汽车电动化趋势确定。
- **智能化率持续向上**：2024年中国市场ADAS渗透率达54.9%，奇瑞、比亚迪、吉利等车企移动中低端车型智驾平权有望带动渗透率持续向上，预计2025年渗透率达59.5%，其中L2以上渗透率达51.9%。


图表：中国汽车销量及新能源渗透率变化（万台）



图表：全球汽车销量及新能源渗透率变化（万台）



图表：中国汽车ADAS渗透率变化



# 1.2 AI带动全球半导体周期向上

- 2023年5月开始，半导体月度销售额同比增速触底，6月开始同比增速反弹，11月同比增速首次转正，目前仍在上行周期中
- 1) 2019/8上行周期起点。2019/7为周期增速底部，此后进入增速上行周期，并于2020/2月增速回到正增长。
- 2) 2022/3下行周期起点。2022/2增速达到本轮上行周期高点。
- 3) 2022/9月进入负增长阶段。根据我们统计的2000年来的6轮周期，其中1轮周期中该阶段不存在，1轮周期中该阶段为10个月，其他4轮周期中为6-7个月。
- 4) 2023年6月下行周期终点。2023年5月增速达到本轮下行周期低点，6月开始增速向上。
- 5) 2023年11月进入正增长阶段。2023年11月开始增速转正，目前仍处于上行周期中。
- WSTS数据显示，2025年10月全球半导体市场销售额为727亿美元，同比增长27.2%，2023年11月起至今，连续24个月同比增速为正，市场需求保持高位。


图表：历年周期表格

|        | 开始时间    | 结束时间    | 时长(月) | 开始时间    | 结束时间    | 时长(月) | 开始时间    | 结束时间    | 时长(月) | 开始时间    | 结束时间    | 时长(月) | 开始时间    | 结束时间    | 时长(月) | 开始时间    | 结束时间    | 时长(月) | 开始时间    | 结束时间    | 时长(月)      | 时长范围(月) | 平均时长(月) |
|--------|---------|---------|-------|---------|---------|-------|---------|---------|-------|---------|---------|-------|---------|---------|-------|---------|---------|-------|---------|---------|------------|---------|---------|
| 上行周期   | 2001/10 | 2002/06 | 9     | NA      | NA      | 0     | 2009/04 | 2009/10 | 7     | 2012/01 | 2012/04 | 4     | 2016/06 | 2016/08 | 3     | 2019/08 | 2020/01 | 6     | 2023/06 | 2023/10 | 5          | 3~9     | 5       |
| 增速为负   |         |         |       |         |         |       |         |         |       |         |         |       |         |         |       |         |         |       |         |         |            |         |         |
| 增速为正   | 2002/07 | 2004/06 | 24    | 2005/08 | 2008/06 | 36    | 2009/11 | 2010/04 | 6     | 2012/05 | 2014/03 | 23    | 2016/09 | 2017/06 | 10    | 2020/02 | 2022/02 | 25    | 2023/11 | 至今尚未结束  | 截至10月已24个月 | 6~36    | /       |
| 下行周期   | 2004/07 | 2005/06 | 12    | 2008/07 | 2008/10 | 4     | 2010/05 | 2011/06 | 14    | 2014/04 | 2015/07 | 16    | 2017/07 | 2018/12 | 18    | 2022/03 | 2022/08 | 6     |         |         |            | 4~16    | 12      |
| 增速为正   |         |         |       |         |         |       |         |         |       |         |         |       |         |         |       |         |         |       |         |         |            |         |         |
| 增速为负   | 2005/07 | 2005/07 | 1     | 2008/11 | 2009/03 | 5     | 2011/07 | 2011/12 | 6     | 2015/07 | 2016/05 | 10    | 2018/12 | 2019/07 | 7     | 2022/09 | 2023/05 | 9     |         |         |            | 1~10    | 6       |
| 总时长(年) |         |         | 3.9   |         |         | 3.7   |         |         | 2.8   |         |         | 4.5   |         |         | 3.2   |         |         | 3.9   |         |         |            |         |         |



## 1.2 AI带动全球半导体周期向上

图表：半导体月度销售额yoy、费城半导体指数



## 1.2 AI带动全球云厂商资本开支继续上行

### ■24年起海内外云厂商Capex迅速提升。

➢国内市场：2024年起国内百度、腾讯、阿里合计Capex显著提升，达1608亿元，yoy+173%，25年前三季度Capex继续快速上涨，达1659亿元，yoy+84%。


➢海外市场：2024年海外头部CSP厂商Meta、谷歌、亚马逊、微软Capex合计达2478亿美金，yoy+65%，2025前三季度达2841亿美金，yoy+67%。

### ■25-26E海外头部CSP厂商Capex指引预期乐观，26年普遍给予Capex增长50%-60%的指引：


➢2025E：Meta、亚马逊、谷歌、微软合计Capex约4050亿美元，yoy约+63%（24年：+66%），增长几乎无放缓。

➢2026E：四大CSP厂商预期显著增加Capex，仍给出Capex规模近50%~60%的增长指引。

图表：海外云厂商季度资本支出（十亿美元）




图表：海外云厂商年度资本支出




备注：包括Meta、谷歌、亚马逊、微软

图表：国内BAT季度资本支出（亿人民币）



图表：国内BAT年度资本支出




备注：包括百度、腾讯、阿里

## 1.3 AI叙事提速：大模型密集迭代、竞争激烈

- 今年以来模型迭代加速，头部竞争激烈、但玩家缩圈。以Artificial Analysis综合评分70分（GPT5.1水平）为基准，OpenAI、Anthropic、谷歌在Q3以来先后达到/超越。


图表：模型发布时间及评分（上）及当前评分（下）




## 1.3 AI叙事提速：基座模型能力突破，驱动应用领域展开

- 应用领域会随AI能力的进化而逐级突破：基础阶段聚焦文本、信息提取等简单任务；中级阶段可完成逻辑推理、跨模态理解，从而支持如代码、法律等更复杂场景；高级阶段向AGI靠近，接近乃至突破人类理解能力，拥有自主学习、上下文长记忆、复杂问题规划等能力。
- 现阶段：模型能力普遍触及“中级脑力劳动”，应用领域大幅展开，推理用量爆发。
- ChatGPT对于不同类型工作的生产力均有提升，尤以复杂任务更显著。根据OpenAI 在25年7月发布的报告，O1模型在不同的6个法律工作流程中，能够将律师的生产力提升34%至140%，并对法律工作质量起到实质性的改善作用，且这种生产力提升和质量改善的效果在复杂任务中表现得更为突出，如在需要高度专业能力和深度分析的 persuasive writing 以及 legal analysis 中。

图表：GPT 能力爬坡对应不同应用领域



图表：Open AI 在各行业应用中可实现不同程度的生产力提升






## 1.3 AI叙事提速：应用渗透，推理用量快速膨胀

- 从用户的AI使用依赖来看：**OpenAI周活用户数量**在今年以来的增长速度显著较此前更高。我们判断部分来自于其在生产力环节的实质驱动，根据OpenAI在25年7月发布的报告，美国的GPT信息流中，用于学习与技能提升/写作/编程与数学/设计创意/商业分析等的占比分别达到20%/18%/7%/5%/4%。
- 从推理端算力用量来看：谷歌月处理Tokens数量自今年年初以来显著提速。从今年4月起，推理用量整体增长约保持在1~2个季度翻倍的水平。

图表：GPT周活用户数量呈加速增长趋势（百万人）



图表：谷歌月处理Tokens自今年年初以来显著提速



## 1.3 AI叙事提速：CSP AI相关业务板块势头正劲

- 云业务板块整体增长继续提速，供不应求矛盾持续突出，由企业级AI需求驱动。
  - AWS Q3 收入330亿美元，yoy: +20% (Q2: +17%，为23年以来最高单季度增速；Q3末未履约云业务订单增长至2000亿美元（不含10月新交易）。
  - 谷歌云服务收入152亿美元（yoy:+34%，前值：+35%），运营利润率提升至23.7%（yoy: +6.6pct）；得益于云平台、AI基础设施及GenAI解决方案的增长，超过70%的云客户已使用AI产品；Q3末积压订单大幅增加、达到1550亿美元（yoy:+82%，qoq:+46%），由企业级AI的强劲需求推动，预计25Q4~26年仍处于供需紧张的状态。
  - Azure Q3 货币中性同比增长39%；积压订单3920亿美元，yoy +51%，qoq+6.5%。
- 广告收入增速整体继续上扬，AI大模型对转化率、客户在app上的留存时间、内容生产等各个维度均有显著提升。


图表：北美大厂云/广告业务板块同比增速

|          | 23 Q1 | 23 Q2 | 23 Q3 | 23 Q4 | 24 Q1 | 24 Q2 | 24 Q3 | 24 Q4 | 25 Q1 | 25Q2 | 25Q3 |
|----------|-------|-------|-------|-------|-------|-------|-------|-------|-------|------|------|
| AWS      | 16%   | 12%   | 12%   | 13%   | 17%   | 19%   | 19%   | 19%   | 17%   | 17%  | 20%  |
| Azure    | 31%   | 27%   | 30%   | 31%   | 35%   | 35%   | 34%   | 31%   | 35%   | 39%  | 39%  |
| 谷歌云      | 28%   | 28%   | 22%   | 26%   | 28%   | 29%   | 35%   | 30%   | 28%   | 32%  | 34%  |
| 谷歌广告     | 0%    | 3%    | 9%    | 11%   | 13%   | 11%   | 10%   | 11%   | 8%    | 10%  | 13%  |
| Meta广告   | 4%    | 12%   | 24%   | 24%   | 27%   | 22%   | 19%   | 21%   | 16%   | 21%  | 26%  |
| Amazon广告 | 23%   | 22%   | 25%   | 26%   | 24%   | 20%   | 19%   | 18%   | 19%   | 22%  | 22%  |


## 1.3 AI叙事提速：推理规模扩张为AI后续投入的主驱动

- 英伟达判断到2030年AI相关支出达到“3~4万亿美元”，其需求来源有：
- CSP转向GenAI，由业务效率提升驱动，如谷歌YouTube广告由AI驱动后，广告支出回报率提升17%；
  - 模型厂训练需求，如OAI, Anthropic, xAI, 谷歌和Meta的模型制造部分；
  - 企业的劳动力需求，Agentic AI进入劳动力市场，例如coding, 法律等；
  - 具身/物理AI，50万亿美元级别的工业化市场未来有望自动化。

图表：NV判断 2030年的数据中心capex达到3~4万亿美元



图表：不同阶段的3种Scaling Law，“我们正处于推理的Scaling Law阶段”




- 图 表：开、闭源模型评分（上）及模型定价（下）
- Legend: ■ Proprietary (闭源), ■ Open Weights (开源)
- Top Chart: Model Performance Scores (Artificial Analysis)
- | Model                      | Score | Type         |
|----------------------------|-------|--------------|
| Gemini 3 Preview (high)    | 73    | Proprietary  |
| Claude Opus 4.5            | 70    | Proprietary  |
| GPT-5.1 (high)             | 70    | Proprietary  |
| Kimi K2 Thinking           | 67    | Open Weights |
| GPT-5.1 Codex (high)       | 67    | Proprietary  |
| DeepSeek V3.2              | 66    | Open Weights |
| Grok 4                     | 65    | Proprietary  |
| Grok 4.1 Fast              | 64    | Proprietary  |
| Claude 4.5 Sonnet          | 63    | Proprietary  |
| Nova 2.0 Pro view (medium) | 62    | Proprietary  |
| MiniMax-M2                 | 61    | Open Weights |
| gpt-oss-1208 (high)        | 61    | Open Weights |
| Qwen3 235B A22B 2507       | 57    | Open Weights |
| KAT-Coder-Pro V1           | 57    | Proprietary  |
| GLM-4.6                    | 56    | Open Weights |
| Claude 4.5 Haiku           | 55    | Proprietary  |
| Gemini 2.5 Flash (Sep)     | 54    | Proprietary  |
| gpt-oss-208 (high)         | 52    | Open Weights |
| Magistral 1.2              | 52    | Proprietary  |
| DeepSeek R1 0528           | 52    | Open Weights |
| Apriel-v1.5-15B-Thinker    | 52    | Open Weights |
| GPT-5.1                    | 43    | Proprietary  |
| Mistral Large 3            | 38    | Open Weights |
| NVIDIA Nemotron Nano 9B V2 | 37    | Open Weights |
| OLMo 3 32B Think           | 36    | Open Weights |
| Llama 4 Maverick           | 36    | Open Weights |
- Bottom Chart: Model Pricing (Analysis)
- | Model                      | Price | Type         |
|----------------------------|-------|--------------|
| NVIDIA Nemotron Nano 9B V2 | 0.04  | Open Weights |
| gpt-oss-208 (high)         | 0.16  | Open Weights |
| OLMo 3 32B Think           | 0.07  | Open Weights |
| DeepSeek V3.2              | 0.2   | Open Weights |
| Grok 4.1 Fast              | 0.2   | Proprietary  |
| gpt-oss-1208 (high)        | 0.35  | Open Weights |
| Llama 4 Maverick           | 0.28  | Open Weights |
| MiniMax-M2                 | 0.42  | Open Weights |
| Mistral Large 3            | 0.2   | Open Weights |
| Gemini 2.5 Flash (Sep)     | 0.5   | Open Weights |
| GLM-4.6                    | 0.15  | Open Weights |
| Kimi K2 Thinking           | 0.6   | Open Weights |
| DeepSeek R1 0528           | 0.6   | Open Weights |
| Claude 4.5 Haiku           | 1.08  | Proprietary  |
| Magistral 1.2              | 3.5   | Proprietary  |
| Qwen3 235B A22B 2507       | 1     | Open Weights |
| GPT-5.1 (high)             | 5     | Proprietary  |
| GPT-5.1 Codex (high)       | 2     | Open Weights |
| GPT-5.1                    | 5     | Proprietary  |
| Nova 2.0 Pro view (medium) | 0.7   | Open Weights |
| Gemini 3 Preview (high)    | 8.4   | Proprietary  |
| Claude 4.5 Sonnet          | 1.25  | Open Weights |
| Grok 4                     | 10    | Proprietary  |
| Claude Opus 4.5            | 12    | Proprietary  |
| Grok 4.1                   | 3     | Open Weights |
| Claude 4.5 Sonnet          | 15    | Proprietary  |
| Grok 4                     | 3     | Open Weights |
| Claude Opus 4.5            | 25    | Proprietary  |




## 1.3 国产差异化路线突围：开源市场生态位稳健提升

- 根据OpenRouter平台基于100万亿Token数据分析得出，中国开源模型市场份额在**2025下半年贡献近30%的份额**，较**24年底显著增长**；中国开源模型中，编程和技术类任务生态位稳固，其工作负载占比达39%，显著超过全球开源模型的15~20%。
- 开源模型的市场份额在今年下半年以来趋于分散，多家国产大模型厂商（标黄）占据可观份额，竞争促进训练侧的持续投入。Deepseek、Qwen、Minimax、Kimi均有大规模生产级采用，用户趋于在多个头部模型中进行多样化选择。

图表：开/闭源Token用量



图表：开源模型份额趋于分散



## 1.3 AI普及加速，推理算力向端侧布局倾斜

- **AI规模化扩展之路不可或缺端侧算力。**根据高通白皮书，AI工作负载正向边缘侧迁移，端侧运算在成本、隐私、时延、可靠性等方面具备优势；根据弗若斯特沙利文预测，到2029年，全球端侧AI市场规模将增至1.2万亿元，复合年增长率达39.6%。
- **国内外AI大厂商积极入局端侧硬件赛道，抢占下一代交互入口。**在AI模型应用飞速普及的大背景下，端侧运行AI的成本与效率优势，使得AI大厂纷纷入局端侧硬件，以提升用户体验、寻求盈利闭环。

图表：端侧特定优势驱动AI的规模化扩展



图表：AI大厂入局端侧硬件案例

| 类别      | 公司     | 代表产品                                    |
|---------|--------|-----------------------------------------|
| 眼镜      | Meta   | Ray-Ban Meta, 支持端侧 AI 视觉识别、实时语音助手、直播等功能 |
|         | 谷歌     | Project Aura, Xreal合作款, 集成Google Gemini |
|         | 阿里巴巴   | 夸克AI眼镜, 搭载千问助手, 深度集成阿里生态                |
| 手机      | 谷歌     | Pixel 10, 端侧运行Gemini Nano               |
|         | 字节     | Nubia豆包合作款, 将豆包大模型植入手机系统底层              |
| 耳机      | 字节     | Ola Friend, 语音唤醒豆包实现交互                  |
|         | 谷歌     | Pixel Buds Pro 2, 与Gemini Live即时对话      |
|         | Meta   | Meta Quest Pro VR耳机, 配合头戴设备使用           |
| 新型可穿戴设备 | OpenAI | 研发阶段, 可穿戴“伴侣型”设备, 实现环境感知和新型人机交互         |

# 目 录

一、AI仍是所有主线

---

二、AI基建缺口扩大

---

三、端侧AI奇点已近

---

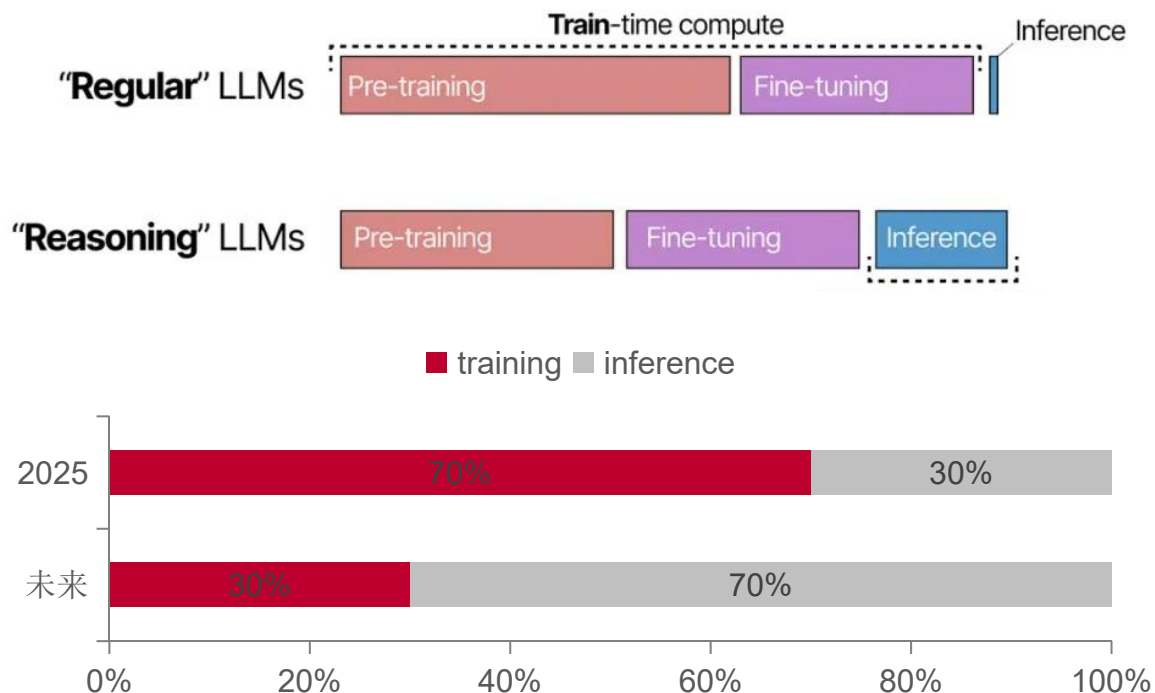
四、投资建议及风险提示

---


## 2.1 模型产业趋势：算力需求由训练向推理转变

- 当前算力结构正经历从训练为主向推理为主的深度转型：中国信通研究院云计算与大数据研究所副所长栗蔚认为大模型推理应用正重塑云智算技术体系，成为推动智能化转型的核心引擎，算力结构转型正从以训练为主转向以推理为核心——**当前70%以上算力用于集中式训练，未来70%以上算力将用于分布式推理**。多模态模型、Agentic AI等创新形态的加速落地将催生实时推理需求的新一轮结构性增长，推理需求规模有望达到训练阶段的5-10倍；据Global Info Research预测，2024年全球AI推理服务器市场规模约139.6亿美元，至2030年市场规模将达393.6亿美元，期间年复合增长率CAGR为18.9%

图表：大模型算力结构中推理需求显著增长



图表：2029-2030E全球AI推理服务器市场规模（单位：百万美元）





## 2.1 GPGPU与ASIC是算力两大支柱

- **GPGPU芯片与ASIC芯片是算力解决方案的两大支柱：**AI芯片在人工智能的算法和应用上做针对性设计，可高效处理人工智能应用的计算任务（其他非计算任务仍由CPU负责）。当前主流的AI芯片分为三类——GPU、FPGA、ASIC，GPU、FPGA均是前期较为成熟的芯片架构，属于通用型芯片，其中GPU并行计算能力强，在AI训练和推理场景应用最多，ASIC属于为AI特定场景定制化的芯片，具有较佳的性能和能效比，和GPU构成目前AI芯片的两大核心。
- **GPGPU适用于AI计算，**相比于传统GPU主要执行图形之外的通用计算任务，利用GPU的并行计算优势，加速科学计算、大数据分析、深度学习等领域，尤其在大规模并行计算时，比传统CPU更为高效。
- **ASIC芯片适用于推理：**ASIC芯片设计目的是高效处理特定算法，通过针对特定任务进行硬件优化，其能够最大限度利用硬件资源实现高性能计算，同时保持极低功耗，因此ASIC芯片在AI推理等任务中表现出色。

图表：CPU、GPU、FPGA和ASIC简要介绍

|       | CPU                              | GPU                                    | FPGA                           | ASIC                            |
|-------|----------------------------------|----------------------------------------|--------------------------------|---------------------------------|
| 名称    | 中央处理器                            | 图形处理器                                  | 现场可编程门阵列                       | 专用集成电路                          |
| 定制化程度 | 通用                               | 半通用                                    | 半定制化                           | 全定制化                            |
| 特点    | 通用性最强，擅长逻辑控制、串行的运算，但并行算力弱，较少用于AI | 提供了多核并行计算的基础结构，可支撑大量数据的并行计算，计算能力强，但功耗高 | 可编程性、灵活性高，但开发周期长，适合大规模、固定场景的应用 | 定制化设计、能效比高，但由于缺乏通用性、开发成本高且复杂度有限 |
| 代表公司  | Intel                            | 英伟达、AMD                                | Altera（Intel收购）、Xilinx（AMD收购）  | 博通、寒武纪                          |

## 2.1 GPGPU与ASIC是算力两大支柱

- 相较于NPU、TPU等AI芯片，GPGPU通用性更强、生态壁垒和开发难度更低：GPGPU采用SIMT架构可实现“开箱即用”，NPU/TPU仍沿用传统SIMD架构，需手动编排流水线，时延隐藏效率远不及SIMT，导致编写高性能内核难度大、效率低，既难以实现易用性，生态完善程度也落后于GPGPU。
- 英伟达GPU是GPGPU主要代表，其架构经历了由Ampere（7nm）至Hopper（4nm）再到Blackwell（4nm）迭代，新一代Rubin（3nm）架构将于26年下半年推出，随AI持续迭代的过程也伴随形态、价值量快速提升。

图表：英伟达GPU历代参数迭代梳理

| 架构                            | 类型    | 发布时间  | 形态                | 制程<br>(nm) | 算力（稠密/稀疏*，TFLOPS） |          |               |          |            |            | 容量<br>(GB) | 显存        |              | 互联带宽<br>(GB/s)       | TDP（最大<br>功耗，W） | ASP<br>(美元) | 单服务器<br>GPU数量 |
|-------------------------------|-------|-------|-------------------|------------|-------------------|----------|---------------|----------|------------|------------|------------|-----------|--------------|----------------------|-----------------|-------------|---------------|
|                               |       |       |                   |            | FP4               | FP6      | INT8          | FP8      | FP16/BF16  | TF32       |            | HBM配<br>置 | 带宽<br>(GB/s) |                      |                 |             |               |
| Volta                         | V100  | 2017年 | SXM               | 12         |                   |          | /             |          | 125        | /          | 16/32      | HBM2      | 900          | NVLink2.0<br>300     | 300             | 1w          | /             |
| Ampere                        | A100  | 2020年 | SXM               | 7          |                   |          | 624/1248<br>* |          | 312/624*   | 156/312*   | 80         | HBM2e     | 2039         | NVLink3.0<br>600     | 400             | 1.5w        | 8             |
|                               | H100  | 2022年 | SXM               | 4          |                   |          | 3958*         | 3958*    | 1979*      | 989*       | 80         | HBM3      | 3350         | NVLink4.0<br>900     | 700             | 2.4w        | 8             |
| Hopper                        | H200  | 2023年 | SXM               | 4          |                   |          | 3958*         | 3958*    | 1979*      | 989*       | 141        | HBM3e     | 4800         | NVLink4.0<br>900     | 700             | 2.4w        | 8             |
| Blackwell+<br>Blackwell Ultra | B100  | 2024年 | SXM(双<br>die)     | 4NP        | 7P/14P*           | 3.5P/7P* | 3.5P/7P*      | 3.5P/7P* | 1800/3500* | 900/1800*  | 192        | HBM3e     | 8000         | NVLink5.0<br>18000   | 700             | 3w          | 8             |
|                               | B200  |       | SXM(双<br>die)     | 4NP        | 9P/18P*           | 4.5P/9P* | 4.5P/9P*      | 4.5P/9P* | 2250/4500* | 1120/2250* | 192        | HBM3e     | 8000         | NVLink5.0<br>18000   | 1000            | /           | 8             |
|                               | GB200 | 2025年 | 2xB200<br>(4 die) | 4NP        | 20P/40P*          | 10P/20P* | 10P/20P*      | 10P/20P* | 5P/10P*    | 2500/5000* | 384        | HBM3e     | 16000        | NVLink5.0<br>18000*2 | 最高达<br>2700     | /           | 36/72         |
|                               | B300  |       | SXM(双<br>die)     | 4NP        | 15P/17.5P*        | /        | /             | 4.5P/9P* | 2.25/4.5P* | 1120/2250* | 288        | HBM3e     | 8000         | NVLink5.0<br>18000   | 1400            | /           | 36/72         |
|                               | GB300 |       | 2xB300            | 4NP        | 30P/38.9P*        | /        | /             | 10P/20P* | 5P/10P*    | 2500/5000* | 576        | HBM3e     | 16000        | NVLink5.0<br>18000*2 | 1400            | /           | 36/72         |

## 2.1 ASIC芯片在能效、价格、功耗等多方面具备竞争优势

- 相较于GPU，ASIC芯片在业务逻辑确定且需求量较大的场景下具备高能效、低功耗、降成本的优势。以英伟达GPU芯片和美国四大云商自研ASIC芯片对比为例，1) 功耗方面：ASIC芯片功耗明显低于GPU芯片，谷歌最新发布的TPU v7功耗约为GB200的35.5%；2) 能效方面：虽然ASIC与GPU在算力水平上仍存在一定差距，谷歌TPU v7算力约GB200的46.1%，但结合功耗后其能效比优于GB200（较GB200能效比提高26.3%），亚马逊及其他云商ASIC芯片能效比较英伟达系列芯片均处在较优水平；3) 成本方面：云商通过设计服务厂商自研ASIC芯片相较于直接外采英伟达GPU芯片可以明显降低成本，几大龙头ASIC设计厂商（Broadcom、Marvell）产品平均销售价格约5000-6500美金，较GPU芯片降本50%-60%，同时由于ASIC定制化的特点，随着需求提升、其规模效应有望提高，成本优势更加凸显。

图表：GPU与ASIC芯片参数对比

| GPU               |        |      |         | ASIC       |        |           |            |            |         |         |          |
|-------------------|--------|------|---------|------------|--------|-----------|------------|------------|---------|---------|----------|
| 厂商                |        | 英伟达  |         | 谷歌         |        | 亚马逊       |            | Meta       |         | 微软      |          |
| 代表产品              | GB200  | B200 | H200    | TPU v7     | TPU v6 | TPU v5    | Trainium 3 | Trainium 2 | MTIA v2 | MTIA v1 | Maia 100 |
| 发布时间              | 2024   | 2024 | 2023    | 2025       | 2024   | 2023      | 2024       | 2023       | 2024    | 2023    | 2023     |
| 制程                | 4NP    | 4NP  | 4nm     | 3nm        | 4nm    | 5nm       | 3nm        | 5nm        | 5nm     | 7nm     | 5nm      |
| FP16 (TFLOPS, 稠密) | 5000   | 2250 | 836-990 | 2307       | 918    | 196.5-459 | 1310       | 667        | 177     | 51.2    | 800      |
| 功耗 (W)            | 2700   | 1000 | 600-700 | 959        | 383    | 225-537   | 728        | 500        | 90      | 50      | 500      |
| 能效比 (TFLOPS/W)    | 1.9    | 2.2  | 1.4     | 2.4        | 2.4    | 0.9       | 1.8        | 1.3        | 2       | 2       | 1.6      |
| 平均单价 (\$)         | 约13000 |      |         | 约5000-6500 |        |           |            |            |         |         |          |

注：英伟达芯片平均单价取2024年其GPU业务营收/出货量，四大 CSPs芯片平均单价取Broadcom、Marvell 2024年ASIC业务营收/出货量

## 2.1 海外CSP布局自研ASIC

- “降本+AI推理需求提高+减少供应链依赖”推动云商自研ASIC芯片：一方面，云商自研ASIC相较向英伟达等商业公司外采可以有效降本同时减少供应链依赖，另一方面，ASIC较GPU拥有更可观的功耗控制与能效比叠加其定制化设计，在执行训练和推理任务时具备优势。因此全球各大厂纷纷布局ASIC产品：1) 谷歌16年发布首代TPU产品此后持续迭代至v7、v8，与博通和联发科（MTK）合作，v7预计今年Q4量产、v8预计26Q3投产；2) 亚马逊22年发布Trainium系列芯片，主要与Marvell和Alchip合作，第三/四代预计26Q1/27Q3量产；3) 微软Maia 200专为数据中心和AI任务定制，预计26年量产；4) Meta与博通合作，将于今年量产MTIA v2。

图表：美国CSPs ASIC关键项目量产时间预测表

| Company   | Project        | Design serice     | 1Q25 | 2Q25 | 3Q25 | 4Q25 | 1Q26 | 2Q26 | 3Q26 | 4Q26 | 1Q27 | 2Q27 | 3Q27 | 4Q27 |
|-----------|----------------|-------------------|------|------|------|------|------|------|------|------|------|------|------|------|
| AWS       | Trainium 2     | Annapurna+Marvell |      |      |      |      |      |      |      |      |      |      |      |      |
|           | Trainium 2.5   |                   |      |      |      |      |      |      |      |      |      |      |      |      |
|           | Trainium 3     | Annapurna+Alchip  |      |      |      |      |      |      |      |      |      |      |      |      |
|           | Trainium 4     |                   |      |      |      |      |      |      |      |      |      |      |      |      |
| Microsoft | Maia 100       | MSFT+GUC          |      |      |      |      |      |      |      |      |      |      |      |      |
|           | Maia 200       |                   |      |      |      |      |      |      |      |      |      |      |      |      |
|           | Maia 300       | Marvell           |      |      |      |      |      |      |      |      |      |      |      |      |
| META      | MTIA v1        | Broadcom          |      |      |      |      |      |      |      |      |      |      |      |      |
|           | MTIA v2        |                   |      |      |      |      |      |      |      |      |      |      |      |      |
|           | MTIA v3(v1)    |                   |      |      |      |      |      |      |      |      |      |      |      |      |
|           | MTIA v3(v1.5)  |                   |      |      |      |      |      |      |      |      |      |      |      |      |
| Google    | TPU v6         | Broadcom          |      |      |      |      |      |      |      |      |      |      |      |      |
|           | TPU v7p        |                   |      |      |      |      |      |      |      |      |      |      |      |      |
|           | TPU v7e        | Google+MTK        |      |      |      |      |      |      |      |      |      |      |      |      |
|           | TPU v8         | Broadcom          |      |      |      |      |      |      |      |      |      |      |      |      |
| OpenAI    | Titan 1        | Broadcom          |      |      |      |      |      |      |      |      |      |      |      |      |
|           | Titan 2        |                   |      |      |      |      |      |      |      |      |      |      |      |      |
| Apple     | Apple 1st ASIC | Broadcom          |      |      |      |      |      |      |      |      |      |      |      |      |



## 2.1海外加速ASIC，国内加速自主化

- **海外CSP加速自研ASIC。**TPU是谷歌自研的AI加速芯片，其AI模型Gemini即使用TPU提供算力支持。谷歌每一代TPU均在性能、可扩展性与系统效率上不断提升，并逐步将光互连技术融入TPU系统，最新TPU v7能够实现9216颗的大规模集群。据财联社，谷歌2027年TPU产能预计将达到500万颗，上修67%。此外，亚马逊12月3日AWS大会宣布Trainium3全面推出，明年快速扩容。Trainium 3部署进度将超市场预期，从12月3日当天起向客户开放使用，明年将开始非常快速地扩大规模。Tranium3较前代，其峰值计算性能提升最高达4.4倍，能效比提升4倍，内存带宽接近4倍。海外CSP推动自研ASIC进展积极。
- **国产积极推动算力芯片国产化。**时间维度上，国产模型比海外进度晚半年左右，算力储备也存在巨大差距，在模型追赶的过程中，也对应了国内算力需求的强上行周期。当前国产互联网在美制裁背景下，积极推动算力芯片国产替代。


图表：BBAT算力芯片进展

| 厂商   | 芯片进展                                                                                  | 合作企业                 |
|------|---------------------------------------------------------------------------------------|----------------------|
| 腾讯   | 紫霄芯片：腾讯自研AI推理芯片，采用创新存算一体架构和专用加速模块，已在内部推荐系统等AI场景中投入使用。                                 | 部分内部团队全自研设计、部分购买燧原科技 |
|      | 玄灵芯片：面向云计算场景设计的高性能网络芯片，可实现虚拟化零损耗，显著提升网络吞吐效率和资源利用率，已应用于腾讯云数据中心，为虚拟机和容器网络提供底层支持。        |                      |
| 阿里巴巴 | 含光800：2019年云栖大会发布，广泛应用于城市大脑、智能安防和新零售场景。                                               | 由内部达摩院全自研设计+外采主流国产厂商 |
|      | 倚天710：2021年云栖大会发布，阿里首款通用服务器芯片，基于ARM架构，采用5nm先进工艺，单核性能强、能效比高，主要服务于阿里云数据中心。              |                      |
| 字节跳动 | 受限于美国出口管制，紧急启动国产芯片加单以保障2026年AI算力供应，包括外采寒武纪、昇腾、海光等国产芯片和自研芯片。                           | 寒武纪、昇腾、海光等           |
| 百度   | 昆仑芯1代：2018年7月推出，是中国首款全功能云端AI芯片，具备高效、低成本、易用等特点，已在数据中心部署超2万片，支持训练与推理一体化。                | 百度昆仑团队全自研            |
|      | 昆仑芯2代：2021年8月宣布量产，采用7nm工艺，搭载第二代XPU架构，性能较1代提升2-3倍，是国内首款使用HBM显存的通用AI芯片，适用于云、边、端多场景。     |                      |
|      | M100：AI推理，2025年11月宣布推出，计划2026年初上市。                                                    |                      |
|      | M300：AI训练与推理，2025年11月宣布推出，计划2027年初上市。                                                 |                      |
|      | 超级节点：大规模AI计算，2025年11月发布天池256（集成256颗P800芯片，2026年上半年可用）及更高级版本（集成512颗P800芯片，2026年下半年可用）。 |                      |


## 2.1 中国GPU市场规模远期超万亿

- **中国AI智算GPU市场超万亿。**据摩尔线程招股书，中国AI智算GPU的市场规模从2020年的142.86亿元迅速增至2024年的996.72亿元，期间年均复合增长率高达62.5%。未来，随着AI不断发展，对算力的需求预计将呈现指数级增长，根据弗若斯特沙利文预测，到2029年，我国AI智算GPU市场规模将达到10,333.40亿元，2025-2029年年均复合增长率为56.7%。此外，桌面级产品的市场规模未来也将保持稳定增长，从2020年的241.91亿元增至2024年的641.45亿元，预计2029年将进一步增至3,302.38亿元。
- 在中国AI智算GPU市场中，数据中心GPU产品是过去增速最快的细分市场，其市场规模从2020年的82.00亿元以70.1%的年均复合增长率，快速增长至2024年的687.2亿元，预计未来还将以年均复合增长率55.7%的高增速增长至2029年的6639.2亿元。

图表：2020-2029E中国GPU市场规模收入（单位：亿元）



图表：2020-2029E中国AI智算GPU市场规模收入（单位：亿元）



## 2.2 AI等应用发展增加对先进制程需求

- 随着制程从 7nm 演进到 5nm、3nm 乃至 2nm，每一代节点上都实现了显著的 PPA（Performance、Power、Area）改善。以台积电公开数据为例，5nm 相较 7nm 提供约 1.8 倍的逻辑密度、15% 的性能提升或 30% 的功耗降低；3nm 再在此基础上实现约 18% 的性能提升或 32% 的功耗降低，并将逻辑密度进一步提高约 60%。规划中的 2nm 技术相较 3nm 将继续带来 10-18% 的性能提升以及 36% 的功耗降低。
- 当前主流 AI 芯片已全面向 5nm 与 3nm 等先进制程迁移。其中 NVIDIA 与 AMD 的最新一代 AI 芯片均采用台积电 3nm 制程，并配备大容量 HBM 以支撑高算力需求，其他主流 AI 芯片同样多数采用 5nm 或 4nm 的先进制程工艺。整体来看，先进制程已成为高端 AI 芯片的标配，未来 2nm 预计将进一步在该领域实现广泛采用。

图表：主流AI芯片先进制程使用情况

| 芯片            | 厂商     | 制程工艺   | 显存                      | 带宽           |
|---------------|--------|--------|-------------------------|--------------|
| Vera Rubin    | NVIDIA | 台积电3nm | 288GM<br>HBM4           | 13TB/s       |
| B300/GB300    | NVIDIA | 台积电4nm | 270-279GB<br>HBM3E      | 7.7-8TB/s    |
| B200/GB200    | NVIDIA | 台积电4nm | 180-186GB<br>HBM3E      | 7.7-8TB/s    |
| H200          | NVIDIA | 台积电4nm | 141GB HBM3E             | 4.8TB/s      |
| H100          | NVIDIA | 台积电4nm | 80-94GB<br>HBM3         | 3.35-3.9TB/s |
| MI355X/MI350X | AMD    | 台积电3nm | 288GB HBM3E             | 8TB/s        |
| MI325X/MI300X | AMD    | 台积电5nm | 192-256GB<br>HBM3/HBM3E | 5.3-6TB/s    |


图表：单位数量晶体管成本对比

| 制程                | 16nm   | 10nm   | 7nm    | 5nm    | 3nm    |
|-------------------|--------|--------|--------|--------|--------|
| 芯片面积 (mm²)        | 125    | 87.66  | 83.27  | 85     | 85     |
| 晶体管数量 (十亿个)       | 3.3    | 4.3    | 6.9    | 10.5   | 14.1   |
| 晶粒总数/单片晶圆         | 478    | 686    | 721    | 707    | 707    |
| 晶粒净产出/单片晶圆        | 359.74 | 512.44 | 545.65 | 530.25 | 509.04 |
| 晶圆价格 ( \$ )       | 5912   | 8389   | 9965   | 12500  | 15500  |
| 晶粒价格 ( \$ )       | 16.43  | 16.43  | 18.26  | 23.57  | 30.45  |
| 每十亿个晶体管的成本 ( \$ ) | 4.98   | 3.81   | 2.65   | 2.25   | 2.16   |

## 2.2制造市场规模大且大陆份额低，国产空间广阔

- 晶圆代工市场规模大，大陆替代空间广阔。据TrendForce，2024年全球晶圆代工市场规模约1402亿美元，同比增长19%，据IC Insights，2024年中国大陆晶圆代工市场规模约130亿美元，占全球比例近10%，相较于2016年占比稳步提升，未来大陆空间广阔。
- 台积电一家独大，国产TOP2份额约7.6%。竞争格局来看，台积电一家独大，凭借先进制程优势，占据了6成以上的市场份额，中国大陆厂商中芯国际和华虹集团分别位列第三和第五，合计份额约7.6%，可发展空间广阔。

图表：2016-2024 年晶圆代工市场规模（亿美元）



图表：24Q3-25Q2 晶圆代工厂商市场份额


|      | 24Q3  | 24Q4  | 25Q1  | 25Q2  |
|------|-------|-------|-------|-------|
| 台积电  | 64.7% | 67.1% | 67.6% | 70.2% |
| 三星   | 9.1%  | 8.1%  | 7.7%  | 7.3%  |
| 中芯国际 | 6%    | 5.5%  | 6%    | 5.1%  |
| 联电   | 5.1%  | 4.7%  | 4.7%  | 4.4%  |
| 格芯   | 4.8%  | 4.6%  | 4.2%  | 3.9%  |
| 华虹集团 | 2.7%  | 2.6%  | 2.7%  | 2.5%  |
| 其他   | 7.6%  | 7.4%  | 7.1%  | 6.6%  |



## 2.2 国产份额仍低，大陆厂商加速扩张

- 中国大陆晶圆制造需求大量由台积电代工，大陆厂商加速扩张。2024年，主要晶圆厂在中国大陆营收体量达200亿美元以上，其中台积电营收为111亿美元，占比达54%，表明中国大陆晶圆代工有大量的需求依然在由台积电等厂商满足，大陆自给率不足。另一方面来看，2020-2024年，大陆主要晶圆厂商的营收合计从32.2亿美元增长至94.1亿美元，CAGR为30.7%，相比之下，台积电的CAGR仅为9.1%，可见大陆晶圆厂正在加速扩张本土份额。

图表：主要晶圆厂在中国大陆营收（亿美元）



## 2.2全球制程技术加速迭代，国内仍有差距

■ 从行业看，晶圆代工的发展方向是向更先进的制程持续推进。目前，业界普遍认为28nm是成熟制程与先进制程的分界线。成熟制程指工艺节点在28nm及以上，其工艺成熟、良率高、制造成本低，适合大规模量产，广泛应用于电源管理芯片（PMIC）、模拟芯片与微控制器（MCU），并服务于消费电子、汽车电子、工业控制及物联网等领域。目前，中国大陆晶圆厂在成熟制程方面进展迅速，在显示驱动IC、功率、模拟、CIS、PMIC等方面均有所突破。先进制程则指28nm及以下节点，专注于高端市场。尽管研发与生产成本高、技术难度大，但可提供更高的晶体管集成度、更低的功耗和更快的性能，主要面向高性能计算（HPC）、人工智能（AI）、5G通信及移动设备处理器等高端应用。目前，晶圆代工龙头台积电、三星正积极推动2nm工艺的量产，并加速2nm以下制程的布局，国内相较海外仍有差距。

图表：全球主要晶圆厂制程节点技术路线图

| 公司  | 制程      | 2018     | 2019      | 2020     | 2021 | 2022       | 2023       | 2024       | 2025E              | 2026E          |
|-----|---------|----------|-----------|----------|------|------------|------------|------------|--------------------|----------------|
| 台积电 | 7/6nm   | N7 (DUV) | N7+ (EUV) | N6 (EUV) |      |            |            |            |                    |                |
|     | 5/4nm   |          |           | N5       | N5P  | N4/N4P     |            | N4X        | N4C                |                |
|     | 3nm     |          |           |          |      | N3 FinFET  | N3E FinFET | N3P FinFET | N3X FinFET         |                |
|     | 2nm     |          |           |          |      |            |            |            | N2 GAAFET          | N2P/N2X GAAFET |
|     | A14/A10 |          |           |          |      |            |            | A14土建      | A14封顶<br>A10动土     |                |
| 三星  | 7/6nm   |          | 7LPP      | 6LPP     |      |            |            |            |                    |                |
|     | 5/4nm   |          |           | 5LPE     | 4LPE | 5/4LPP     | 4LPP+      | 4HPC       | 4LPA               |                |
|     | 3nm     |          |           |          |      | 3GAE/SF3E  |            | 3GAP/SF3   | 3GAP+/SF3P         |                |
|     |         |          |           |          |      | GAA MBCFET |            | GAA MBCFET | GAA MBCFET         |                |
|     | 2nm     |          |           |          |      |            |            |            | 2GAP<br>GAA MBCFET |                |

## 2.2中芯国际：大陆最大代工厂， 前瞻推进至先进制程

- 中芯国际积极布局先进制程。经历 25 年的发展，中芯国际折合 8 寸月产能在 25Q3 年达到 102.3 万片，为大陆产能规模最大的晶圆代工厂。2016 年中芯南方成立，系公司先进技术及制程产线的运营主体，提供 14nm FinFET 及以下技术工艺；同年 12 月，公司开建其第一条 14nm 产线，地址位于其上海厂区。2017 年，梁孟松加入中芯国际，随后带领公司攻克 14nm 节点，并完成 7nm 技术开发。虽然后续美国制裁限制了公司 14nm 及以下制程的扩产，但中芯国际仍然是大陆晶圆厂中少数具备先进制程量产经验、并完成 7nm 技术制造的厂商。


图表：中芯国际芯片代工厂布局



## 2.2 华虹半导体：集团唯一上市平台，华力微注入体内预期

- **上海国资委实控，股权结构稳定。**上海国资委通过华虹集团、华虹国际间接持有华虹半导体20%股份，通过上海联和、联和国际间接持有华虹半导体9.3%股份，两者合计持股29.3%，是公司实际控制人。此外，上海国资委还通过上海创投、上海国盛等公司控股ICRD（上海集成电路研发中心公司）53%的股份。
- **华力微注入上市公司体内，有望增厚业绩。**华虹公司通过三家子公司展开业务，分别是华虹宏力（一二三厂）、华虹无锡（七厂）和华虹制造（九厂），此外华虹集团持有上海华力微电子有限公司（五厂）54%的股份，上海华力微持有上海华力集成电路制造有限公司（六厂）54%的股份。2025年8月18日，公司公告拟通过发行股份及支付现金方式收购华力微控制权，并配套募集资金。随着华力微的注入，有望进一步增厚上市公司业绩。

图表：华虹集团股权架构图  
(截至2025年9月30日)






## 2.2 AI性能需求快速增长，先进封装亟待发展

- AI时代数据峰值吞吐量增速高于峰值带宽增速，提高I/O密度迫在眉睫。随着大数据、AI等新技术的发展，当前计算系统面临着带宽不足的问题。据台积电，计算系统需处理的数据峰值吞吐量平均每两年增长1.8倍，而峰值带宽每两年增长仅约1.6倍，峰值带宽较峰值吞吐量的差距愈发扩大，增加峰值带宽迫在眉睫，而增加峰值带宽最有效的方式是增加I/O数量。


图表：数据峰值吞吐量增速快于峰值带宽增速



## 2.2 AI性能需求快速增长，先进封装亟待发展

- 先进封装可有效提升I/O密度，是AI大数据时代封装发展的必由之路。随着ChatGPT点燃AI行情，微软、谷歌以及国内百度、阿里巴巴等先后发布大模型，算力需求持续释放。据台积电，CoWoS、InFO、Flip-Chip等先进封装技术，可有效提升I/O密度。例如Flip-Chip技术将每平方毫米I/O密度提升到100个级别，InFO和CoWoS工艺进一步将I/O密度提升到1000个级别，是此前技术的10倍。据台积电预测，通过使用SoIC及其未来的扩展，未来芯片I/O密度有可能再提高10000倍。


图表：先进封装提升I/O仍有很大发展空间



## 2.2单位面积I/O数量增加是升级方向，2.5D/3D代表未来趋势

- 先进封装朝着更细I/O间距和更细RDL线间距方向发展。如前文所述，大数据、AI时代，发展先进封装、提升I/O密度是应有之义。而提升I/O最直观的方式即制造更细的I/O间距（pitch）和更细线间距（L/S）。
- 具体而言I/O间距包括：1）混合键合（一种将介电键（SiO<sub>x</sub>）与嵌入金属（Cu）结合形成互连的工艺技术）时上下die之间的键合间距，2015年时为2μm级别，到2023年有望升级至1μm以下；2）Bumping工艺中Bump（通常称作“凸点”或“凸块”，为先进封装上下层连接的接触部分）间距，2015年在200-150μm，2025年有望达到50μm级别；3）Ball（焊球）间距，2021年之前在1200-350μm级别，2023年有望达300μm级别。而线间距主要指RDL（重新布线层）的L/S（线间距），2015年≥10μm，2023年有望达2μm级别。


图表：先进封装发展技术路线图





## 2.2单位面积I/O数量增加是升级方向，2.5D/3D代表未来趋势


图表：先进封装技术分类





- **2.5D/3D封装市场的2021-2027年复合增长率高达14.34%。**先进封装各细分类别中，2.5D/3D封装市场的年复合增长率最大，高达14.34%，主要由AI、HPC、HBM等应用驱动；而WLCSP主要用于手机、智能穿戴等主控芯片中，近年来随着手机总销量放缓，拖累了WLCSP的复合增速预期。

图表：2021-2027E全球先进封装市场规模（按技术分类，单位：亿美元）



2.2单位面积I/O数量增加是升级方向，2.5D/3D代表未来趋势


图表：2021-2027E全球先进封装市场规模及出货量（按技术分类）

| 封装技术    |            | 2021  | 2022E | 2023E | 2024E | 2025E | 2026E | 2027E | CAGR   |
|---------|------------|-------|-------|-------|-------|-------|-------|-------|--------|
| SIP     | 销售额（百万-美元） | 3806  | 4174  | 4376  | 4511  | 4546  | 4739  | 4801  | 3.95%  |
|         | 出货量（百万颗）   | 9435  | 10128 | 10395 | 10818 | 11251 | 11597 | 11911 | 3.96%  |
|         | 每颗单价(颗/美元) | 0.40  | 0.41  | 0.42  | 0.42  | 0.40  | 0.41  | 0.40  |        |
| FCCSP   | 销售额（百万-美元） | 6347  | 7054  | 7984  | 8699  | 9721  | 11189 | 13243 | 13.04% |
|         | 出货量（百万颗）   | 12606 | 13347 | 14586 | 16020 | 18293 | 21493 | 26020 | 12.84% |
|         | 每颗单价(颗/美元) | 0.50  | 0.53  | 0.55  | 0.54  | 0.53  | 0.52  | 0.51  |        |
| FCBGA   | 销售额（百万美元）  | 10821 | 12586 | 13183 | 14292 | 14746 | 16481 | 17331 | 8.17%  |
|         | 出货量（百万颗）   | 1259  | 1304  | 1354  | 1466  | 1501  | 1662  | 1726  | 5.39%  |
|         | 每颗单价(颗/美元) | 8.59  | 9.65  | 9.74  | 9.75  | 9.82  | 9.92  | 10.04 |        |
| 2.5D/3D | 销售额（百万美元）  | 6607  | 7950  | 9151  | 10470 | 11820 | 13145 | 14766 | 14.34% |
|         | 出货量（百万颗）   | 3078  | 3591  | 4052  | 4541  | 5033  | 5560  | 6128  | 12.16% |
|         | 每颗单价(颗/美元) | 2.15  | 2.21  | 2.26  | 2.31  | 2.35  | 2.36  | 2.41  |        |
| WLCSP   | 销售额（百万美元）  | 2398  | 2540  | 2703  | 2880  | 2869  | 2991  | 3132  | 4.55%  |
|         | 出货量（百万颗）   | 31391 | 32940 | 34766 | 36725 | 36685 | 36681 | 38525 | 3.47%  |
|         | 每颗单价(颗/美元) | 0.08  | 0.08  | 0.08  | 0.08  | 0.08  | 0.08  | 0.08  |        |
| FO      | 销售额（百万美元）  | 2137  | 2401  | 2758  | 3114  | 3348  | 3656  | 3975  | 10.90% |
|         | 出货量（百万颗）   | 2810  | 2843  | 3091  | 3273  | 3278  | 3334  | 3338  | 2.92%  |
|         | 每颗单价(颗/美元) | 0.76  | 0.84  | 0.89  | 0.95  | 1.02  | 1.10  | 1.19  |        |
| TOTAL   | 销售额（百万美元）  | 32115 | 36704 | 40154 | 43966 | 47049 | 52200 | 57247 | 10.11% |
|         | 出货量（百万颗）   | 60579 | 64154 | 68244 | 72842 | 76041 | 80327 | 87648 | 6.35%  |
|         | 每颗单价(颗/美元) | 0.53  | 0.57  | 0.59  | 0.60  | 0.62  | 0.65  | 0.65  |        |


## 2.2 CoWoS技术优势凸出：实现多芯片封装、高密度互连

- CoWoS通过Si Interposer进行互联，实现多芯片封装、高密度互连和功耗优化。2011年，台积电认为摩尔定律开始面临困境，因此决定在先进封装领域寻求突破。2012年，台积电与赛灵思合作推出Virtex-7 HT系列FPGA，采用的工艺是CoWoS（Chip-on-Wafer-on-Substrate）。CoWoS是一种2.5D封装技术，先将芯片（如处理器、存储器等）通过Chip on Wafer（CoW）的工艺与硅转接板连接，然后将CoW芯片与基板（Substrate）连接，形成CoWoS结构，加入硅转接板是因为基板的最小线宽较大，用硅转接板在中间做过渡，可以缩小线宽，进行高密度I/O的互连。CoWoS技术采用了TSV、 $\mu$ Bump和RDL技术，该封装方法使得多颗芯片可被集成在一起，制造出体积小、功耗低、高密度互连的封装。

图表：CoWoS结构示意图



图表：转接板的典型结构






## 2.2 CoWoS技术优势凸出：实现多芯片封装、高密度互连

### ■ CoWoS封装技术主要分为CoWoS-S、CoWoS-R、CoWoS-L。

- 1) **CoWoS-S (Silicon)**：最早被广泛采用的一种CoWoS技术。它采用硅中介层实现芯片之间的重分布层（RDL）连接，是目前最为成熟的CoWoS技术。
- 2) **CoWoS-R (RDL)**：使用高密度I/O的RDL层作为转接板，灵活星高，相较于CoWoS-S技术，成本更低。
- 3) **CoWoS-L (Local)**：是CoWoS技术的扩展版，针对需要更大规模集成的应用场景。在硅中介层（-S）和有机中介层（-R）之间，增加了硅桥连接相邻芯片边缘的（超短距离）互连。这些硅片嵌入在有机基板中，既提供了高密度的超短距离连接（具有紧凑的线间距），又具备有机基板上（粗线和层板）的互连和电力分配特性。

图表：cowos分为三种类型

| 类型             | 特点                                                                                                                     | 图示                                                                                   |
|----------------|------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------|
| <b>COWOS-S</b> | 通常所说的COWOS指的就是COWOS-S，S指Silicon，Interposer是硅片★CoWos类型中成本最高，性能最好，最成熟的技术，相较于RDL interposer，Silicon interposer可以做到更高的布线密度 |   |
| <b>COWOS-R</b> | R指RDL，interposer是RDL层，RDL 中介层由聚合物和铜走线组成，在机械上相对灵活★成本降低，灵活性高                                                             |   |
| <b>COWOS-L</b> | L指LSI (Local Silicon Interconnect)，使用局部的硅桥进行芯片之间的电气互联，硅桥以外的位置使用RDL层或substrate进行代替★针对需要更大规模集成的应用场景                      |  |




## 2.2 CoWoS技术10年5次迭代，受益AI迎来新机遇


■ CoWoS发展历程：从技术角度来看，CoWoS在面积、晶体管数量与内存提升上不断改进。

- 1) 通过光罩拼接技术持续扩大中介层面积，晶体管数量不断增多：CoWoS使用的是硅制造技术，遵守光罩限制的原则，2011年台积电开发出的第一代CoWoS-S硅中介层最大面积为775mm<sup>2</sup>，已经接近掩膜版的曝光尺寸极限（858mm<sup>2</sup>），对此，台积电研发出光罩拼接技术突破了该瓶颈，光罩拼接即两个光罩组合，产生重合部分的RDL互联需做到一致。突破光罩限制后，2014年台积电第二代CoWoS-S产品的硅中介层面积达到1150mm<sup>2</sup>，第三代/第四代/第五代/第六代硅中介层面积分别为1245mm<sup>2</sup>、1660mm<sup>2</sup>、2500mm<sup>2</sup>、3320mm<sup>2</sup>，对应的集成芯片数量分别为1个soc+4个HBM（内存16GB）、1个soc+6个HBM（内存48GB）、2个soc+8个HBM（内存128GB）、2个soc+12个HBM。硅转接板面积不断增加，便于集成更多元器件，从第三代开始，CoWoS由同质集成转变为异质集成。第五代芯片不仅对逻辑与内存进行了改进，还针对硅中介层的RDL、TSV进行改进，在硅中介层加入了eDTC（嵌入式深沟槽电容器）以进一步稳定电源系统。在应用上，赛灵思高端FPGA“XCVU440”采用了第二代CoWoS，英伟达GP100采用了第三代CoWoS，英伟达A100、H100采用第四代CoWoS。

图表：台积电CoWoS封装技术路线图




图表：CoWoS时间线梳理




## 2.2 CoWoS技术10年5次迭代，受益AI迎来新机遇

- CoWoS发展历程：从应用层面来看，已应用于HPC、AI领域多款高性能芯片中。
- CoWoS技术得到英伟达、AMD等科技巨头使用。第一代CoWoS封装技术被赛灵思高端FPGA采用，FPGA“7V2000T”配备四个FPGA逻辑芯片；第二代CoWoS于2015年被赛灵思高端FPGA“XCVU440”采用，配备了三个FPGA逻辑芯片；第三代CoWoS则在2016年被英伟达高端GPU“GP100”采用，配备了4个16GB的HBM2模块和大容量的DRAM和GPU高速连接。第四代CoWoS在2020年被英伟达A100 GPU系列产品使用，将1颗英伟达A100 GPU芯片和6个三星的HBM2集成在一个1700mm<sup>2</sup>的无源转接板上，每个HBM2集成1颗逻辑芯片和8个动态随机存取存储器（DRAM）。目前英伟达H100/B100等数据中心GPU使用的都是CoWoS技术。此外，Broadcom、Google TPU、Amazon Trainium、NEC Aurora、Fujitsu A64FX、AMD Vega、Intel Spring Crest和Habana Labs Gaudi均使用了CoWoS技术。台积电表示，2020年TOP 500超算中有超过一半的算力来自基于CoWoS-S封装技术的芯片。CoWoS一大重要应用场景就是HPC、AI领域中需要大规模堆砌算力、存储资源的芯片。

图表：B100 GPU和HBM阵列



图表：CoWoS封装切面图



## 2.2 国产2.5D/3D封装崛起，为本土AI赋能

■ 国产2.5D/3D封装发展迅速，为本土AI产业提供坚实支持。国内封测厂中，长电科技在 QFN、WLP 与 FCBGA 等封装上经验成熟，并通过 XDFOI® 推进高密度异构集成技术，向 2.5D/3D 方向持续发展。通富微电在 Bumping、WLCSP、SIP 等工艺布局广泛，持续推进 2D+先进封装项目。华天科技具备 DIP、SOP、WLP/WLCSP 及 TSV 等能力，2.5D/3D 产线已建成通线。甬矽电子的先进封装占比最高，已覆盖多类封装技术，2.5D 项目实现样品交付并进入客户验证阶段。

图表：大陆厂商封装技术布局及先进封装业务占比

| 公司名称 | 先进封装占比 | 主要封装技术                                      | 2.5D/3D封装进展                                                 |
|------|--------|---------------------------------------------|-------------------------------------------------------------|
| 长电科技 | 65%    | Wire bonding、QFN 到 WLP、FCBGA、2.5D/3D        | 推出XDFOI®芯粒高密度多维异构集成系列工艺，已进入量产阶段<br>利用工艺设计协同优化突破了2.5D、3D集成技术 |
| 通富微电 | 75%    | Bumping、WLCSP、FC、BGA、SIP、OFN、QFP、SO、2.5D/3D | 南通通富2D+ 先进封装项目已完成机电安装消防备案                                   |
| 华天科技 | 70%    | DIP、SOP、SIP、CSP、WLP/WLCSP、2.5D/3D(TSV)      | 2.5D/3D 封装产线已完成通线                                           |
| 甬矽电子 | 100%   | FCCSP、FCBGA、FC、SIP、BGA、QFN、MEMS             | 2.5D 封装已通线并完成样品交付，截至 25H1处于客户产品验证阶段                         |




## 2.3 存储需求：服务器是最强动力，AI推理驱动需求爆发

- 受益AI数据中心建设需求，服务器是近几年存储需求的最强驱动力，26年有望成为DRAM、NAND最大下游需求。
- DRAM：2024年全球需求总量达到30.9EB，下游需求占比：手机37%、服务器37%、PC 11%、Graphics（包含HBM）7%，手机+PC+服务器占据85%需求，考虑Graphics（包含HBM），手机+PC+服务器占据92%需求。Trendforce预计26年服务器DRAM需求增速35%，占比达到41%，Graphics占比达到12%，服务器成为DRAM最大下游需求。
- NAND：2024年全球需求总量达到871EB，下游需求占比：手机33%、服务器24%、PC 23%，手机+PC+服务器占据80%需求。Trendforce预计26年服务器NAND需求增速48%，占比达到37%，服务器成为NAND最大下游需求。


图表：DRAM需求量（单位：EB）

■ PC ■ Server ■ Mobile ■ Graphics ■ Others




图表：DRAM需求不同下游占比

■ PC ■ Server ■ Mobile ■ Graphics ■ Others




图表：DRAM不同下游需求增速

— PC — Server — Mobile — Graphics — Others




图表：NAND需求量（单位：EB）

■ Handsets ■ PC SSD ■ Game Console  
■ Enterprise SSD ■ UFD+Memory Card ■ Others




图表：NAND需求不同下游占比

■ Handsets ■ PC SSD ■ Game Console  
■ Enterprise SSD ■ UFD+Memory Card ■ Others



图表：NAND不同下游需求增速

— Handsets — PC SSD — Game Console  
— Enterprise SSD — UFD+Memory Card





## 2.3 存储需求：服务器是最强动力，AI推理驱动需求爆发

- 受益AI数据中心建设需求，服务器是近几年存储需求的最强驱动力，26年有望成为DRAM、NAND最大下游需求。
- 手机、PC和服务对DRAM、NAND存储需求直观体现在出货量和单机容量两个维度。
- 1) 手机和PC的出货量已达到相对稳态天花板状态，对存储的需求更多体现在单机容量逐步提升。预计2020-2025年手机、PC的出货量CAGR均为-2%，预计2020-2025年手机单机DRAM容量CAGR14%、NAND容量CAGR17%，预计2020-2025年PC单机DRAM容量CAGR 11%、NAND容量CAGR 15%。
- 2) 服务器出货量和单机容量均在快速提升。预计2020-2025年服务器出货量CAGR为5%，预计2020-2025年服务器单机DRAM容量CAGR 13%、NAND容量CAGR 26%。

图表：DRAM、NAND三大下游的出货量和单机容量趋势

|                | 2018  | 2019  | 2020  | 2021  | 2022   | 2023   | 2024   | 2025E  | 2020-2025 CAGR |
|----------------|-------|-------|-------|-------|--------|--------|--------|--------|----------------|
| 出货量（百万台）       |       |       |       |       |        |        |        |        |                |
| 手机             | 1,891 | 1,795 | 1,608 | 1,655 | 1,437  | 1,380  | 1,437  | 1,435  | -2%            |
| PC             | 265   | 273   | 312   | 361   | 301    | 260    | 263    | 278    | -2%            |
| 服务器            | 12    | 12    | 13    | 14    | 15     | 12     | 14     | 16     | 5%             |
| YOY            |       |       |       |       |        |        |        |        |                |
| 手机             |       | -5%   | -10%  | 3%    | -13%   | -4%    | 4%     | 0%     |                |
| PC             |       | 3%    | 14%   | 16%   | -17%   | -14%   | 1%     | 6%     |                |
| 服务器            |       | 0%    | 7%    | 7%    | 10%    | -17%   | 17%    | 12%    |                |
| DRAM单机容量（GB/台） |       |       |       |       |        |        |        |        |                |
| 手机             | 4     | 5     | 6     | 6     | 8      | 8      | 9      | 11     | 14%            |
| PC             | 7     | 8     | 8     | 8     | 10     | 12     | 12     | 13     | 11%            |
| 服务器            | 352   | 420   | 476   | 545   | 585    | 819    | 785    | 892    | 13%            |
| YOY            |       |       |       |       |        |        |        |        |                |
| 手机             |       | 17%   | 19%   | 11%   | 22%    | 9%     | 13%    | 14%    |                |
| PC             |       | 6%    | -1%   | 6%    | 29%    | 19%    | 1%     | 5%     |                |
| 服务器            |       | 19%   | 13%   | 15%   | 7%     | 40%    | -4%    | 14%    |                |
| NAND单机容量（GB/台） |       |       |       |       |        |        |        |        |                |
| 手机             | 72    | 92    | 117   | 145   | 179    | 229    | 231    | 257    | 17%            |
| PC             | 192   | 323   | 367   | 451   | 564    | 729    | 770    | 749    | 15%            |
| 服务器            | 3,660 | 4,463 | 5,893 | 8,236 | 10,752 | 18,326 | 14,395 | 18,396 | 26%            |
| YOY            |       |       |       |       |        |        |        |        |                |
| 手机             |       | 28%   | 27%   | 24%   | 23%    | 28%    | 1%     | 11%    |                |
| PC             |       | 69%   | 14%   | 23%   | 25%    | 29%    | 6%     | -3%    |                |
| 服务器            |       | 22%   | 32%   | 40%   | 31%    | 70%    | -21%   | 28%    |                |

注意：DRAM单机容量没有考虑HBM

来源：IDC、Trendforce，中泰证券研究所

## 2.3 存储需求：服务器是最强动力，AI推理驱动需求爆发

- 2024年服务器存储市场（DRAM+NAND+HDD）近700亿美金，预计25年达到1100亿美金规模。
- CSP的资本开支投入带来数据中心相关建设，数据中心建设需要三类服务器，AI服务器、普通服务器和存储服务器。AI服务器涉及的存储器主要是HBM、DRAM和固态硬盘SSD（NAND Flash为存储介质），普通服务器涉及的存储器主要是DRAM、NAND Flash（SSD形态），存储服务器涉及机械硬盘和固态硬盘SSD。
- 服务器存储市场规模：根据我们的测算，2024年服务器DRAM市场383亿美金（含HBM），服务器NAND市场158亿美金，服务器HDD市场126亿美金，合计达到667亿美金规模，预计25年达到1100亿美金。根据Gartner数据，2024年服务器DRAM市场181亿美金，HBM 152亿美金，合计333亿美金。
- 服务器存储配置：根据我们的测算，2025年预计每100万台服务器（包含AI、普通和存储服务器）的存储器配置容量为DRAM 1EB、NAND Flash 17.8 EB、HDD 86EB，DRAM、NAND Flash、HDD的配置比例接近1:20:100，同时DRAM、NAND、HDD的容量增加趋势显著。2023-2025年服务器中存储器的价值量占比在25%左右。
- AI服务器存储配置：我们详细梳理了英伟达AI服务器，NVL72 GB200、GB300中，HBM、DRAM、NAND三类存储的价值量占机架售价的比例在8-10%左右。2026年，英伟达NVL72、NVL144机架对HBM需求2.1EB，LPDDR需求1.8EB，NAND需求范围在49-98EB，占据全球约一半HBM需求，24年LPDDR需求10.6EB，企业级SSD需求208EB，拉动也较为显著。

图表：全球服务器存储市场规模和服务器存储价值量测算

|                       | 2023   | 2024   | 2025E  |
|-----------------------|--------|--------|--------|
| 全球存储需求 (EB)           |        |        |        |
| Server DRAM           | 10.1   | 11.4   | 14.4   |
| Graphic DRAM          | 1.4    | 2.3    | 3.8    |
| Enterprise SSD        | 227    | 208    | 297    |
| 企业级HDD                | 606    | 1,052  | 1,429  |
| 存储ASP (美金/GB)         |        |        |        |
| DRAM ASP              | 2.0    | 3.1    | 3.9    |
| NAND ASP              | 0.04   | 0.08   | 0.07   |
| 企业级HDD ASP            | 0.011  | 0.012  | 0.014  |
| 服务器存储价值量 (亿美金)        |        |        |        |
| DRAM (涵盖HBM)          | 202    | 383    | 668    |
| NAND                  | 94     | 158    | 205    |
| HDD                   | 67     | 126    | 198    |
| 合计                    | 362    | 667    | 1,071  |
| 全球服务器出货情况             |        |        |        |
| 服务器出货量 (百万台)          | 12     | 14     | 17     |
| 服务器价值量 (亿美金)          | 1,473  | 2,530  | 4,554  |
| ASP (美金/台)            | 11,890 | 17,250 | 27,223 |
| 每100万台服务器的存储容量 (EB)   |        |        |        |
| DRAM                  | 0.8    | 0.9    | 1.0    |
| NAND Flash            | 18.3   | 14.4   | 17.8   |
| HDD                   | 49     | 73     | 86     |
| 每100万台服务器的存储价值量 (亿美金) |        |        |        |
| DRAM                  | 16.3   | 26.4   | 40.0   |
| NAND Flash            | 7.6    | 10.9   | 12.3   |
| HDD                   | 5.4    | 8.7    | 11.9   |
| 合计                    | 29.3   | 46.1   | 64.2   |
| 服务器中存储的价值量占比          | 25%    | 26%    | 24%    |

图表：英伟达AI服务器的存储配置梳理

|            | DGXA100                                                                                                        | DGXH100                                                                                                                          | DGXH200                                                                                                                          | GB200 NVL72                                                                                                                                                                                       | GB300 NVL72                                                                                                                                             | NVL144 (Rubin)                                                                                                                                            |
|------------|----------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------|
| 类型         | 8卡服务器                                                                                                          | 8卡服务器                                                                                                                            | 8卡服务器                                                                                                                            | 机架                                                                                                                                                                                                | 机架                                                                                                                                                      | 机架                                                                                                                                                        |
| GPU        | 8颗A100                                                                                                         | 8颗 H100                                                                                                                          | 8颗H200                                                                                                                           | 72颗B200                                                                                                                                                                                           | 72颗B300                                                                                                                                                 | 72颗Rubin, 144 Rubin (按 dual-reticle 计数)                                                                                                                   |
| CPU        | 2颗CPU                                                                                                          | 2颗intel 8480C                                                                                                                    | 2颗intel 8480C                                                                                                                    | 36颗Grace CPU                                                                                                                                                                                      | 36颗Grace CPU                                                                                                                                            | 36颗Vera CPU                                                                                                                                               |
| HBM        | 640GB (单颗GPU配置6颗16GB HBM2e, 但实际调用5颗)                                                                           | 640GB (单颗GPU配置6颗16GB HBM3, 但实际调用5颗)                                                                                              | 1128GB (单颗GPU使用6颗24GB HBM3E)                                                                                                     | 13.5 TB HBM3e (单颗GPU使用8颗24GB HBM, 全柜8*24*72)                                                                                                                                                      | 20TB HBM3E (单颗GPU配置8颗36GB, 全柜36*8*72)                                                                                                                   | 20TB HBM4 (单颗GPU配置8颗36GB, 全部就是36*8*72)                                                                                                                    |
| CPU配置的DRAM | 2TB DDR4                                                                                                       | 2TB DDR5 (32根64GB内存条)                                                                                                            | 2TB DDR5 (32根64GB内存条)                                                                                                            | 17 TB LPDDR5X (单颗CPU配置16颗30GB LPDDR5=480GB)                                                                                                                                                       | 17 TB LPDDR5X (单颗CPU配置16颗30GB LPDDR5=480GB)                                                                                                             | 使用SOCAMM2                                                                                                                                                 |
| SSD配置      | 数据缓存盘: 8×3.84TB NVMe企业级SSD, 合计30TB (DGX A100整机标配) 123。<br>另有OS盘为2×1.92TB NVMe SSD (部分配置), 用于系统和管理软件, 容量约3.84TB | 1、2×1.92 TB NVMe M.2 SSD (each) in RAID 1 array) 【可用容量1.92TB, 因为做备份; 装操作系统、驱动、管理软件】<br>2、8×3.84 TB NVMe U.2 SED in RAID 0 array) | 1、2×1.92 TB NVMe M.2 SSD (each) in RAID 1 array) 【可用容量1.92TB, 因为做备份; 装操作系统、驱动、管理软件】<br>2、8×3.84 TB NVMe U.2 SED in RAID 0 array) | 一柜 18 个 compute tray, 每个 tray 8× E1.S Gen5 NVMe, 合计就是 18 × 8 = 144 块 E1.S<br>3.84 TB 盘: 144 × 3.84 =0.55 PB<br>7.68 TB 盘: 144 × 7.68 =1.11 PB。<br>(可选) 引导盘: 部分 OEM 在 tray 上另配 M.2 NVMe 作为 OS/Boot | 最多 144 个 E1.S PCIe 5.0 容量取决于选配:<br>3.84 TB 盘: 144 × 3.84 =0.55 PB<br>7.68 TB 盘: 144 × 7.68 =1.11 PB。<br>(可选) 引导盘: 部分 OEM 在 tray 上另配 M.2 NVMe 作为 OS/Boot | 最多 144 个 E1.S PCIe 5.0 容量取决于选配:<br>3.84 TB 盘: 144 × 3.84 ≈ 0.55 PB<br>7.68 TB 盘: 144 × 7.68 ≈ 1.11 PB。<br>(可选) 引导盘: 部分 OEM 在 tray 上另配 M.2 NVMe 作为 OS/Boot |

图表：英伟达AI服务器的存储价值量占比情况

|                 | DGXA100 | DGXH100 | DGXH200 | GB200 NVL72 | GB300 NVL72 | NVL144 (Rubin) |
|-----------------|---------|---------|---------|-------------|-------------|----------------|
| 美金/GB (2024年均价) |         |         |         |             |             |                |
| HBM             | 13      | 13      | 13      | 13          | 13          | 13             |
| DRAM            | 2.5     | 2.5     | 2.5     | 2.5         | 2.5         | 5              |
| NAND Flash      | 0.07    | 0.07    | 0.07    | 0.07        | 0.07        | 0.07           |
| 机架配置的容量 (TB)    |         |         |         |             |             |                |
| HBM             | 0.6     | 0.6     | 1.1     | 13.5        | 20.0        | 20.0           |
| DRAM            | 2.0     | 2.0     | 2.0     | 17.0        | 17.0        | 17.0           |
| NAND Flash      | 33.8    | 33.8    | 33.8    | 553.0       | 553.0       | 553.0          |
| 机架配置的存储价值量 (美金) |         |         |         |             |             |                |
| HBM             | 8,320   | 8,320   | 14,664  | 179,712     | 266,240     | 266,240        |
| DRAM            | 5,120   | 5,120   | 5,120   | 43,520      | 43,520      | 87,040         |
| NAND Flash      | 2,426   | 2,426   | 2,426   | 39,636      | 39,636      | 39,636         |
| 合计              | 15,866  | 15,866  | 22,210  | 262,868     | 349,396     | 392,916        |
| 不同存储的价值量占比      |         |         |         |             |             |                |
| HBM             | 52%     | 52%     | 66%     | 68%         | 76%         | 68%            |
| DRAM            | 32%     | 32%     | 23%     | 17%         | 12%         | 22%            |
| NAND Flash      | 15%     | 15%     | 11%     | 15%         | 11%         | 10%            |
| 机架的售价 (万美金)     | 10      | 20      | 30      | 320         | 350         | 360            |
| AI服务器中的存储价值量占比  | 16%     | 8%      | 7%      | 8%          | 10%         | 11%            |

图表：英伟达AI服务器的存储需求测算

|                    | 2024 | 2025E | 2026E |
|--------------------|------|-------|-------|
| 英伟达服务器的存储需求测算 (EB) |      |       |       |
| HBM                | 0.4  | 1.1   | 2.1   |
| DRAM               | 0.9  | 1.2   | 1.8   |
| NAND (3.84TB单盘容量)  | 16.1 | 31.2  | 49.3  |
| NAND (7.68TB单盘容量)  | 32.2 | 62.4  | 98.5  |

- 理解服务器对存储的增量需求，我们认为可以从AI Capex和AI发展2个维度。
- 1、Capex角度看存储器需求：26年服务器相关存储需求增速至少30%。
  - 25Q3大型CSP厂商对26年Capex进行规划、制定关键器件的采购计划，开始与存储原厂谈26年长期供货协议（LTA），26年CSP存储需求超过供给，存储现货价开始飙升，25Q4存储合约价价格涨幅开始超预期。另外HDD供给有限，加速NAND替代HDD。
  - 根据Trendforce，2026年全球八大CSP的资本开支投入2026年有望达到6020亿美金，yoy+40%。（注：八大CSP包含美系谷歌、亚马逊、Meta、微软、甲骨文以及中系的腾讯、阿里巴巴和百度。）全球服务器主要由CSP和非CSP采购，CSP Capex中服务器价值量占比达到60%左右，由此得到2026年全球CSP服务器相关支出达到3612亿美金。根据我们的测算，2023-2025年服务器中存储价值量25%左右，2026年CSP服务器存储采购金额有望达到850亿美金（未考虑26年存储价格上涨影响），yoy+40%，假设非CSP的需求增加20%，2026年全球服务器存储采购金额达到1376亿美金，yoy+31%，带来企业级DRAM、NAND、HDD的需求全面提升。

图表：Capex维度拆解存储需求（注：该测算未考虑26年存储涨价）

|                    | 2023   | 2024  | 2025E | 2026E | 批注                                                           |
|--------------------|--------|-------|-------|-------|--------------------------------------------------------------|
| CSP服务器采购情况         |        |       |       |       |                                                              |
| 八大CSP的Capex（亿美金）   | 1,627  | 2,609 | 4,306 | 6,020 | 数据来源为Trendforce，全球八大CSP厂商                                    |
|                    | yoy-3% | 60%   | 65%   | 40%   |                                                              |
| CSP Capex中服务器价值量占比 | 60%    | 60%   | 60%   | 60%   | AI Capex 60%用于服务器等ICT设备采购                                    |
| CSP服务器采购金额（亿美金）    | 976    | 1,565 | 2,584 | 3,612 |                                                              |
| 全球服务器采购            |        |       |       |       |                                                              |
| 全球服务器市场规模（亿美金）     | 1,473  | 2,530 | 4,554 | 5,853 | 数据来源：IDC                                                     |
| CSP服务器采购占全球的比例     | 59%    | 59%   | 59%   | 59%   | Omdia预测，2024年10家大CSP公司将占据全球服务器投资的近60%。此处假设全球服务器市场，八大CSP贡献59% |
| CSP服务器采购金额（亿美金）    | 869    | 1,493 | 2,687 | 3,612 |                                                              |
| 非CSP服务器采购金额        | 604    | 1,037 | 1,867 | 2,241 | 根据Capex计算                                                    |
|                    |        |       |       |       | 假设非CSP的服务器存储采购需要2026年yoy+20%                                 |
| 服务器存储采购情况          |        |       |       |       |                                                              |
| 服务器中存储价值量占比        | 25%    | 26%   | 24%   | 27%   | 此前测算                                                         |
| 服务器存储采购金额（亿美金）     | 389    | 686   | 1,046 | 1,376 |                                                              |
| yoy                |        |       | 53%   | 31%   |                                                              |
| CSP服务器存储采购金额（亿美金）  | 240    | 413   | 607   | 849   |                                                              |
| 非CSP服务器存储采购金额（亿美金） | 149    | 273   | 439   | 527   |                                                              |
| 存储占CSP capex比例     | 15%    | 16%   | 14%   | 14%   |                                                              |
| 服务器存储市场规模（亿美金）     | 362    | 667   | 1,071 | 1,376 | 此前测算                                                         |

图表：服务器LTA的位元分布和增速

|      | 服务器DRAM LTA的位元占比 |       | 2026年同比增速 |
|------|------------------|-------|-----------|
|      | 2025年            | 2026年 |           |
| 微软   | 14%              | 23%   | >100%     |
| 亚马逊  | 21%              | 20%   | 30-35%    |
| 谷歌   | 14%              | 12%   | 20-25%    |
| Meta | 13%              | 11%   | 20-25%    |
| 甲骨文  | 5%               | 7%    | 80-90%    |
| 字节   | 14%              | 12%   | 20-25%    |
| 阿里巴巴 | 9%               | 8%    | 20-25%    |
| 腾讯   | 9%               | 8%    | 25-30%    |
| 百度   | 1%               | 1%    | 5-10%     |





### ■ 2、AI推理驱动存储需求指数级爆发。

- 1) KV Cache多层缓存成为推理系统“标配”，带来存储需求全面爆发。
- 定位分工：HBM 成本高、延迟低，承担热点计算与高频访问；DRAM承接层级缓存与中等频度访问；SSD作为成本/容量折中层，承接冷数据与长周期缓存/索引。
- 工程逻辑：在大体量查询与长上下文背景下，系统优先复用 Prefill 阶段的 KV cache，以降低 Decode 计算与端到端时延。当再次遇到相似问题时，可直接调用已缓存 KV，无需重复计算，整体算力成本更优。
- 随着“缓存保留时长”与“并发度”提升，热数据上收至 HBM、冷数据下沉至 DRAM/SSD 的比重上升，带动DRAM 与 SSD配置同步放大。当前海外大型互联网公司已在基础设施侧普遍采用 HBM+DRAM+SSD的KV Cache多层缓存方案。
- 2) 对话范式升级：从模型自答到思维链展开、与外部工具/Agent 联动，Token消耗量明显提升。
- 范式切换：2024 年以前，主流对话以模型自答为主，外部检索与数据库调用有限；2025 年起，链式推理（CoT）与工具调用/多 Agent 协作渗透率提升，token 用量与外部数据访问显著增加。
- 量纲变化：模型在理解与拆解问题后，还需跨检索/地图/支付/本地生态等多环节交互，产生二次与多次数据读写。单次复杂任务的 token 消耗从千级提升至万级，存在10 倍量级的上行空间。
- 多环节协作引致的中间态与历史态需要更长时间的可追溯与更低成本的快速载入，强化了 DRAM/SSD 对中低温数据的承接作用。
- 3. 媒介升级：从文本到多模态，存储需求进一步提升。
- 过去以文本为主，当前多模态（图、音、视频）快速普及，视频生成/理解成为重点方向。
- 工程结论：多模态（尤其视频）在推理端的时空 token 密度更高，需要更大的活跃窗口与更频繁的分页/换入。由此带来 HBM 的峰值压力与DRAM/SSD 的持续扩容；SSD 在承接冷段缓存、检索索引与长周期知识库方面弹性最强。

图表：存储的分层

| 存储层级         | 在大语言模型（LLM）推理中存储什么？                                                                                        | 在AI视频生成推理中存储什么？                                                                           |
|--------------|------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------|
| HBM(GPU显存)   | 模型权重 + 活跃的KV Cache。这是推理的主战场，所有计算都在此进行。KV Cache用于避免重复计算注意力，是支持流式输出的关键。当KV Cache超过HBM容量时，非活跃部分会被卸载至DRAM或SSD。 | 正在执行计算的模型参数 + 当前帧的中间特征张量（激活值）。例如，生成视频时，当前正在渲染的帧及其相关神经网络层的输出会驻留在HBM中。部分模型参数（如不活跃层）可根据策略卸载。 |
| DRAM(主机内存)   | 非活跃或溢出的KV Cache（如用户会话上下文）、准备被GPU加载的模型分块。作为HBM的溢出池，通过类似LLM或英伟达Dynamo引擎的技术，存放暂时不用但很快可能需要的中间数据，避免重新计算。        | 待处理的视频帧数据。从HBM卸载的部分模型参数或中间特征。当HBM容量不足时一些计算量较小的组件会被换出到此，充当高速缓存。                            |
| SSD(高速本地盘)   | 所有模型权重的本地副本、被换出的KV Cache（当DRAM也不足时）。作为“温存储”，保障模型和部分中间数据能快速加载至DRAM和HBM。也用于存储短期的对话日志和推理结果NVMe-of等高速访问协议。     | 视频素材库、模型检查点（Checkpoint）、近期生成的视频成品。从DRAM进一步溢出的中间数据。充当高速缓存，存放生成过程中所需的热门素材和组件，支持             |
| HDD(硬盘/对象存储) | 模型归档副本、长期日志/审计数据、训练数据集。作为持久化、低成本的“冷存储”或“数据湖”，用于备份和归档，几乎不会参与日常高频推理。通常不存储KV Cache。                           | 海量的原始视频素材、长期归档的视频成品、训练用的数据集。存放访问频率极低但需要长期保留的巨量冷数据。                                        |

- HBM需求继续保持强劲。
- 美光将2025年HBM全球市场规模预期从250亿美元提高至300亿美元以上，并预计2028年HBM总目标市场规模将从2024年的160亿美元增长四倍，到2030年将超1000亿美元。


图表：HBM配置

| 公司     | AI加速卡           | 所用内存    | 内存容量   |
|--------|-----------------|---------|--------|
| 英伟达GPU | Rubin Ultra     | HBM4e   | 1024GB |
|        | Rubin R200      | HBM4    | 288GB  |
|        | GB300           | HBM3e   | 288GB  |
|        | GB200           | HBM3e   | 192GB  |
|        | B300            | HBM3e   | 288GB  |
|        | B200            | HBM3E   | 192GB  |
|        | B100            | HBM3E   | 192GB  |
|        | H200            | HBM3E   | 141GB  |
|        |                 | HBM3E   | 141GB  |
|        | H100            | HBM3    | 80GB   |
|        |                 | HBM3    | 188GB  |
| AMD    | MI300A          | HBM3    | 128GB  |
|        | MI300X          | HBM3    | 192GB  |
|        | MI350           | HBM3e   | 288GB  |
|        | MI355           | HBM3e   | 288GB  |
|        | MI350X          | HBM3e   | 288GB  |
|        | MI355X          | HBM3e   | 288GB  |
|        | MI400           | HBM4    | 432GB  |
|        | MI450           | HBM4    | 432GB  |
| 谷歌     | TPU v5p         | HBM3    | 95GB   |
|        | Trillium        | HBM3/3E | 32GB   |
| Meta   | MTIA 3 (Iris)   | HBM3E   | 216GB  |
| 亚马逊    | Trainium 2      | HBM3E   | 96GB   |
| 微软     | Maia 200        | HBM3    | 64GB   |
|        | Maia 300        | HBM4    | 288GB  |
| OpenAI | Nexus (Titan 1) | HBM3E   | 144GB  |

## 2.3 存储供给：扩产谨慎，增加有限

- 26年DRAM、NAND新增产能有限，新增产能向HBM倾斜，制程升级带来位元数量增长。
- 1) Capex: NAND Capex 23年明显下滑，主要系市场需求低迷+NAND价格持续下滑，24年以来Capex缓慢增长，整体处于相对低位。未来Capex投放重点预计在工艺升级，NAND 将向更高层数、更快速度、AI 优化方向演进，据Trendforce，24-26年3D 2XX L及以上制程产品出货量占比预计由21%提升至65%。DRAM Capex 24年来持续提升，主要系HBM、DDR5等产品率先受益AI拉动、需求好于NAND，同时利润率明显高于NAND，原厂积极投资HBM、DDR5相关产能建设。
- 2) 产能: DRAM 全球产能接近200万片/月，NAND全球产能接近170万片/月，26年底，预计三星、海力士合计增加10万片左右DRAM月产能，优先满足HBM供给，NAND无明显产能增加。
- 3) 产出: 考虑DRAM制程升级（1a到1b，1b到1c）叠加产能增加，Trendforce预计26年位元产出yoy20%，NAND主要是层数升级，trendforce预计位元产出+21%

图表：DRAM、NAND资本开支（百万美金）



图表：DRAM、NAND产能

|              | 2022 | 2023 | 2024 | 2025E | 2026E |
|--------------|------|------|------|-------|-------|
| DRAM         |      |      |      |       |       |
| Q4末产出 (千片/月) | 1591 | 1351 | 1803 | 1965  | 2117  |
| 三星           | 670  | 455  | 670  | 650   | 700   |
| 海力士          | 410  | 358  | 480  | 545   | 605   |
| 美光           | 333  | 300  | 315  | 340   | 355   |
| 南亚科          | 60   | 52   | 54   | 62    | 65    |
| PSMC         | 34   | 30   | 40   | 45    | 45    |
| 华邦           | 17   | 24   | 24   | 23    | 22    |
| 晋华           | 10   | 10   | 10   | 20    | 25    |
| 长鑫           | 57   | 122  | 210  | 280   | 300   |
| NAND         |      |      |      |       |       |
| Q4末产出 (千片/月) | 1699 | 1157 | 1570 | 1365  | 1344  |
| 三星           | 655  | 330  | 560  | 400   | 325   |
| 铠侠/闪迪        | 460  | 350  | 460  | 400   | 410   |
| 海力士          | 200  | 135  | 150  | 145   | 140   |
| Solidigm     | 93   | 65   | 85   | 95    | 95    |
| 美光           | 155  | 130  | 155  | 130   | 135   |
| 长江存储         | 105  | 120  | 130  | 160   | 200   |
| PSMC         | 5    | 4    | 4    | 6     | 8     |
| 华邦           | 7    | 8    | 15   | 15    | 15    |
| 旺宏           | 15   | 12   | 8    | 9     | 11    |
| 中芯国际         | 4    | 3    | 3    | 5     | 5     |

图表：DRAM、NAND位元产出


|           | 2022 | 2023 | 2024 | 2025E | 2026E |
|-----------|------|------|------|-------|-------|
| 位元产出 (EB) |      |      |      |       |       |
| DRAM      | 26   | 28   | 29   | 36    | 43    |
| NAND      | 742  | 721  | 822  | 931   | 1,122 |
| DRAM-yoy  | 19%  | 6%   | 6%   | 24%   | 20%   |
| NAND-yoy  | 30%  | -3%  | 14%  | 13%   | 21%   |



## 2.3 存储供给：扩产谨慎，增加有限

- DRAM工艺节点正从1a系列加速向1b、1c迭代，预计26年1b节点仍是主力,1c节点率先用于高端产品。
- 1) 三星：三星确认2026年将使用1bDRAM向英伟达供应超过50%的第二代SOCAMM模块，并考虑削减30%-40%1a DRAM产能转向1bDRAM,同时率先使用1cDRAM制造HBM4，与英伟达敲定供货协议，计划通过扩建P4+转换旧制程提升1c产能，26年1c产能有望达到20万片/月。
- 2) 海力士：海力士采用1bDRAM制程生产HBM4，M15X工厂已启动1bDRAM试产线，初始月产量目标为1万片，后续将逐步提升至6万片，同时计划将利川园区的1cDRAM产能扩大至当前的8倍，以满足英伟达、AMD及大型云服务厂商的订单需求。
- 3) 美光：美光采用1β/1bDRAM制程生产HBM4，已向多家客户送样，预计2026年量产，1γ/1cDRAM 制程已用于DDR5、LPDDR5X，并计划逐步拓展至包括GDDR7与数据中心产品在内的整个DRAM产品线。

图表：DRAM节点演进



图表：原厂DRAM节点路线图

| Density | Nodes (nm)  | Company  | 1Q25                | 2Q25 | 3Q25 | 4Q25 | 1Q26           | 2Q26 | 3Q26 | 4Q26 |
|---------|-------------|----------|---------------------|------|------|------|----------------|------|------|------|
| 16Gb    | 1Y          | SAMSUNG  | 4800-5600 MT/s EOL  |      |      |      |                |      |      |      |
|         |             | SK hynix | 4800 MT/s EOL       |      |      |      |                |      |      |      |
|         | G4          | cxmt     |                     |      |      |      | 4800-6400 MT/s |      |      |      |
|         | 1Z          | micron   | 4800-5600 MT/s EOL  |      |      |      |                |      |      |      |
|         | 1a/1α/alpha | SAMSUNG  |                     |      |      |      | 5600-6400 MT/s |      |      |      |
|         |             | SK hynix |                     |      |      |      | 4800-6400 MT/s |      |      |      |
|         | 1b/1beta    | SAMSUNG  | C/S: 5600-8000 MT/s |      |      |      | 5600-6400 MT/s |      |      |      |
|         |             | SK hynix |                     |      |      |      | 7200 MT/s      |      |      |      |
|         | 1c/1gamma   | micron   | C/S: 7200 MT/s      |      |      |      | 5600-6400 MT/s |      |      |      |
|         |             | SK hynix | C/S: 7200 MT/s      |      |      |      | C/S: 8000 MT/s |      |      |      |
|         |             | micron   | C/S: 8000 MT/s      |      |      |      | 5600-7200 MT/s |      |      |      |

Note: C/S=Customer Sample


★ means applying EUV technology

## 2.3 存储供给：扩产谨慎，增加有限


- **3D NAND 技术通过垂直堆叠更多层数打破了平面存储的限制，显著提升存储密度和容量。**1) 密度提升：从 32 层发展至 128 层期间，单位面积的存储密度 (GB/mm<sup>2</sup>) 增长超过 3 倍。2) 单片容量提升：虽然 3D NAND 层数堆叠使同一片晶圆切出 Die 数量减少约 10%，但单片容量可提升 50%-60%，在从 128 层向 296 层演进的过程中，单片容量从 512GB 提高至 800GB 左右。
- **头部厂商正加速迈入 300+ 层时代。**三星 286L、铠侠 286L、美光 276L、SK 海力士 321L、长存 267L 在 25 年纷纷进入量产，海力士是首个突破 300L 的厂商，其推出的 321 层 QLC NAND 单 Die 容量密度提升 100%，达到 2Tb，单片晶圆可切割的有效容量产出提升约 59%，未来头部厂商将加速 NAND 向 300L 以上升级。

图表：3D NAND 层数演进

### NAND Tech. and Roadmap




图表：原厂 NAND 路线图




### ■ 三大原厂服务器收入占比持续提升。

- 1) 海力士：营收持续向DRAM集中，2025年前三季度DRAM营收占比已接近80%。DRAM内部结构由通用产品转向AI驱动的高价值组合，Server与Graphics占比快速提升，显著受AI服务器与GPU需求拉动。
- 2) 三星：存储及半导体（DS）业务营收占比自2023年24%增长到2025年前三季度的32%，消费电子与通讯网络（DX）业务营收占比逐步下滑。
- 3) 美光：2025年对业务部门进行重新划分，设立专为OEM数据中心客户提供存储解决方案的数据中心业务部门（CDBU），25Q1-Q3，营收占比达19%，计算和联网业务、移动业务、汽车业务分别占比36%、32%、13%。


图表：海力士DRAM收入结构



图表：三星各业务营收占比



图表：美光各业务营收占比





## 2.3 存储供需：供给向服务器倾斜，26年供需持续紧张

- 原厂产能倾斜于高景气度的AI数据中心业务，重点投资生产面向AI服务器的HBM和大容量DRAM芯片，以满足AI数据中心对高速、大容量存储的需求，NAND方面也加速向适配数据中心的高密度、大容量产品方向转型。
- 1) 三星：DRAM方面，三星与英伟达签订 HBM4 供应协议，并通过 P4 建设与 P5 重启扩大 HBM 和 1c DRAM 产能，并通过升级产线+改造 NAND 产线转产 DRAM；NAND 方面，重启 Z-NAND 研发，性能目标达到传统 NAND 闪存的 15 倍，同时将功耗降低多达 80%，适配 AI 工作负载需求。
- 2) 海力士：HBM4 已通过英伟达验证，M15X、龙仁园区及印第安纳封装厂三线并进扩产，同时发布面向 AI 负载的 AI-NAND 家族，并定于 2026 年 4 月停产 DDR4，将空出产能转进 HBM 与 DDR5。
- 3) 美光：25 年 8 月宣布停止移动 NAND，包括 UFS 5 的开发，2025 年 12 月宣布退出英睿达消费级业务；美光新厂台湾 A5 厂 & 日本广岛厂预计聚焦 HBM 生产，NAND 方面也推出基于 G9-NAND 的三款数据中心 SSD。

| 公司  | 产能向AI数据中心倾斜                                                                                                                                                                                                                                                                                 |
|-----|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 三星  | 1) 三星已与英伟达敲定HBM4 供应协议，预计2026年量产。2) 三星针对AI低延迟需求重新启动Z-NAND 研发。3) 产能：P4厂聚焦HBM4并兼具部分NAND产线，预计26年投产；P5 工厂则在2025年重启建设，预计2028年量产，主要面向 1c DRAM + HBM4。                                                                                                                                              |
| 海力士 | 1) 海力士HBM4已通过英伟达验证，预计25Q4开始供货 。2) 海力士推出AI-NAND Family 产品组合，其中 AIN-P 面向大规模推理场景，AIN-D 将容量提升至 PB 级，兼具 SSD 性能+ HDD 经济性，而 AIN-B 则采用 HBF 技术通过堆叠 NAND 获取更高带宽。3) 产能：M15X厂聚焦下一代DRAM+HBM，预计25年投产；龙仁园区预计将在 2027年底开始贡献部分产能，聚焦 HBM；美国印第安纳州计划建设先进封装工厂，预计于 2028 年完工，专注HBM。                                 |
| 美光  | 1) 美光宣布停止英睿达（Crucial）品牌的消费级业务。2) 美光宣布全球范围停止移动 NAND 开发，包括终止 UFS 5 的研发。3) 美光推出三款基于 G9 NAND 打造的数据中心SSD。其中9650 SSD 是全球首款 PCIe 6.0 SSD；6600 ION SSD 面向 AI 数据湖，提供超高密度与空间效率；7600 SSD 则覆盖 AI 推理与混合工作负载，为企业级应用提供领先性能。4) 产能：台湾 A5 厂将在 2025 年启动建设、重点聚焦 HBM（投产时间未公布），日本广岛的新厂则计划在 2026 年启用，用于未来 HBM 的量产。 |



## 2.3 存储供需：供给向服务器倾斜，26年供需持续紧张

■ AI驱动，三星、海力士和美光三大原厂展望服务器需求旺盛，消费电子需求稳定，DRAM新增产能有限，NAND扩产保守、主要通过制程升级增加供给，预计至2026年DRAM、NAND供给会持续紧缺，同时客户开始谈26、27年的供应。

图表：三大原厂供需展望


|     | 手机                                                                                            | PC                                             | 服务器                                                                                 | 存储供需关系                                                       |
|-----|-----------------------------------------------------------------------------------------------|------------------------------------------------|-------------------------------------------------------------------------------------|--------------------------------------------------------------|
| 三星  | -                                                                                             | -                                              | 预计HBM3E、高密度eSSD在AI和传统服务器领域需求依旧强劲，高附加值服务器存储产品销量将继续上升；2026年将扩大HBM产品销量，并用HBM4产品响应AI需求  | 由于产业优先满足AI服务器需求，存储市场将出现供应紧张，包括手机、PC领域                        |
| 海力士 | 受宏观经济不确定性，智能手机出货量将温和增长，随着AI在终端设备普及，单机搭载内存容量将持续上升                                              | 受宏观经济不确定性，PC出货量将温和增长，随着AI在终端设备普及，单机搭载内存容量持续上升  | AI推理快速扩展导致并行用户数与计算量急剧增加，整体内存使用量呈指数级增长，AI服务器对高带宽HBM与高密度DRAM、eSSD需求增长，并扩展至通用服务器与边缘设备  | AI驱动存储需求远超预期，公司已经锁定2026年客户需求与订单                              |
| 美光  | 2025年预计智能手机出货量维持低个位数增长，AI手机占比提升将推动移动设备DRAM容量增长，25Q2出货的旗舰机型已有三分之一配备12GB或更高容量内存，预计未来这一比例会进一步上升。 | AI在PC端的广泛应用带动PC需求增长，2025年预计PC出货量中个位数增长，超过公司预期。 | 预计2025年服务器出货量上升10%，超过公司此前中个位数增长的预期，其中传统服务器增长前景从持平上升至中个位数增长，AI服务器增长非常强劲，驱动DRAM产品需求增长 | 强劲的数据中心需求导致DRAM市场供应紧张，预计由于供应商库存偏低，制程迁移受限，预计2026年DRAM供给将进一步紧张 |

## 2.3 存储供需：供给向服务器倾斜，26年供需持续紧张


### ■ 25Q2本轮周期开始，25Q4涨价幅度超预期。

- 1) 21Q4-23Q2下行周期合约价格：DRAM、NAND价格自20Q4、21Q4开始下降，价格下降6个季度，价格下降到23Q2，价格跌幅约80%。
- 2) 23Q3-24Q3上行周期合约价格：DRAM、NAND价格自23Q3开始全面上涨，价格上涨4—5个季度，到24Q3，DRAM、NAND价格自低点平均涨幅50-60%。此次是大容量NAND、DRAM(DDR5 LPDDR5)领涨。
- 3) 24Q3-25Q1下行周期合约价格：24Q3手机存储价格率先承压，24Q4 PC存储价格开始下降，25Q1 企业级存储价格开始下降，消费类价格跌幅30-40%左右，企业级存储价格相对坚挺。
- 4) 25Q2-至今新的上涨周期：DDR4、LPDDR4原厂减产，25Q2率先开启涨价，涨价幅度远超DDR5、LPDDR5和NAND，NAND中主要是MLC、SLC NAND涨价；25Q3开始存储全线涨价且涨幅扩大，除主流DRAM、NAND价格上涨外，利基DRAM、2D NAND、NOR Flash全面涨价。25Q4涨价幅度超预期。

图表：DRAM合约价变化



图表：NAND合约价变化



## 2.3 存储供需：供给向服务器倾斜，26年供需持续紧张

■ 预计26年供需紧张，价格继续上涨。

➤ 据Trendforce，预计：1) 26年NAND、DRAM全年涨幅预计在50%+、40%+；2) 预计26年NAND、DRAM涨价幅度逐季回落，节奏为Q1强劲、Q2回落、Q3个位数增长、Q4略小幅增长。


|                | 25Q1     | 25Q2     | 25Q3E   | 25Q4E    | 26Q1F    | 26Q2F    | 26Q3F   | 26Q4F  |
|----------------|----------|----------|---------|----------|----------|----------|---------|--------|
| eMMC/UFS       | -15%~20% | +5%~10%  | +0%~5%  | +20%~25% | +20%~25% | +15%~20% | +5%~10% | +0%~5% |
| Enterprise SSD | -18%~23% | 持平       | +5%~10% | +25%~30% | +20%~25% | +13%~18% | +5%~10% | +3%~8% |
| Client SSD     | -18%~23% | +5%~10%  | +3%~8%  | +20%~25% | +20%~25% | +15%~20% | +5%~10% | +0%~5% |
| 3D NAND wafer  | -8%~13%  | +15%~20% | +8%~13% | +65%~70% | +15%~20% | +10%~15% | +3%~8%  | +0%~5% |
| Total NAND     | -15%~20% | +3%~8%   | +5%~10% | +25%~30% | +20%~25% | +13%~18% | +5%~10% | +0%~5% |

|               | 25Q1                                                       | 25Q2                                                  | 25Q3E                                                         | 25Q4E                                                         | 26Q1F                                          | 26Q2F                                      | 26Q3F                                     | 26Q4F                             |
|---------------|------------------------------------------------------------|-------------------------------------------------------|---------------------------------------------------------------|---------------------------------------------------------------|------------------------------------------------|--------------------------------------------|-------------------------------------------|-----------------------------------|
| PC DRAM       | DDR4: -13%~18%,<br>DDR5: -10%~15%                          | DDR4:+13%~18%;<br>DDR5:+3%~8%;                        | DDR4:+38%~43%;<br>DDR5:+3%~8%;                                | DDR4:+25%~30%;<br>DDR5:+25%~30%;                              | DDR4:+18%~23%;<br>DDR5:+18%~23%;               | DDR4:+5%~10%;<br>DDR5:+5%~10%;             | +3~8%                                     | +0~5%                             |
| Server DRAM   | DDR4: -10%~15%,<br>DDR5: -3%~8%                            | DDR4:+18%~23%;<br>DDR5:+3%~8%;                        | DDR4:+28%~33%;<br>DDR5:+3%~8%;                                | DDR4:+30%~35%;<br>DDR5:+28%~33%;                              | DDR4:+25%~30%;<br>DDR5:+23%~28%;               | DDR4:+5%~10%;<br>DDR5:+5%~10%;             | +3~8%                                     | +0~5%                             |
| Mobile DRAM   | LPDDR4X -8%~13%;<br>LPDDR5X -3%~8%                         | LPDDR4X +0%~5%;<br>LPDDR5X +3%~8%                     | LPDDR4X +38%~43%;<br>LPDDR5X +10%~15%                         | LPDDR4X +38%~43%;<br>LPDDR5X +38%~43%                         | LPDDR4X<br>+15%~20%;<br>LPDDR5X<br>+15%~20%    | LPDDR4X<br>+5%~10%;<br>LPDDR5X<br>+8%~13%  | LPDDR4X 持平;<br>LPDDR5X +5%~10%            | LPDDR4X 持平;<br>LPDDR5X +3%~8%     |
| Graphics DRAM | GDDR6: -8%~13%,<br>GDDR7: -0%~5%                           | GDDR6:持平<br>GDDR7: -0%~5%                             | GDDR6:+28%~33%<br>GDDR7: +5%~10%                              | GDDR6:+28%~33%;<br>GDDR7: +28%~33%                            | GDDR6:+20%~25%;<br>GDDR7: +20%~25%             | GDDR6:+0%~5%;<br>GDDR7: +8%~13%            | GDDR6:+0%~5%;<br>GDDR7: +3%~8%            | GDDR6:持平;<br>GDDR7: +0%~5%        |
| Consumer DRAM | DDR3 -3%~8%;<br>DDR4 -10%~15%<br>常规 -8%~13%;<br>HBM -0%~5% | DDR3 持平;<br>DDR4 +18%~23%<br>常规 +3%~8%;<br>HBM +3%~8% | DDR3+0%~5%;<br>DDR4 +85%~90%<br>常规 +10%~15%;<br>HBM +15%~20%; | DDR3 +20%~25%;<br>DDR4 +25%~30%<br>常规 +30~35%;<br>HBM +35~40% | DDR3 +15%~20%;<br>DDR4 +15%~20%<br>常规 +20~25%; | DDR3 +3%~8%;<br>DDR4 +3%~8%<br>常规型+5%~10%; | DDR3 +0%~5%;<br>DDR4 +0%~5%<br>常规型+3%~8%; | DDR3 持平;<br>DDR4 持平<br>常规型+0%~5%; |
| Total DRAM    | (HBM渗透率: 8%)                                               | (HBM渗透率: 9%)                                          | (HBM渗透率: 10%)                                                 | (HBM渗透率: 11%)                                                 | 常规 +20~25%;                                    | 常规型+5%~10%;                                | 常规型+3%~8%;                                | 常规型+0%~5%;                        |

## 2.3长鑫：发布国产DDR5，追赶国际厂商进度

- **合肥长鑫打破海外垄断，引领大陆 DRAM 发展。**合肥长鑫是大陆首家 DRAM IDM 厂商，2016 年在合肥成立，2019 年长鑫 19nm 8Gb DDR4 投产，2025 年 11 月，在 IC China 2025 展会上，长鑫存储正式发布了速率高达 8000Mbps、单颗容量 24Gb 的 DDR5 标准内存新品及覆盖全场景的七大模组产品，并同步展示了近期发布的 10667Mbps 高速率 LPDDR5X 移动端内存。标志我国在内存芯片领域实现量产技术突破。后续长鑫持续扩产，持续引领中国大陆 DRAM 产业的发展。
- **与海外差距逐步缩小。**三星、海力士、美光等在 2011-2014 年间已完成 DDR4 的发布与量产，并于 2020 年前后转向 DDR5，部分厂商同步布局 GDDR6 等高带宽产品。相比之下，长鑫存储于 2019 年量产 DDR4，并在 2025 年进入 DDR5 阶段，较海外龙头仍有差距。但随着产线扩建与工艺提升，长鑫正加速缩小差距，未来在 DDR5 及后续产品上具备进一步追赶的空间。

图表：长鑫存储发展历程




图表：主要厂商 DRAM 技术发展情况

| 厂商  | DDR4                    | DDR5                            | GDDR6        |
|-----|-------------------------|---------------------------------|--------------|
| 三星  | 2011年发布，2014年进入量产       | 2021年宣布量产最先进的14nm EUV DDR5 DRAM | 2017年底宣布准备量产 |
| 海力士 | 2011年首发DDR4样品，2014年进入量产 | 2020年全球首家宣布 DDR5 DRAM 量产        | 2018年宣布量产    |
| 美光  | 2012年发布公告，2014年进入量产     | 2020年宣布DDR5已准备量产并出货给数据中心与PC客户   | 2018年宣布量产    |
| 长鑫  | 2019年宣布DDR4量产           | 2025年首次全面展示DDR5                 | 未宣布          |



■ 长江存储是一家集芯片设计、生产制造、封装测试及系统解决方案产品于一体的存储器IDM企业。公司自成立以来持续加码 NAND 技术研发，打造自主创新的 Xtacking 架构体系，有效提升 NAND 的性能、能效与扩展性，据TechInsights，长江存储在2022年突破232层，进入2XX世代。与此同时，三星、海力士、美光等厂商已陆续准备突破3xx层及以上产品，长江存储在3XXL 节点上仍存在技术差距，但随着架构迭代与产线扩张推进，未来在先进 NAND 领域具备持续追赶空间。

图表：长江存储发展历程



图表：主要厂商NAND技术发展时间节点情况

| 厂商  | 32L/36L | 64L/72L    | 128L  | 176L/192L | 2XXL  | 3XXL及以上 |
|-----|---------|------------|-------|-----------|-------|---------|
| 三星  | 2015年   | 2017年      | 2020年 | 2022年     | 2023年 | 2025年   |
| 海力士 | 2015年   | 2017年      | 2020年 | 2020年     | 2023年 | 2024年底  |
| 美光  | 2016年   | 2017年      | 2020年 | 2020年     | 2022年 | 2025年   |
| 长存  | 2018年   | 2019/2020年 | 2021年 | 2022年     | 2022年 | 暂无      |

## 2.3 存储国产化率仍低，本土厂商扩产趋势持续

■ 当前DRAM、NAND国产化率仍然低，产能供不应求，本土存储厂商扩产信号强烈。我们根据公开资料梳理，合肥长鑫2024年DRAM月产能约为20万片，技术节点达到17nm，预计2025年底月产能30万片，公司于2025年7月启动上市辅导，有望带动产能进一步扩充。长江存储NAND产能预计2025年底可达到15万片，同时长江存储也在研发布局新型3D堆叠DRAM。福建晋华一期规划产能6万片，总产能规划为24万片，目前已与美光达成和解，预计将持续稳步投产以达到预期产能。本土存储厂商积极扩产，规模庞大且对国产设备验证、导入均较为积极，有望在未来数年奠定国产设备厂商订单增长的坚实基础。


图表：本土主要存储厂商扩产规划

| 客户   | 规划产能                                                         | 建设进度与动态                                       |
|------|--------------------------------------------------------------|-----------------------------------------------|
| 合肥长鑫 | DRAM产能2024年底约为20万片/月，预计2025年底可达到30万片/月                       | 公司尚有DRAM产线在建，DRAM产能持续扩张，2025年7月启动上市辅导         |
| 福建晋华 | 一期规划产能6万片/月，二、三期投产后产能24万片/月                                  | 2017年因与美光的诉讼事件生产线陷入停滞，目前公司已与美光达成和解，预计重启DRAM项目 |
| 长江存储 | NAND产能目前约为2025年底约为15万片/月，预计2028年底可达到30万片/月，目标占全球15%的NAND市场份额 | 长江存储（YMTC）也在研发新型3D堆叠DRAM，提升内存性能的同时，减少了传统电容的限制 |


## 2.3 国产存储厂商扩产拉动本土设备需求

- 下游扩产将直接拉动相关设备需求。从单位产能来看，先进 DRAM 扩产每新增 1 万片/月对应 CAPEX 水平约11亿美元，NAND则约7亿美元，后续随着制程/结构升级，CAPEX有望继续向上，意味着每项新建或扩建项目均将带动大量设备采购。随着国内长鑫、长存等厂商陆续启动新一代产线规划，未来存储行业的扩产节奏有望继续带来大量的设备订单。

图表：每万片产能CAPEX（单位：亿美元）



图表：各环节半导体设备份额占比



## 2.4 PCB：产品结构持续升级，有效产能不足仍是主旋律

- 数通产品持续升级，对PCB厂商要求不断提升：从产品结构上来看，由于服务器、交换机等数通类产品对传递速率、损耗等要求逐代提升，PCB作为传递数据的核心部件，整体规格提升趋势明显。
- 服务器：通用服务器整体层数通常在14-18层，但是升级到AI服务器，前一代H100 UBB主板层数超20层以上，升级至机柜形态的GB200/300，由于线路更复杂，其compute tray规格为5阶HDI，switch tray规格为22层高多层，整体生产难度进一步提升。
- 交换机：由于传递速率持续提升，PCB规格也持续提升，1) 400G交换机24层以上设计，M7材料；2) 800G交换机是38层以上设计，M8等级材料，交换机升级对PCB价值量提升显著。
- 规格提升致使有效产能不足：此前PCB虽然产能充沛，但是大多集中在以消费电子等为要配套的低端产能，以低层数、低阶数产能为主，真正能供给AI产能高端产能极为有限，且AI高壁垒且产能难度骤增使得新PCB厂商认证难度加大，进一步让有效产能受限，有效产能不足仍是未来PCB主旋律。

图表：英伟达主要产品规格情况

| 英伟达          | 数量 | 层数     | 工艺    |
|--------------|----|--------|-------|
| GB200/300    |    |        |       |
| compute tray |    | 18 22L | 5阶HDI |
| switch tray  |    | 9 24L  | 高多层   |
| Rubin        |    |        |       |
| compute tray |    | 18 22L | 6阶HDI |
| switch tray  |    | 9 32L  | 高多层   |
| CPX背板        |    | 18 44L | 高多层   |
| CPX板卡        |    | 36 22L | 5阶HDI |



## 2.4 PCB未来新增量：正交背板

### ■ 未来新增量：正交背板及CoWoP技术

■ 除PCB升级外，PCB在服务器中预计也会进一步替代其他部分价值量，预计后续PCB以正交背板的形式替代机柜铜缆，后续可能通过CoWoP技术替代载板，PCB价值量进一步提升！

### ■ 正交背板：


应用代际：大概率在27年rubin ultra上应用，小概率26年在rubin上应用，主要由于当前无论是M9材料（阻抗高）还是PTFE（加工难度大）均有缺陷，各厂商还在积极送样解决相关问题；但是rubin ultra由于GPU更多，若应用铜缆将超过3w根，连接密度和装配难度极大，空间有限的情况下几乎不可能采用铜缆方案，因此rubin ultra用正交背板概率极高，rubin则需要看PCB厂商送样进展。

当前主要方案：材料目前M9和PTFE方案并行测试，M9整体加工性更好，但是阻抗高，PTFE阻抗更好，但是材料较软，PCB加工端良率较低；预计相关产品层数、规格、价值量均极高。

## 2.4 PCB未来新增量：CoWoP

- 新技术方向：cowop: cowop技术通过将芯片直接封装在PCB上，省去传统封装基板，实现“芯片-硅中介层-PCB”一体化设计，完成封装层级重构。同时充分利用大尺寸PCB产线的高产能与成熟工艺。预计NV将在rubin ultra上考虑新方案，使用cowop工艺。

图表：CoWoP工艺示意图



## 2.4 关注覆铜板及IC载板涨价机会

- 关注其他涨价环节：覆铜板和IC载板
- 覆铜板环节：今年以来受益于AI需求火爆，消费等需求回暖，且厂商不断将低端产能切换至高端AI产能，整体CCL结构有所缺货，叠加以铜为代表的原材料成本上涨，CCL涨价趋势明确，四季度主要覆铜板厂商均已涨价，后续随着原材料成本进一步上升及AI需求持续挤占其他产能，后续CCL有望持续涨价。
- IC载板：受益于存储需求旺盛，BT载板出现缺货，叠加金等原材料价格上涨，BT载板也迎来缺货涨价，后续随着存储持续高景气，IC载板价格有望持续上涨。

**KB** 广东建滔积层板销售有限公司  
GUANGDONG KINGBOARD LAMINATES TRADING CO., LTD  
建滔集团成员  
地址：广东省佛山市石角镇建滔工业园 TEL: (0755)29839514 FAX: (0755) 29839790

### 涨价通知

编号：20251201

各尊敬的客户：

衷心感谢各客户长期以来对建滔的支持！

由于目前铜价高企，原铜难求，玻璃布供应亦十分紧张，迫于成本压力，故将从即日起接单起，对所有材料价格调整如下：

| 产品（所有厚度）        | 加价幅度（RMB） |
|-----------------|-----------|
| CEM-1/22F/V0/HB | +5%       |
| FR-4            | +10%      |
| PP              | +10%      |

请各位尊敬的客户知悉并理解，谢谢！

建滔积层板（澳门）有限公司  
广东建滔积层板销售有限公司  
2025年12月1日 业务专用章

### 2025年11月铜箔基板（CCL）反映成本通知

尊敬的客户您好：

一、承蒙 贵公司长期对本公司之支持与惠顾，谨此致上十二万分谢意。

二、由于上游原物料（国际LME铜价、铜箔加工费、电子级玻纤布）均上涨，考量长期的稳定供应，本公司将反映成本：

拟全系列CCL产品调涨8%、PP调涨8%，于11/20起交运日生效。

敬请予以惠顾与指教。


谨此奉达 並祝 商祺

南亚塑胶工业股份有限公司  
电子材料事业部 营业一处

## 2.5 服务器液冷：全液冷趋势明确，看好增量环节

- **全液冷趋势明确，市场规模有望持续向上：**英伟达B200/B300GPU单片功率已超过风冷方案极限，GB200/300计算托盘全面使用液冷方案，根据Semi analysis估算，GB200/GB300机柜功率约140/180kW，下一代VR NVL144 CPX机柜预计功率将增加至370kW，机柜全液冷趋势明确，功率提升有望带动液冷系统市场规模提升。根据IDC数据，2024年中国服务器液冷市场规模23.7亿美元，预计2029年增长至162亿美元。
- **液冷系统分为一次侧和二次侧：**一个机柜集群的液冷系统分为两个独立的液体通路，二次侧负责将服务器内芯片产生的热量输送至冷量分配单元CDU内；一次侧负责将服务器产生的热量输送到室外；一次和二次侧通过CDU内的热交换单元交换热量（液体不直接连通），最终实现服务器机柜内热量向室外的传输。常规数据中心的关键液冷部件包括CDU、Manifold（分水歧管）、UQD（快接头）、液冷板、液冷管路等。

图表：机柜集群液冷系统







## 2.5 规格升级带动价值量向上

- 液冷规格升级有望液冷部件价值量持续提升。
  - **GB200:** 1) 液冷板: 采用大面积液冷板, 每个冷板覆盖两个B200 GPU和一个CPU, 单计算托盘两块液冷板; 2) 快接头: 全机柜约108对快接头。
  - **GB300:** 1) 液冷板: 升级为分体式方案, 四个B300 GPU与2个CPU均分别配备一块液冷板, 单计算托盘液冷板数量提升至6片, 有望带来价值量提升; 2) 快接头: 由于液冷板数增加, 单机柜快接头数量预计增加至252对, 单价或有所降低但价值量预计有增长; 3) 液冷管: 由于散热需求进一步提升, 液冷管由GB200的EPDM升级为不锈钢波纹管。
  - **VR NVL144 CPX:** 1) 液冷板: 在GB300基础上, Rubin CPX GPU预计增加两层堆叠PCB之间的液冷板用于散热, 带来液冷板纯增量; 2) 分水器&液冷管: 由于VR NVL144 CPX机架内空间紧凑, 托盘进/出水管位置从托盘中部移动至托盘两侧, 液冷管使用总长度有望增加; 同时由于液冷板数量增加, 机架内分水器结构或更加复杂, 分水器&液冷管价值量有望提升。
- **未来浸没/相变液冷有望进一步提升价值量:** 未来随着服务器功率进一步提升, 散热效果更佳的相变液冷/浸没液冷有望实现渗透率提升, 更复杂的液冷系统有望推动行业规模进一步向上。

图表: GB300计算托盘液冷



图表: VR NVL144 CPX计算托盘液冷



## 2.5 服务器液冷市场空间测算

■ 我们测算2025/26年Nvidia GB200/300 服务器机柜液冷市场空间将达到42.7/57.2亿美元，下一代Rubin CPX机柜内芯片密度大幅提升，液冷系统及液冷板设计复杂度有望提升，短期高确定性增长。液冷系统后续亦有望向相变/浸没式液冷过渡，支撑长期增量。

图表：Nvidia GB200/300 液冷市场空间测算

| GB200液冷价值量拆分    |              |        |     |        | GB300液冷价值量拆分  |              |        |     |        |
|-----------------|--------------|--------|-----|--------|---------------|--------------|--------|-----|--------|
| 部件              |              | 单价（美元） | 数量  | 总价（美元） | 部件            |              | 单价（美元） | 数量  | 总价（美元） |
| 冷板              | Compute Tray | 650    | 36  | 23400  | 冷板            | Compute Tray | 240    | 108 | 25920  |
|                 | Switch Tray  | 700    | 9   | 6300   |               | Switch Tray  | 770    | 9   | 6930   |
| CDU             |              | 30000  | 1   | 30000  | CDU           |              | 34500  | 1   | 34500  |
| Manifold        |              | 12000  | 1   | 12000  | Manifold      |              | 13200  | 1   | 13200  |
| UQD             |              | 80     | 150 | 12000  | UQD           |              | 85     | 270 | 22950  |
| 合计（美元）          |              |        |     | 83700  | 合计（美元）        |              |        |     | 103500 |
| 预测2025出货量（万台）   |              |        |     | 3.3    | 预测2025出货量（万台） |              |        |     | 1.5    |
| 预测2026出货量（万台）   |              |        |     | 2.5    | 预测2026出货量（万台） |              |        |     | 3.5    |
| 2025合计市场规模（亿美元） |              |        |     |        |               |              |        |     | 42.7   |
| 2026合计市场规模（亿美元） |              |        |     |        |               |              |        |     | 57.2   |

## 2.5 被动元件：AI带来新增量

- 由于AI服务器功耗提升显著，预计对多种被动元件均提出更高要求，其用量及价值量将显著提升
- 1) 铝电解电容：随着AI服务器功率提升，铝电解电容用量将同步得到提升，另外后续电容可能会承担部分调频功能，用量进一步提升；
- 2) 超级电容：超级电容作为可以瞬间释放大功率的元器件，可以起到功率补偿/调频作用，有效减轻GPU动态负载对交流电网的影响。目前超容方案集中在EDLC和LIC两种，预计两者均会应用在AI服务器领域。
- 3) 芯片电感：由于AI服务器中功率极高，对供电系统的稳定性和效率要求极为严格。芯片电感通过高效滤波和扼流，能有效平滑电流波动，稳定输出电压，从而保障高算力设备的可靠运行，预计后续在GPU、ASIC芯片中将成为主流配置且后续会随着芯片功耗提升而进一步提升。
- 4) 钽电容：此前钽电容多用于军工、高端消费电子等领域，我们看到后续随着AI服务器对电容产品要求进一步提升，预计后续有望在CPU、GPU、企业级存储等领域成为标配产品。

# 目 录

一、AI仍是所有主线

---

二、AI基建缺口扩大

---

三、端侧AI奇点已近

---

四、投资建议及风险提示

---



## 3.1 端侧AI奇点已近，AI手机+AI眼镜双线并行


- 现阶段端侧AI还未出现真正爆款产品，但国内外大厂加速探索从云到端侧布局的趋势已然明晰，端侧AI蓄势待发。从落地硬件来看，AI手机和AI眼镜或为中短期主线，长期看好机器人等应用场景。
- AI手机：
  - 手机是端侧AI落地最顺畅的场景。1) 硬件：手机硬件技术成熟，且存力算力升级配合能够充分满足端侧AI运行的性能和功耗要求；2) 软件：手机软件应用覆盖面足够广且成熟，端侧AI应用更易融合落地；3) 用户&品牌：手机普及率高、用户黏性强，厂商推出的AI手机功能更易被感知，用户学习成本低。
  - AI手机逐步从应用级AI助手向系统级AI Agent演变。2024年1月三星发布实时翻译、写作助手、即圈即搜、相片助手、AI相机等多项Galaxy AI功能，打响AI手机第一枪，国内安卓品牌亦陆续推出类似AI功能，苹果则于2024年6月发布Apple Intelligence，系统级AI Agent蓝图初显。2025.12.1日豆包手机助手技术预览版正式发布，通过操作系统层级的AI Agent打通APP，实现跨APP操作，如跨平台比价下单、预订餐厅/高铁、请假/差旅报备等，此外Pro模式还将引入工具链和记忆数据，执行效率更高，可实现一句话完成多项执行任务，搭载该功能的努比亚M153工程样机售价3499元。
  - 系统级AI Agent技术路径：屏幕识别落地难度较低，API调用效率&权限跟高。
    - 1) 屏幕识别：通过识别到的屏幕内容交由大模型推理，再由AI模拟人手操作，短期内该技术为主流路径，商业推进和技术难度不高，缺点在于推理时间长、可能被APP禁用（例如微信、阿里系APP禁止豆包手机登录）等；
    - 2) API调用：通过直接调用APP的API接口实现跨APP操作的效率和权限都更高，大模型厂商如字节、阿里、腾讯可调用自有体系APP，但外部APP谈判难度较高，存在数据安全隐患担忧以及AI助手和APP厂商流量入口之争的问题。

## 3.2 苹果具备打造爆款AI手机潜力


■ 苹果用户基础、开发者生态优势明显，系统级AI底层框架清晰，具备打造爆款AI手机潜力。

- 用户基础：目前苹果全球活跃设备数量超过23.5亿台，用户基数庞大，且主要是中高端消费人群，全球iPhone保有量已达15.6亿部，为导入AI功能打下坚实的用户基础。
- 开发者生态：苹果拥有3400万注册开发者和180万款APP Store应用，开发者可基于苹果生态构建AI应用，与系统原生功能深度融合。苹果通过增强开发者工具大幅降低跨平台AI应用的开发门槛，全平台统一的设计语言亦简化了应用扩展流程，WWDC25上苹果还宣布向第三方开发者开放苹果的设备端基础模型（Foundation Models），为AI生态开发提供平台型赋能。
- 自研+第三方合作强化模型能力：据报道，苹果计划使用谷歌开发的1.2万亿参数模型以助力Siri全面升级，苹果将每年向谷歌支付约10亿美元以使用该技术。
- 苹果系统级AI底层框架：APP Intent + MCP。1) 苹果App Intent是能够提升应用在整个系统上的可发现性、可见性和能力的系统框架，提供将应用内操作和跨平台系统体验深度集成的功能。开发者通过将 App 接入 App Intent接入苹果快捷指令Shortcut，将APP具体功能转化为可为系统直接调用的能力，从而实现跨APP操作）。2) 25年9月苹果于iOS26.1开发者测试版中初步整合 MCP（模型上下文协议），未来通过在 App Intents框架中构建系统级 MCP支持，ChatGPT、Claude等兼容 MCP的 AI 模型可依托苹果自有的APP Intent框架执行iOS应用功能。

图：全球iPhone保有量



图：苹果APP intent




## 3.2 苹果AI升级：重视26Q1潜在催化

- **26Q1升级版Siri有望推出，新款 Siri将依赖谷歌Gemini模型的定制版本，重点提升语义理解、多轮对话及实时信息检索能力，支持多步骤任务。**
  - **支持个人情境感知：**个人情境感知功能将允许Siri追踪用户的电子邮件、信息、文件和照片等内容。凭借这些信息，Siri能更有效地帮助用户查找所需内容，如航班号、下载的文件或他人发送的照片，同时在对话中给出更加个性化的回答。
  - **支持屏幕感知：**Siri将能够识别用户屏幕上显示的内容，并据此执行相关操作。例如可以通过语音指令将收到的短信中的地址添加到联系人中。
  - **跨应用操作集成增强：**借助App Intents框架实现苹果应用与第三方应用的深度集成，能够执行数百种跨应用新操作，例如使用Siri调出Safari阅读列表中的文章或将特定照片并发送。LLM-Siri还将增强对多步骤任务的支持，可通过一条命令连续完成多步骤操作。
- **25年底-26Q1中国区Apple intelligence有望推出。**
  - **合作情况：**苹果在最初选择了百度作为中国大陆Apple Intelligence合作商，但由于技术和隐私原因合作进展不佳，苹果于2025年2月转向与阿里合作。目前大陆Apple Intelligence合作服务主要由阿里提供，包括通义千问大模型、合规审查模型等；次要内容由百度提供，例如视觉识别、云端搜索等。
  - **开发进展顺利，苹果AI预计25年底-26Q1落地。**苹果正和阿里协同对中国区Apple Intelligence进行功能测试，中国区Apple Intelligence最早在年底前通过iOS 26.2发布，若进展稍慢则可能在26年春季iOS 26.4版本与升级版Siri一同发布。
- **AI叙事重启有望缩短换机周期：**目前全球iPhone活跃用户（iPhone保有量）约15.6亿，截至25年底我们估算能够支持Apple intelligence的机型（15 Pro系列、16系列和17系列）累计约4亿部，仍有11-12亿潜在换机用户，若苹果AI叙事重启，有望缩短换机周期，进而抬升销量。

## 3.2 2026-28年苹果有望迎来创新周期

- **iPhone18:** 1) 发布节奏: Air/Pro/ProMax/折叠机预计于26年秋季发布, 标准款发布或延迟至27年春季以平滑新品淡旺季; 2) 硬件升级: SoC (台积电N2+WMCM封装, 性能+15%)、光学 (Pro版首搭可变光圈) 等。
- **折叠屏:** 1) 首款折叠屏iPhone 18 Fold (左右折): 有望于2026年秋季推出, 预期定价2000美元左右, 备货量预期1000-1500万部。配置上, 搭载A20芯片, 7.8英寸无孔内屏+5.5英寸打孔外屏, 屏幕外覆盖UTG+PET膜, 铰链采用液态金属+MIM+3D打印+CNC工艺, 搭载钛合金屏幕支撑层、3D玻璃后盖+钛合金中框等, 影像配置预计与iPhone18类似。2) 二代、三代折叠手机: 2027年有望推出第二代Fold机型, 28年有望推出第一代Flip机型 (上下折)。3) 首款折叠iPad: 有望于2028年推出, 预测内屏尺寸18至20英寸。
- **AI/AR眼镜:** 首款无显示AI眼镜有望26H2-27H1发布; AR眼镜目前多个方案在研, 有望28年推出。
- **AI耳机:** 带红外摄像头的耳机有望26H2推出。
- **Vision Pro:** 27H2有望推出降本减重版Vision Air (目前暂时搁置, 重点推进AI眼镜); Vision Pro 2有望28年推出。
- **智能家居摄像头:** 预计最早26年底发布。
- **桌面机器人:** 外形类似家庭智能中枢显示屏, 底座配有电动臂, 预计27-28年推出。

图：2026-28年苹果创新硬件发布节奏展望





### 3.3 AI眼镜有望成为端侧AI核心载体

- **Meta引领行业发展，大厂相继入局，AI眼镜产业趋势明确，有望成为端侧AI核心载体。**
  - **Meta：**Meta于9月Connect大会发布Ray-Ban Meta 3、Oakley运动款AI眼镜、消费级AR Celeste以及肌电感应手表等新品，25Q4销量有望继续向上。26年Meta有望发布自有品牌AI眼镜，叠加新旧联名AI眼镜贡献，26年Meta AI眼镜销量增长动能强劲。
  - **阿里：**25年11月阿里夸克AI眼镜S1正式发布，单绿色MicroLED+衍射光波导，深度接入“千问”和夸克AI能力，将淘宝、支付宝、高德、飞猪等阿里系核心服务。
  - **苹果：**首款无显示AI眼镜有望26H2-27H1发布；AR眼镜目前多个方案在研，有望28年推出。
  - 此外，字节无显示AI眼镜有望26Q1发布，AR眼镜有望26Q4推出，三星、华为等有望于2026年推出首款AI眼镜，亚马逊有望于26年推出toB和toC两款AR眼镜，谷歌AI眼镜最早26Q4推出。

图：AI眼镜发布时间表



注：本图仅统计拍摄类AI眼镜和AI+AR眼镜，不包含纯音频AI眼镜和观影类AR眼镜。


### 3.3 新终端：大厂相继入局AI玩具

- 随大模型智能化提升，对话式AI成为主要交互方式之一，由此延伸出AI陪伴式硬件终端—AI+玩具类、桌面机器人、陪伴类产品等。继字节之后，华为、京东等相继入局AI玩具，有望打造爆款产品。
- 华为：11月25日华为发布首款AI玩具“智能憨憨”，售价399元，发售即售罄，该产品由华为和珞博智能联合设计开发，是Fuzozo 芙崽和“憨憨”定制合作款，搭载小艺大模型，具备记忆能力。
- 京东：11月20日京东京造宣布预售搭载JoyInside系统的AI毛绒玩具，该系列共推出8款各具人设的AI玩具。
- 跃然创新：24年7月推出的全球首款AI玩具BubblePal，售价389元，累计销量突破25万台。25年8月发布全球首款端到端AI玩具，大幅提升交互响应速度，底层技术架构由跃然创新和豆包团队联合研发，且加入了微触感芯片，用户只需轻触毛绒玩具，设备即可瞬间唤醒。
- 远期市场空间：据共研网数据显示，预计到2030年全球AI玩具市场规模达351.1亿美元，潜力空间巨大。

图表：华为智能憨憨



图表：全球AI玩具市场规模及预测




### 3.3 新终端：人形机器人产业加速落地

- 全球人形机器人产业加速落地。
  - 海外方面，特斯拉26Q1有望发布Gen 3原型机，26年中期启动小规模生产，26年底启动年产百万台的大规模产线；Figure于25年10月发布Figure03机器人，相比上一代，其视觉感知能力与抓握稳定性大幅提升，BotQ工厂首条生产线预计年产能1.2万台。
  - 国内方面，宇树机器人已完成IPO辅导，25年预计出货2000台人形机器人和1.5万台四足机器人；智元机器人25年预计交付6500台；优必选计划2026年实现5000台人形机器人交付，机器人产业化加速。
- 市场空间广阔。全球智能机器人（工业机器人+服务机器人）市场规模预计从2025年的706亿美元增长至2029年的1239亿美元，CAGR为15.1%；其中，人形机器人属于服务机器人重要分支，全球人形机器人市场规模预计从2025年的23亿美元增长至2029年的129亿美元，CAGR达54.4%。


图表：国内外机器人厂商进展梳理

| 公司     | 代表机型      | 详细信息                                                       |
|--------|-----------|------------------------------------------------------------|
| 特斯拉    | Optimus   | 26Q1有望发布Gen 3原型机，26年中期启动小规模生产，26年底启动年产百万台的大规模产线            |
| Figure | Figure03  | BotQ工厂首条生产线预计年产能1.2万台，未来4年内计划将产能扩至每年10万台。25年10月发布Figure03。 |
| 宇树     | H2、G1     | 25年预计出货2000台人形机器人和1.5万台四足机器人，25年11月完成IPO辅导。                |
| 智元     | 远征A2、灵犀X2 | 2024年10月临港量产工厂投产，25年计划交付6500台。                             |
| 小鹏     | IRON      | 2026年底计划实现高阶人形机器人的规模化量产。25年11月发布新一代IRON。                   |
| 优必选    | Walker S2 | 计划2026年实现5000台人形机器人交付，2027年努力达成万台交付规模                      |

图表：全球智能机器人市场规模（亿美元）



图表：全球人形机器人市场规模（亿美元）



# 目 录

一、AI仍是所有主线

---

二、AI基建缺口扩大

---

三、端侧AI奇点已近

---

四、投资建议及风险提示

---



## ■ 建议关注AI算力链：

- 1) 海外算力：生益科技、沪电股份、深南电路、胜宏科技、鹏鼎控股、生益电子、东山精密、兴森科技、江海股份、顺络电子、三环集团等。
- 2) 国产算力：寒武纪、灿芯股份、芯原股份、翱捷科技、中芯国际、华虹半导体、长电科技、通富微电、甬矽电子等。

## ■ 建议关注存储产业链：

- 1) 设计公司：兆易创新、普冉股份、东芯股份、聚辰股份、澜起科技等；
- 2) 模组：江波龙、德明利、香农芯创、佰维存储、开普云、时空科技等；
- 3) 其他：晶合集成、汇成股份、深科技等。

## ■ 建议关注AI端侧公司：立讯精密、歌尔股份、蓝思科技、领益智造、信维通信、水晶光电、恒玄科技、瑞芯微、乐鑫科技等。

## ■ 建议关注设备公司：北方华创、拓荆科技、中微公司、微导纳米、精智达、京仪装备、华海清科、中科飞测、骄成超声、百傲化学等。

- 行业需求不及预期的风险：若包括手机、PC、可穿戴等终端产品需求不及预期，则产业链相关公司的业绩增长可能不及预期。
- 大陆厂商技术进步不及预期、中美贸易摩擦加剧、研报使用的信息更新不及时的风险、报告中各行业相关业绩增速测算未剔除负值影响，计算结果存在与实际情况偏差的风险、行业数据或因存在主观筛选导致与行业实际情况存在偏差风险。

# 重要声明

- 中泰证券股份有限公司（以下简称“本公司”）具有中国证券监督管理委员会许可的证券投资咨询业务资格。本报告仅供本公司的客户使用。本公司不会因接收人收到本报告而视其为客户。
- 本报告基于本公司及其研究人员认为可信的公开资料或实地调研资料，反映了作者的研究观点，力求独立、客观和公正，结论不受任何第三方的授意或影响。本公司力求但不保证这些信息的准确性和完整性，且本报告中的资料、意见、预测均反映报告初次公开发布时的判断，可能会随时调整。本公司对本报告所含信息可在不发出通知的情形下做出修改，投资者应当自行关注相应的更新或修改。本报告所载的资料、工具、意见、信息及推测只提供给客户作参考之用，不构成任何投资、法律、会计或税务的最终操作建议，本公司不就报告中的内容对最终操作建议做出任何担保。本报告中所指的投资及服务可能不适合个别客户，不构成客户私人咨询建议。
- 市场有风险，投资需谨慎。在任何情况下，本公司不对任何人因使用本报告中的任何内容所引致的任何损失负任何责任。
- 投资者应注意，在法律允许的情况下，本公司及其本公司的关联机构可能会持有报告中涉及的公司所发行的证券并进行交易，并可能为这些公司正在提供或争取提供投资银行、财务顾问和金融产品等各种金融服务。本公司及其本公司的关联机构或个人可能在本报告公开发布之前已经使用或了解其中的信息。
- 本报告版权归“中泰证券股份有限公司”所有。事先未经本公司书面授权，任何机构和个人，不得对本报告进行任何形式的翻版、发布、复制、转载、刊登、篡改，且不得对本报告进行有悖原意的删节或修改