2026 年 04 月 11 日

看好

国产 AI 算力继续推荐！Claude、DeepSeek 新进展！

——计算机行业周报 20260406-20260410

相关研究

《26Q1 计算机业绩前瞻！关于大模型 Harness 的讨论！——计算机行业周报 20260330-20260403》 2026/04/06

《从 CPU 涨价到“词元经济”！——计算机行业周报 20260323-20260327》 2026/03/28

证券分析师
黄忠煌 A0230519110001
huangzh@swsresearch.com
洪依真 A0230519060003
hongyz@swsresearch.com
刘洋 A0230513050006
liuyang2@swsresearch.com
研究支持
崔航 A0230524080005
cuihang@swsresearch.com
曹峥 A0230525040002
caozheng@swsresearch.com
陈晴华 A0230525100001
chenqh@swsresearch.com
罗宇琦 A0230124070004
luoyq@swsresearch.com
联系人
王开元 A0230125030001
wangky@swsresearch.com

申万宏源研究微信服务号

本期投资提示：

- **本周周报重点：1）国产算力进入单卡-系统交替技术突破贡献效率提升的周期。2）Claude Mythos 及 DeepSeek V4 进展。3）重点公司更新：浪潮信息：**Token 经济快速发展正在将算力服务器推向产业核心；**聚水潭：**盈利拐点乙现，规模化+AI+出海驱动未来增长。
- **国产算力进入了单卡-系统交替技术突破贡献效率提升的周期。**数据端，25 年国内 AI 芯片总出货量超 400 万，25 年英伟达国内市占率进一步下降。23-25 年，国内 AI 芯片出货，NV 占比从 85%-70%-55%。推理芯片看，25 年国内出货量 NV 占比低于 50%。华为仍是国产断层第一，25 年华为出货 81 万卡，市占率达到 20%，平头哥出货达到 25.9 万张位居第二，昆仑芯、寒武纪位列 3-4（份额相当），三大黑马奋力追赶，但华为仍为国内断层第一。
- **能力端，超节点相关的多维技术均起步。**26Q1 国内超节点网络拓扑、互联协议、机柜设计已经有标准方案。网络拓扑，国内预计向 Clos 全对等网络收敛，交换 ASIC 是核心增量环节。互联协议，总线型 UB、HSL 领头，以太型各 CSP 基于以太网自行拓展。机柜设计，互联网、服务器、通信厂商均发布标准构型。
- 统一内存、通信运行时和 RAS 把这些被打开的系统能力组织成一条可持续演进的软件路径，使新变量能够沿着既有生态被持续吸收，并最终稳定兑现为 Goodput。**因此，我们认为国产算力进入了单卡-系统交替技术突破贡献效率提升的周期，未来的 LPO/CPO/OCS、HBM/3D DRAM、infra 技术的突破，都可能带来效率提升，实现乘数效应**
- **大模型持续更新！**1）Claude Mythos 引发关注讨论，标志着 AI 开始在网络安全领域具备规模化攻防能力，把过去昂贵、稀缺、依赖资深研究员的漏洞挖掘工作推向更可规模化阶段。2）DeepSeek V4 灰度测试，预计补齐多模态能力，此外预期推理和代码能力继续升级、长上下文和复杂长任务处理能力（Agent）提升、国产算力适配，技术架构延续 DSA+MoE，有望运用 Engram 和 DualPath。
- **重点公司更新：1）：浪潮信息：**Token 经济快速发展正在将算力服务器推向产业核心；**2）聚水潭：**盈利拐点已现，规模化+AI+出海驱动未来增长。
- **重点推荐主线：**1）数字经济领军；2）AIGC 应用；3）AIGC 算力；4）数据要素；5）信创弹性；6）港股核心；7）智联汽车；8）新型工业化；9）医疗信息化。详细标的请见正文。
- **风险提示：行业若激进扩人策略，可能影响盈利增长。外部因素影响供应链稳定性。**

1. 国产算力继续推荐！

需求持续爆发。当前市场对于未来国内云厂和大模型厂商加码资本开支的认知是充分的，日均 Token 调用、AI APP MAU 数据均证明了这一点。2026 年国产 AI 芯片市场增速仍存在预期差，预计增速将会非常陡峭。

图 1：豆包大模型日均 Token 调用量达到 50 万亿（时间截点：2025.12，单位：万亿）

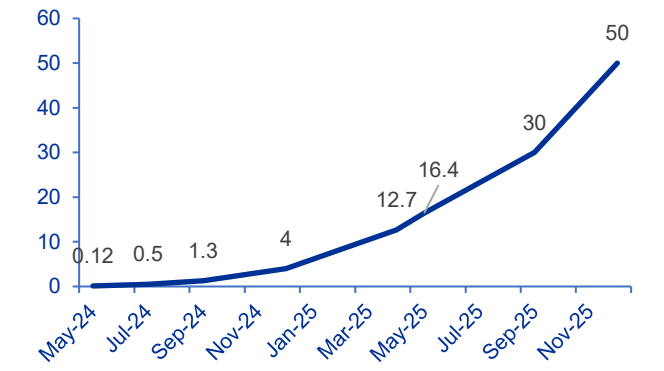

资料来源：火山引擎大会，申万宏源研究

图 2：25H2 国内主要 AI APP MAU（亿）

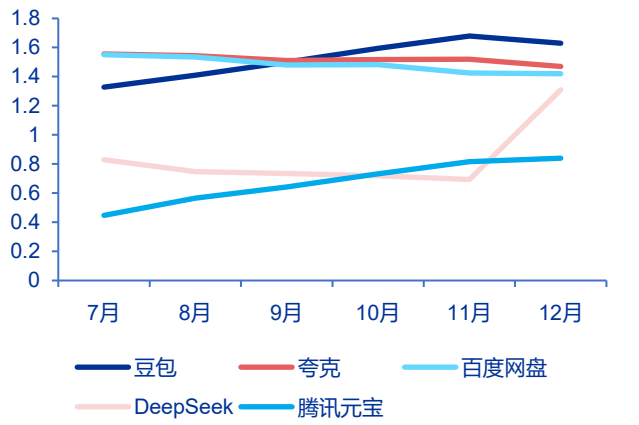

资料来源：AI 产品榜，申万宏源研究

中国市场整体 AI 算力需求呈现爆发式增长。根据 IDC 数据，三年间总出货量从 108 万片激增突破至 401 万片，年复合增长率达到 55%。2022-2025 年，英伟达在中国市占率不断下降，2025 年仅为 55%。华为昇腾确立领先地位，出货量由 2022 年的 10.46 万片飙升至 2025 年的 81.96 万片，稳居国产厂商首位。阿里平头哥实现跨越式增长，2025 年成为仅次于华为的国产芯片主力，寒武纪与昆仑芯稳守第一梯队。

图 3：英伟达在国内市场份额快速下降

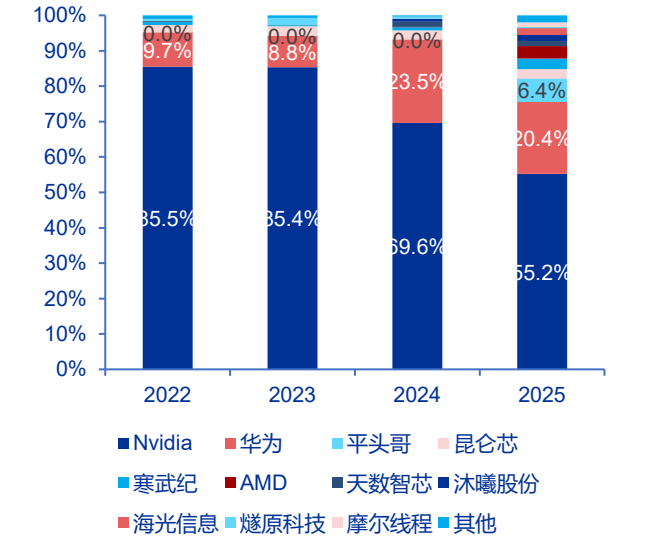

资料来源：IDC（国际数据公司），申万宏源研究

图 4：中国国内 AI 芯片出货量（万片）

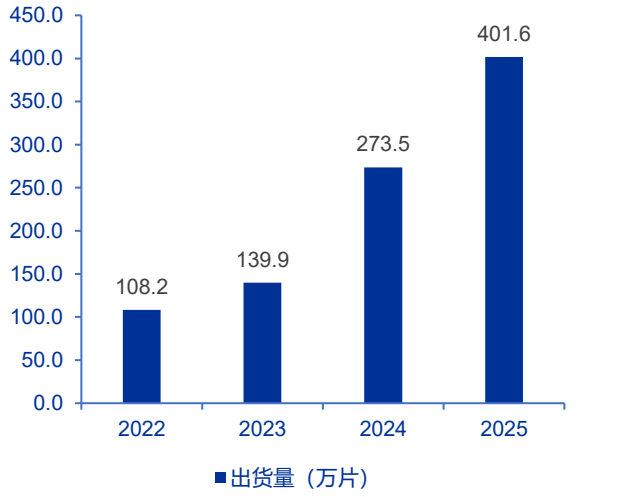

资料来源：IDC（国际数据公司），申万宏源研究

展望未来，我们认为国内芯片厂商仍将齐头并进，共享 AI 时代的需求爆发。

寒武纪：大模型和搜广推训推解决方案，已完成大规模技术和产品验证，伴随大客户成长。

在搜广推训练方向，寒武纪稳步推进技术和产品验证。验证结果表明，解决方案可支撑多场景下的流式训练任务，可持续超数月稳定运行，精度与稳定性均满足要求。持续性能优化方面，完成 Layernorm/RMSNorm/L2Norm 等多种图匹配融合，显著提升性能。在图融合基础上进一步优化 XLA 支持，并获得更显著的加速比结果。

在大模型训练方向，寒武纪重点支持 DeepSeek V3/V3.1、Qwen2.5/Qwen3/Qwen3-next 等 MoE 类模型训练，同时扩展了 GLM4.5、Flux、Wan2.1/2.2、Qwen3-VL、Hunyuan-Video 等模型的训练支持。基于原生 FP8 的计算能力，新增 Qwen/DeepSeek 等系列网络 FP8 的训练支持，精度符合预期。

寒武纪在生态适配上采取了多线并进策略。除自有的 BANG 语言外，寒武纪开源了跨平台 AI 编译器前端 Triton-Linalg，专为支持 Triton 语言设计。Triton-Linalg 不仅完备支持 Triton 编程原语，还能高效处理从复杂的指针操作到张量（Tensor）的转换，大幅降低了 AI 编程的难度，可作为 CUDA 的另一选择。

图 5：昇腾 AI 芯片未来三年规划三大系列共四款产品，算力每年翻一倍

资料来源：寒武纪官网，申万宏源研究

华为：26 年关键词是“改变”。950 芯片多项变化，SIMD—>SIMT，搭配自研大显存。

Ascend 950 系列是华为正在开发、且即将推出的芯片。与前一代昇腾芯片相比，Ascend 950 在以下几个方面实现了根本性提升：

1）新增支持业界标准 FP8/MXFP8/MXFP4 等低数值精度数据格式，算力分别达到 1P 和 2P，提升训练效率和推理吞吐。并特别支持华为自研的 HiF8 数据格式，在保持 FP8 的高效的同时，精度非常接近 FP16。

2）大幅度提升了向量算力。其一，提升向量算力占比；其二，采用创新的新同构设计，即**支持 SIMD/SIMT 双编程模型**，SIMD 能够像流水线一样处理“大块”向量，而 SIMT 便于灵活处理“碎片化”数据；其三，把内存访问颗粒度从 512 字节减少到 128 字节，内存访问更精细，从而更好地支持了离散且不连续的内存访问。

3）互联带宽相比 Ascend 910C 提升了 2.5 倍，达到 2TB/s。

4）PD 分离在芯片层级实现：华为自研了两种 HBM，分别是：HiBL 1.0 和 HiZQ 2.0。不同的自研 HBM 与 Ascend 950 Die 合封，分别构成芯片 Ascend 950PR：面向 Prefill 和推荐场景，以及 Ascend 950DT：面向 Decode 和训练场景。

3.20 日，**Ascend 950PR 已经发布，搭载该款芯片的标卡 Atlas 350 也一并发布。**

图 6：昇腾 AI 芯片未来三年规划三大系列共四款产品，算力每年翻一倍

资料来源：快科技，申万宏源研究

据华为昇腾计算业务总裁张迪煊介绍， Atlas 350 的 FP4 精度算力为 1.56P，带宽达到了 1.4TB/s，搭载 112GB HBM，功耗为 600W 。

图 7：搭载昇腾 950PR 的 Atlas 350 具体参数

资料来源：华为计算，申万宏源研究

此外，国内摩尔线程、沐曦股份、天数智芯、壁仞科技等，也正快速追赶。这四家公司产品均为 GPGPU 架构，搭配自研的软件栈生态，产品正从“可用”向“好用”迈进，预计在 2026 年缺算力背景下，进入成长的窗口期。

图 8：AI 芯片四小龙 2022-2025 年收入（亿元）

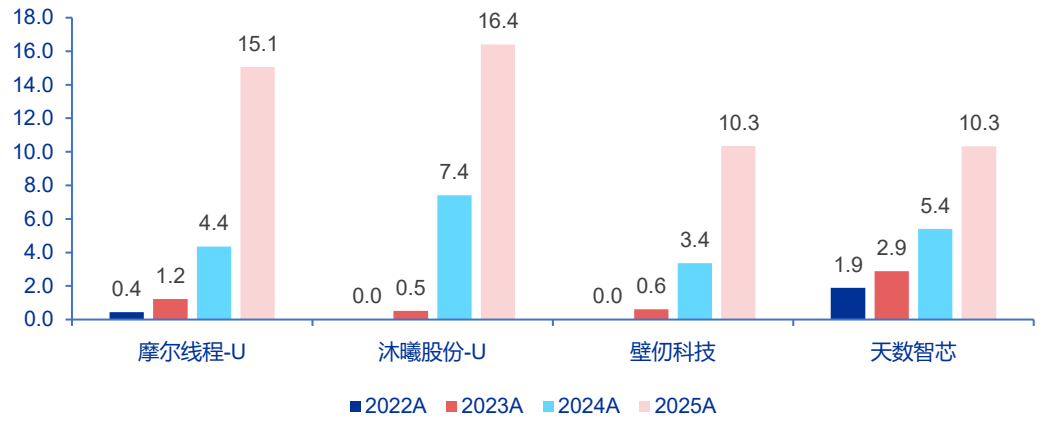

资料来源：Wind，申万宏源研究

摩尔线程：生态、架构、集群亮点纷呈。

摩尔线程成立于 2020 年，专注自主研发全功能 GPU 芯片及相关产品。创始人团队均来自英伟达，创始人张建中曾任英伟达全球副总裁、大中华区总经理，行业经验丰富。

定位全功能 GPU，24 年起智算产品开始商业化。摩尔线程单一 GPU 芯片中集成了 AI 计算加速、图形渲染、物理仿真和科学计算、超高清视频编解码等多种能力，满足多样化需求。在工作效率、生态完整多样性以及兼容性等方面更具有优势，更好适应未来新兴及前沿计算加速应用场景的需求。产品线覆盖 AI 智算、图形加速及智能 SoC，可应用于端侧设备、PC、服务器及数据中心等场景。24 年后 AI 智算卡驱动收入高速增长。

智算领域，公司在芯片、集群层级均具备先进性：1）芯片级：公司自主研发软硬融合的全功能 GPU 计算加速统一系统架构 MUSA，硬件上采用 Chiplet、高速 I/O 接口和优化通信协议等提升性能；软件上兼容 CUDAC++核心语义和 Triton 语言，与国际主流 GPU 生态的兼容。**2）集群级：**打造软硬一体、系统级算力解决案 KUAE，包含基础设施、集群管理、大模型三个层级，攻克千卡至万卡级 GPU 集群的高效互联难题，确保算力协同与通信性能契合大规模智算中心需求；千卡集群效率超过同等规模国外同代产品。

表 1：摩尔线程智算集群与可比公司比较情况

公司名称	代表产品	集群规模	FP16 Tensor (EFLOPs)	GPU 数目	网络方案	卡间互连（GB/s）
摩尔线程	KUAE2	万卡级	不披露	10,240 张	IB/RoCE	~800
微软/OpenAI	Azure AI SuperCluster	十万卡级	100（预估）	10 万张 H100	IB	900
Meta	AI Research SuperCluster(RSC)	十万卡级	100（预估）	10 万张 H100	IB/RoCE	900
xAI	Colossus 超级计算集群	十万卡级	200	20 万张	IB	900

资料来源：摩尔线程招股说明书，申万宏源研究

沐曦股份是国内高性能通用 GPU 产品的主要领军企业之一，致力于自主研发全栈高性能 GPU 芯片及计算平台。于 2020 年成立于上海，主营业务是研发、设计和销售应用于人工智能训练和推理、通用计算与图形渲染领域的全栈 GPU 产品，并围绕 GPU 芯片提供配套的软件栈与计算平台。深度积累了 GPU IP（包括指令集、微架构等）、GPU SoC、高速互连、GPU 软件等核心技术。

沐曦股份深度构建“1+6+X”生态与商业布局。

“1”：基础算力底座方面相继交付 9 大智算集群，算力网络覆盖国家人工智能公共算力平台、运营商智算平台和商业化智算中心。

“6”：GPU 产品深度赋能众多行业应用场景，已率先布局教科研、金融、交通、能源、医疗健康、大文娱等行业。

“X”：区域横跨北京、上海、杭州、长沙、中国香港等地区，并逐渐向更多区域延伸。

公司自主研发全栈高性能 GPU 芯片及计算平台，积累大量核心技术。基于对包括 GPU IP、GPU 指令集和架构在内的一整套 GPU 底层核心技术的完全自主掌握。

曦云 C 系列 GPU 芯片：具备国内稀缺的高带宽、超多卡互连能力。公司全系列产品采用统一的 XCORE 架构，兼具通用性和高性能，利于快速迭代；

基于 MetaXLink 互连技术，公司的单颗芯片产品拥有 7 个高速 MetaXLink 互连接口，可实现 2 卡、4 卡、8 卡、16 卡、32 卡、64 卡等多种互连拓扑；

GPU 硬件在计算能力（C500 FP16/BF16 算力处于国内第一梯队）、存储（C500 使用 HBM2e，HBM3/3e 产品研发中）、互联能力（MetaXLink 支持 2-64 卡 Scale-up）等维度具有领先产品力。自研的 MXMACA 软件框架兼容 CUDA，兼具易用性和通用性；

根据招股说明书，曦云 C500 系列训推一体 GPU 具备国内领先的计算能力，综合性能对标英伟达 A100，并且相较英伟达目前国内可售产品 H20 在大模型训练场景下更具性能优势。

图 9：沐曦股份软件栈

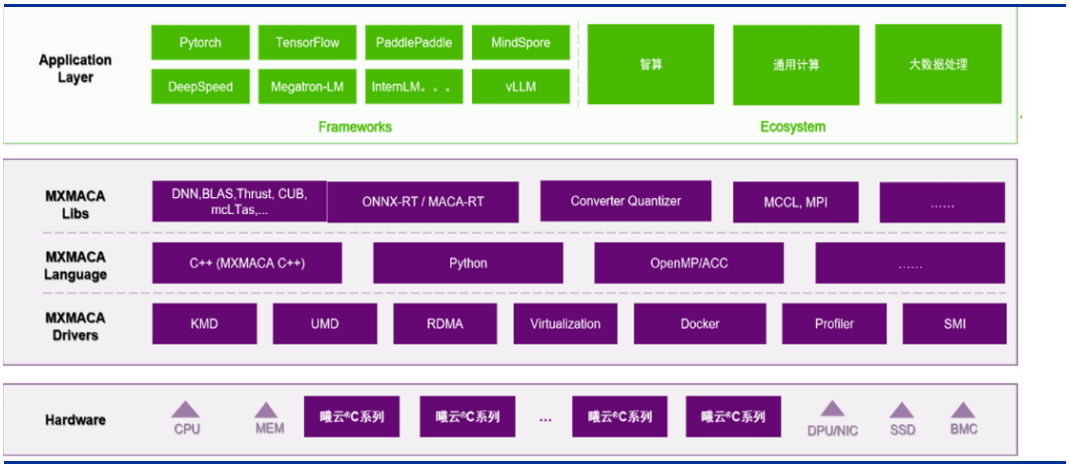

资料来源：沐曦股份招股说明书，申万宏源研究

天数智芯：国产 GPU“四小龙”中成立最早，为国内首家实现通用 GPU 芯片量产的公司。

公司成立于2015年12月，创始团队背景多元，涵盖架构、GPU IP设计、基础软件、AI 算法、软硬件协同等领域的专家，核心研发人员多来自 AMD、英伟达等国际半导体企业，主要负责人拥有逾 20 年行业经验。公司已构建覆盖“云-边-端”全场景的通用 GPU 产品矩阵。公司构建天垓、智铠、彤央系列的产品矩阵，覆盖训练、推理、端侧应用场景，满足多元化算力需求。营收高速增长，商业化节奏稳健。公司芯片出货量从 2022 年的 0.78 万片增长至 2025 年上半年的 1.57 万片，产品迭代伴随着持续的商业化放量；截至 2025 年底，公司已经累计服务客户超 340 家，完成 1,000 个项目部署应用。2025 年，公司营收规模已达到 10.34 亿元。

图 10：天数智芯架构路线图

资料来源：天数智芯官网，申万宏源研究

壁仞科技：多元背景，硬件实力强劲。

壁仞科技 2019 年成立，创始团队源自 AMD、华为等大厂，CEO 张文先生拥有丰富的科技企业管理、战略及资本市场经验，首席 GPU 架构师洪洲先生曾担任华为海思 GPU 首席架构师。公司研发人员占比超 83%，截至 2025 年 6 月拥有全球 1158 项发明专利，位列中国 GPGPU 企业第一。

产品聚焦 GPGPU 架构，前瞻布局 Chiplet 芯粒和光交换技术。公司率先采用 PCIe 5.0、Chiplet 芯粒技术，BR166 通过双 BR106 裸晶集成，算力、内存性能达 BR106 两倍，裸晶间双向带宽高达 896GB/s。硬件支持 OAM、PCIe 等多形态部署，软件平台支持 PyTorch 等主流框架，形成从芯片设计到集群部署的全栈优化能力，技术实力行业领先。

生态协同深化，OCS 超节点方案引领创新。公司联合中兴通讯等发布 LightSphere X 光交换超节点，采用分布式 OCS 技术，支持 2 千卡规模部署及万卡级弹性扩展。通过动态调整拓扑结构适配大模型训推需求。同时，壁仞科技与阶跃星辰、上海仪电等开展 “芯-模-云” 协同，深化国产大模型适配，生态黏性持续增强。

图 11：壁仞科技芯片迭代历程及未来规划

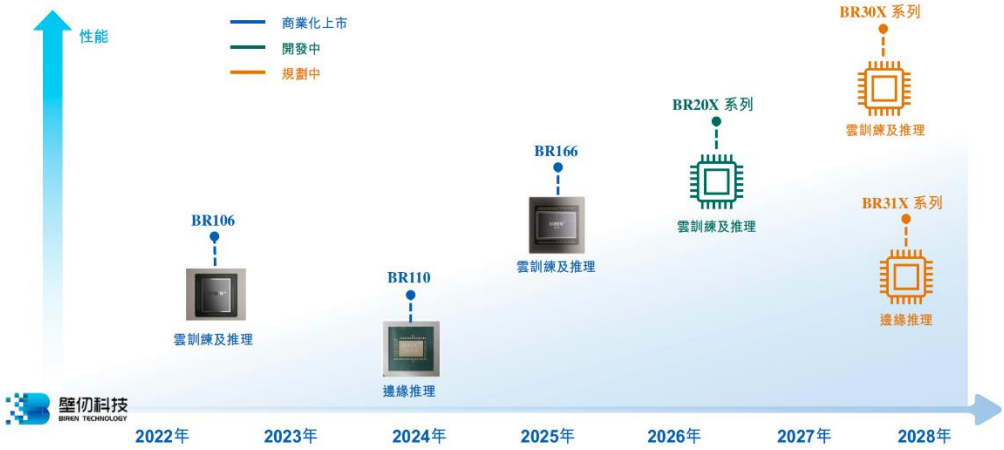

资料来源：壁仞科技招股书，申万宏源研究

另外一个国产算力产业端的变化，是超节点的成熟。

2025 年，全球 AI 服务器开启超节点趋势。2024 年 GTC 大会，英伟达发布 GB200 NVL72 超节点，开启全球 Scale-up 规模化的新趋势；2025 年 4 月，华为推出 CloudMatrix 384 超节点产品，为国内首个超节点产品。

超节点通过 Scale-up 组网的方式，将更多 AI 芯片聚合，实际补足了国产 AI 芯片在单卡性能上的短板，提升了国产 AI 芯片在推理场景的性能。

国产超节点生态走向开放，算力底座加速国产 AI 芯片落地。超节点产品设计门槛较高，包括互联协议（软件栈）、交换芯片、机柜设计等，主要由英伟达、华为、海光+曙光等具备全栈设计能力的头部 AI 芯片厂商完成。过去，以英伟达 NVLink 为代表的 Scale-up 生态为闭源生态，仅供英伟达 GPU 使用；**当前，国内超节点生态逐步走向开源，头部厂商通过开放互联协议、设计兼容多种 AI 芯片接口的超节点机柜，为国产 AI 芯片提供算力底座。**

我们认为，架构层面，Clos 网络成为公共选择，通信协议形成了总线型和以太型两大类。

图 12：不同芯片厂商 Scale-up 协议的选择

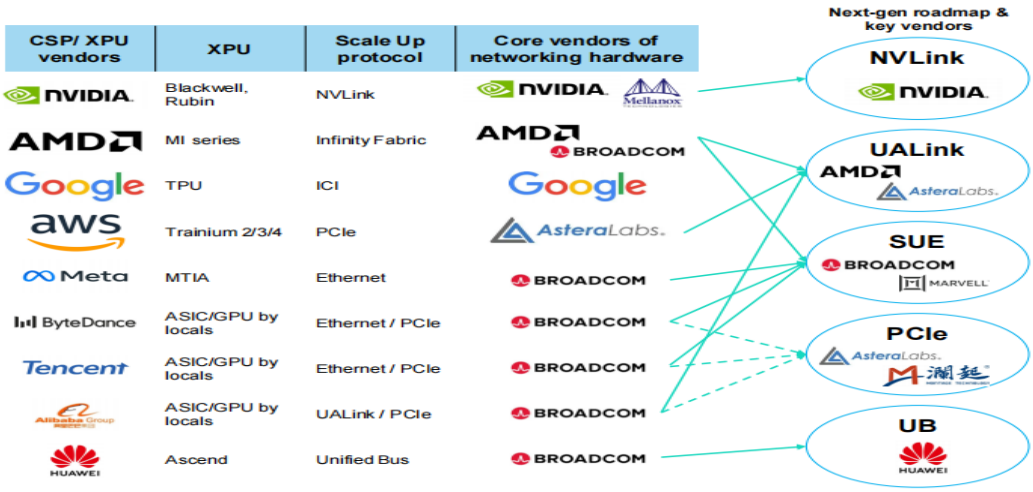

资料来源：申万宏源研究

供给端，华为、海光曙光等头部厂商开源软硬件生态。

华为超节点路线并不以单卡性能领先为主要特征，而是通过昇腾 NPU、鲲鹏 CPU、自研 HCCS/UB 灵衢互联以及云侧调度软件，把更多强耦合通信尽量保留在高带宽域内。CloudMatrix 384 是这一路线第一次较完整落地到超节点形态的代表性产品，其后续方向则是继续沿着更大 Scale-Up 域和更高层级互联能力演进，向千卡甚至万卡级别的系统扩展。

2025 年 9 月 18 日，在 2025 全联接大会上华为正式对外开放面向超节点的互联协议灵衢 2.0（Unified Bus 2.0）技术规范。华为采用“硬件开放，软件开源”策略。

表 2：华为互联协议情况

层级	技术	作用
芯片间 / 板级互联	HCCS	昇腾早期的高速缓存一致性互联，主要支撑 8 卡节点内协同
节点内 Scale-Up	UB 灵衢	总线级互联，支持内存语义和消息语义，单跳时延约 150-200 ns
跨柜互联	UB 灵衢 + 光模块	用于把多柜计算节点组织成统一超节点，距离可扩展到 200 m 以上
Scale-Out	RoCE/RDMA	连接更大规模集群，承担超节点外的横向扩展

资料来源：超节点技术白皮书，申万宏源研究

硬件方面，1）开放灵衢协议和超节点参考架构，允许产业界基于技术规范自研相关产品或部件；2）全面开放超节点基础硬件，包括 NPU 模组、风冷刀片、液冷刀片、AI 标卡、CPU 主板和级联卡等不同形态的硬件，方便客户和伙伴进行增量开发，设计基于灵衢的各种产品。**软件方面，**操作系统灵衢组件全部开源，组件代码将陆续合入 openEuler 等多个操作系统开源社区，用户可以根据实际需求，将部分或全部源代码集成到现有操作系统中。

灵衢 2.0 为国产 AI 芯片提供了 Scale-up 互联技术标准与生态入口，有助于从“单芯片”到“算力基础设施系统”的跨越。

海光信息：ScaleX 40 超节点产品发布。

海光信息与中科曙光合作的 scaleX40 采用标准 19 英寸箱式设计，将高密算力单元从机柜体系中解耦，形成可独立部署的“箱式算力单元”，可直接部署在主流传统 8 卡服务器机房。其通过正交无线缆架构实现一级互连，计算与交换节点可直接对插，无需线缆、无需光模块，大幅减少线缆连接带来的复杂度与故障点，从根本上重构了算力基础设施的交付方式。这也打破了传统超节点高度依赖光纤与铜缆连接的局限，摆脱了部署复杂、周期长、运维门槛高的困境。**实测显示，scaleX40 芯片间单向通信时延达到百纳秒级，比行业主流组网快近 10 倍，端到端时延降低 30%-50%，系统故障率显著下降，长期可用性提升至 99.99%。运维组装时间从数小时压缩至分钟级，功耗较传统铜缆方案降低 40%-70%。**

图 13：ScaleX40 超节点

资料来源：自主可控新鲜事，申万宏源研究

建议关注：

1） **AI 芯片：**寒武纪、海光信息、摩尔线程-U、沐曦股份-U、天数智芯、壁仞科技；

2） **服务器：**浪潮信息、华勤技术；

3） **交换机及交换芯片：**锐捷网络（通信）、盛科通信（通信）；

其他环节：杰华特、泰嘉股份、航天电器、华正新材、金山云等。

2. 模型更新：Claude Mythos 及 DeepSeek V4

一、Claude Mythos 标志着 AI 在网安领域具备规模化功放能力。

本周， Claude Mythos 引起关注讨论。Mythos 是 Anthropic 研发的一款尚未公开发布的前沿 AI 模型。Anthropic 表示，由于担心其最新 AI 模型 Mythos 太擅长发现主流操作系统和网络浏览器中的“高危漏洞”，现已暂停更广泛地发布。

我们认为，自媒体的部分“过于危险，普通人不能用”宣传有一定营销和媒体放大，但它确实标志着一个重要拐点：AI 开始在网络安全领域具备规模化攻防能力。

Claude Mythos（Preview） 是 Anthropic 新一代旗舰模型，定位在 Claude 系列的 Opus 之上，属于新的能力层级。Anthropic 宣布 不会对公众开放 Mythos，而是只给少数机构使用，包括：大型科技公司、网络安全公司、政府机构。

根据 Antropic 的公开资料，Mythos 有几个关键特点：

1）网络安全能力极强

Mythos 可以在大型软件系统中自动寻找零日漏洞（zero-day），能生成完整 exploit 验证漏洞是否可利用。根据 Claude 公布的案例，Mythos 在测试中发现了数千个高危漏洞，覆盖主流操作系统和浏览器，其中一些漏洞甚至存在 20+ 年，例如在 OpenBSD 中发现的 27 年漏洞。

图 14：火狐浏览器 JavaScript 漏洞利用，Mythos 明显高于 Claude 4.6

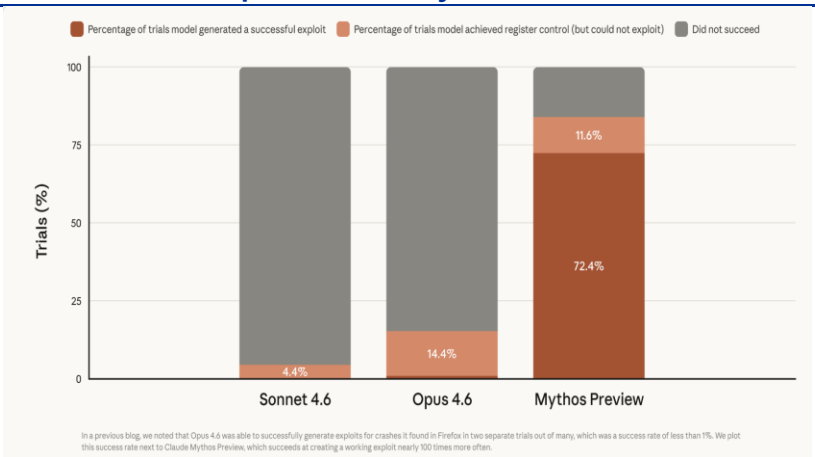

资料来源：Claude 官网，申万宏源研究

2）Agent 化能力很强

根据泄露资料和系统卡：可以自主扫描软件系统，自动组合漏洞链，生成攻击代码并测试，甚至能自动完成复杂安全任务。**这意味着它更像一个自动化红队 AI Agent，明显区别与传统信息安全工程中的安全日志模式。**

我们认为，Mythos 把过去昂贵、稀缺、依赖资深研究员的漏洞挖掘工作，推向更可规模化的阶段。根据 Claude 官网，Anthropic 内部一些没有接受过正规安全培训的工程师，曾让 Mythos Preview 夜间去查找远程代码执行漏洞，第二天醒来后，已经得到一份完整、可工作的 exploit。但是目前看，Mythos 案例仍然以网络安全为主，其他多模态、推理、科学计算等能力并未明确提到迭代，因此部分公众号所说的“过于危险“可能存在部分夸大。

二、2026 年 4 月 DeepSeek V4 开启灰度测试。

当前从灰度测试产品变化上能够看到模型选项分为“快速”、“专家”及视觉，推测对应轻量级、深度思考、多模态。由此判断 DeepSeek V4 将补齐多模态短板。

此外，根据一些信息整理和近阶段 DeepSeek 的论文推测，对 DeepSeek V4 的预期一句话总结为：推理和代码能力继续升级、长上下文和复杂长任务处理能力（Agent）提升、国产算力适配，技术架构延续 DSA+MoE，有望运用 Engram 和 DualPath。

1） 推理和代码能力达业内领先水准。

根据 The information（海外科技媒体），DeepSeek-V4 主打编码能力，内部初步测试结果显示超过 Claude 和 GPT 系列。

2） 长上下文和复杂长任务处理能力（Agent），背后或有新创新技术架构。

2月11日，DeepSeek App 更新灰度测试版本，**升级包括模型上下文处理长度由 128K 扩展至 1M，代表其在长上下文、长编码等任务上能力可能大幅提升。**而根据 DeepSeek 近期发布的两篇重磅论文，我们认为可能是长上下文和复杂任务处理能力突破的关键。

一是 2026 年 1 月 12 日发布的《Conditional Memory via Scalable Lookup：A New Axis of Sparsity for Large Language Models》论文，核心是存算解耦，大幅降本提效。在 MoE 基础上引入 Engram 模块作为条件记忆轴处理静态记忆，MoE 负责计算，Engram 负责知识检索，通过将海量 KV-Cache 移到 CPU 内存，用 O（1）哈希检索进行关键记忆回溯，最终能够实现保障长上下文与推理精度的同时释放 GPU 计算压力。

图 15：推理阶段 Engram 卸载至内存，通过检索异步预取实现通信过程与前序 Transformer 块在计算过程的重叠

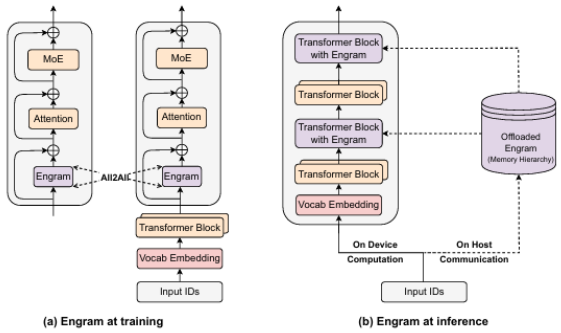

资料来源：《Conditional Memory via Scalable Lookup：A New Axis of Sparsity for Large Language Models》论文，申万宏源研究

图 16：实验证明 MoE 和 Engram 的混合分配效果优于纯 MoE

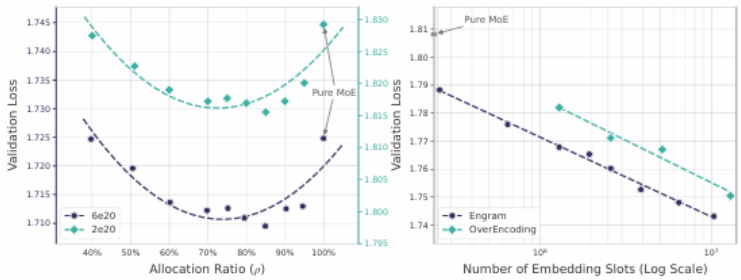

资料来源：《Conditional Memory via Scalable Lookup：A New Axis of Sparsity for Large Language Models》论文，申万宏源研究

此前大模型技术路径均从注意力机制（Full Attention/Linear Attention）和计算（FFN/MoE）着手改进，Engram 从记忆层面着手，影响可能是：让模型以较低成本实现参数规模扩大，或让固定资源下的小参数模型变得更聪明。

二是 2026 年 2 月 26 日发布的《DualPath：Breaking the Storage Bandwidth Bottleneck in Agentic LLM Inference》论文，核心是解决智能体复杂任务工作负载下的性能瓶颈。

长上下文和多轮对话（Agent 场景）中，推理系统通常采用 prefill 预填充和 decode 解码在不同节点上运行的解耦架构，多轮对话或 Agent 频繁调用工具时需从外部存储加载海量 kv-cache，由于 preill 极短时间加载历史缓存会导致 prefill 节点网卡带宽饱和从而成为瓶颈，而 decode 节点网卡闲置，此带宽不对称性限制系统吞吐量。

论文提出存储-decode-prefill 新路径，利用 decode 节点闲置带宽协助读取 kv-cache，通过计算网络快速传输至 prefill 节点，通过动态负载均衡根据集群各节点的网卡负载、计算任务和网络状况动态分配 kv-cache 搬运路径。**测试中，离线推理吞吐量提升 1.87 倍，在线服务吞吐量平均提升 1.96 倍。**

图 17：DualPath 下 GPU 的利用率大幅提升

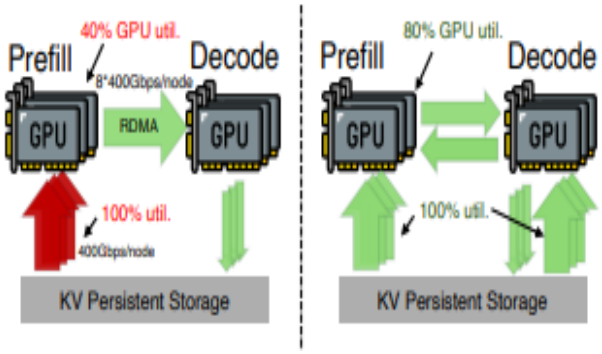

资料来源：《DualPath: Breaking the Storage Bandwidth Bottleneck in Agentic LLM Inference》论文，申万宏源研究

图 18：证明 DualPath 下在处理大规模 Agent 任务时性能更优

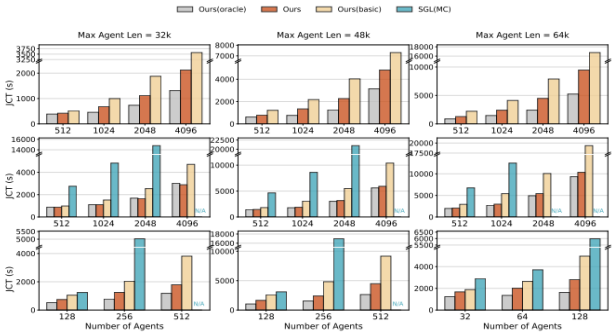

资料来源：《DualPath: Breaking the Storage Bandwidth Bottleneck in Agentic LLM Inference》论文，申万宏源研究

上述两篇最新论文都能证明 DeepSeek 依旧延续一贯思路——极致的系统工程优化。Engram 和 DualPath 以存算解耦、异步掩盖、带宽倍增为核心，为突破长下文和长任务 Agent 能力限制带来可能。因此在 DeepSeek v4 发布前夕的两篇论文，可能是其重要的创新架构。

3） 国产算力适配。

DeepSeek V4 预计全面迁移至华为昇腾 AI 芯片及 CANN 异构计算架构，双方完成核心技术适配，进入性能调优阶段。此次合作不是简单浅层适配，而是从底层算子到上层应用的深度协同，实现：

兼容性适配：V4 核心功能能够在昇腾/CANN 架构完整实现，包括万亿参数模型加载、百万 Token 上下文处理、多模态融合推理、代码生成等。

性能优化适配：算子优化、算力调度、显存管理等，V4 在 950PR 芯片上推理速度达到英伟达 H100 的 85%，显存占用降低 40%，能耗降低 30%。

场景化适配：针对核心应用场景定制化优化，例如代码生成场景下优化算子调度逻辑，提升代码生成响应速度。

3. 重点公司更新

3.1 服务器板块机会，重点推荐浪潮信息

Token 经济的快速发展正在将算力服务器推向产业核心。随着大模型、生成式 AI 和企业智能助手的广泛落地，Token 的消耗量呈指数级增长，直接拉动对高性能算力的需求。在这一背景下，算力服务器成为支撑产业落地的关键基础设施。Token 的高频调用和复杂推理流程要求服务器不仅具备强大的计算能力，还需要高带宽内存、低延迟网络以及高效的 I/O 协调能力，以确保大规模训练和多轮推理场景的稳定性和经济性。

对于服务器厂商来说，目前有两个核心支撑：

1）收入端：真实需求爆发阶段，字节、阿里、腾讯等大厂的资本开支保持高速增长，中型厂商逐渐开始追赶，在服务器格局相对稳定的背景下，服务器头部厂商的收入增长会十分明显；

2）利润端：超节点作为产业确定性趋势，其复杂性将带动服务器厂商的利润率上行。服务器行业费用增长相对较慢，规模化效应明显，净利率弹性大。

因此，服务器行业在 2026 年有望迎来收入爆发增长的同时，体现净利率水平上升，利润弹性大，考虑到行业格局进一步优化，估值水平也将在高增背景下得到提升。

国产算力服务器在 Token 经济下具备战略性机会。在 Token 密集型场景中，国产服务器不仅可以支撑复杂任务和高并发访问，还可以提供可控的部署环境和长期运营的成本优势。随着国产算力架构的持续优化，企业在 Token 经济场景中的核心依赖逐渐从单一硬件转向整机与异构架构协同，这使得国产服务器成为产业投资和采购的重点。

Token 的应用场景日益多元，进一步凸显算力服务器的重要性。除了生成式 AI，企业智能助手、行业知识计算、金融风控、医疗影像分析等垂直应用也对 Token 消耗量提出了显著需求。这类场景对分布式训练和实时推理提出高要求，而算力服务器通过提供整合的 CPU/GPU 资源、存储和网络能力，能够保证复杂任务的顺利执行和模型推理的稳定性。由此可见，算力服务器的部署不仅是技术支撑，更是 Token 经济落地的关键保障。

产业趋势表明，高性能算力将持续成为企业和数据中心的核心资源。随着 Token 调用量的爆发，企业采购和投资将更多聚焦服务器的性能功耗比、架构优化能力以及长期可持续运营能力。通过优化服务器整机架构、加强异构协同以及提升国产算力成熟度，企业能够在降低单位 Token 成本的同时保证系统效率。这也为国内厂商在 Token 经济和 AI 服务全球化竞争中提供了明确的战略优势。

核心标的：浪潮信息、华勤技术（电子）

3.2 聚水潭：盈利拐点已现，规模化+AI+出海驱动未来增长

国内领先的电商 SaaS ERP 供应商，卡位电商中后台核心系统。成立于 2014 年，以 ERP 为切入点持续拓展产品矩阵，目前已形成覆盖订单、库存、仓储、采购、分销及财务的一体化系统能力。2024 年公司在国内电商 SaaS ERP 市场份额达 24.4%，位居行业第一，连接 400+电商平台及 800+仓配服务商，具备电商运营中枢属性。

收入保持较快增长，利润实现转亏为盈。公司 2023-2025 年收入同比增速分别为 33.3%/30.5%/25.6%，经调整净利润由 2023 年的-2.1 亿元提升至 2025 年的 2.3 亿元，盈利能力显著改善。现金流持续增强，表明收入增长具备较高质量。

行业层面，电商 SaaS ERP 具备确定性扩容趋势。随着电商经营从单平台走向多平台、多渠道、多仓配演进，订单管理、库存协同及履约复杂度显著提升，ERP 系统成为电商商家的核心基础设置。当前电商 ERP 渗透率仍处低位，预计未来随数字化程度提升持续增长，公司作为领军有望核心受益于行业扩容。

核心竞争力来自系统能力与商业模式，规模化效应已现。公司围绕电商运营痛点构建底层技术系统，实现多平台订单、库存及履约统一调度，形成系统性壁垒。同时，公司以标准化 SaaS 产品实现规模扩张，客户数持续增长，现有客户收入占比提升带动营销效率优化，获客成本显著下降，单位经济效益持续提升。交叉销售加速兑现，协同产品收入快速增长，单客户价值提升，公司增长由客户扩张向客户扩张+价值提升转变。

AI 赋能与出海拓展打开新空间。公司积极推进 AI 在电商 SaaS 场景的应用，通过智能客服、自动化运营及 NLP 交互降低使用门槛、提升效率，有望进一步增强产品竞争力。同时，公司加速东南亚市场布局，伴随中国电商出海趋势，未来有望从跟随出海向本地化运营转变，构建新增长曲线。

首次覆盖，给予买入评级。我们预计公司 2026-2028 年营业收入分别为 14.0/16.5/19.8 亿元，同比增长分别为 22.6%/17.8%/19.9%，归母净利润分别为 3.7/5.0/7.4 亿元，盈利能力持续释放。考虑到公司 SaaS 收入占比 90%以上，商业模式纯度较高，且已进入规模化盈利阶段，具备较强可比性于高 SaaS 化程度公司。参考可比公司 2026 年平均 44xPE 估值水平，给予公司 2026 年 44xPE，对应目标市值约 161 亿元。

风险提示：电商平台生态变化风险、行业竞争加剧风险、客户结构变化风险、新业务拓展不及预期风险。

4.风险偏好判断以及重点标的

4.1 数字经济领军

海康威视+金山办公+恒生电子+中控技术+德赛西威+启明星辰+科大讯飞+华大九天（计算机+电子）+同花顺+广联达+新大陆

4.2 AIGC 应用

金山办公+鼎捷数智+税友股份+同花顺+东方财富+虹软科技+万兴科技+润达医疗（申万医药+计算机）+科大讯飞+云从科技+福昕软件+萤石网络+道通科技

4.3 AIGC 算力

浪潮信息+海光信息+神州数码+中科曙光+寒武纪

4.4 数据要素

税友股份+博思软件+广电运通

4.5 信创弹性

海光信息+太极股份+纳思达+软通动力+索辰科技+达梦数据

4.6 港股核心

中国软件国际+金蝶国际+中国民航信息网络+联想集团

4.7 智联汽车

德赛西威+虹软科技+中科创达+豪恩汽电+经纬恒润

4.8 新型工业化

鼎捷数智+思看科技+中控技术+赛意信息+能科科技+用友网络+柏楚电子（申万机械）

4.9 医疗信息化

润达医疗（医药+计算机）+嘉和美康+创业慧康

5.风险提示

行业若采取激进扩人策略，存在影响盈利增长的风险。如果 2025 年企业主依然选择长期激进扩张，会影响行业年度盈利和增长。

全球外部因素影响供应链稳定，存在业绩不及预期的风险。如果外部物流环境长期不佳，或影响短期季度的同比增速，递延翻转结论。

6. 计算机重点公司估值表

表 3：计算机重点公司估值表

股票代码	股票简称	2026/4/10	归母净利润（亿元）				PE			
		总市值（亿元）	2024A	2025A/E	2026E	2027E	2024A	2025A/E	2026E	2027E
688041.SH	海光信息	5,388	19.3	25.4	46.0	66.0	279	212	117	82
688256.SH	寒武纪-U	5,105	-4.5	20.6	49.5	85.9		248	103	59
300059.SZ	东方财富	3,123	96.1	120.8	146.2	164.1	32	26	21	19
002415.SZ	海康威视	2,906	119.8	141.9	158.0	181.1	24	20	18	16
300033.SZ	同花顺	1,721	18.2	32.1	38.6	46.0	94	54	45	37
603019.SH	中科曙光	1,248	19.1	21.1	30.6	36.8	65	59	41	34
688111.SH	金山办公	1,093	16.5	18.4	22.5	27.0	66	59	48	40
002230.SZ	科大讯飞	1,101	5.6	8.7	12.6	16.5	197	127	87	67
0992.HK	联想集团	1,099	71.7	99.4	115.2	127.4	15	11	10	9
603296.SH	华勤技术	1,004	29.3	40.5	51.4	64.6	34	25	20	16
000977.SZ	浪潮信息	991	22.9	24.1	36.9	49.3	43	41	27	20
002920.SZ	德赛西威	636	20.0	24.5	30.2	36.7	32	26	21	17
688777.SH	中控技术	530	11.2	4.5	9.5	13.5	47	118	56	39
600570.SH	恒生电子	509	10.4	12.3	14.1	16.7	49	41	36	30
301269.SZ	华大九天	461	1.1	1.7	3.0	4.7	421	272	151	98
600588.SH	用友网络	411	-20.6	-13.5	2.2	7.1			183	57
301236.SZ	软通动力	401	1.8	4.0	5.5	7.7	222	100	73	52
688188.SH	柏楚电子	410	8.8	11.1	13.7	17.0	46	37	30	24
002152.SZ	广电运通	295	9.2	8.6	11.2	13.1	32	34	26	23
0268.HK	金蝶国际	257	-1.4	0.9	4.6	7.9		276	56	32
300496.SZ	中科创达	278	4.1	5.4	6.6	8.0	68	51	42	35
0696.HK	中国民航信息网络	259	20.7	23.4	25.4	27.6	12	11	10	9
000034.SZ	神州数码	256	7.5	5.2	13.1	15.8	34	49	20	16
002180.SZ	纳思达	240	7.5	-7.5	7.6	11.3	32		32	21
688692.SH	达梦数据	263	3.6	5.2	6.5	8.1	73	51	41	32
688208.SH	道通科技	245	6.4	9.4	11.6	14.6	38	26	21	17
688475.SH	萤石网络	215	5.0	5.7	7.1	8.6	43	38	30	25
603171.SH	税友股份	207	1.1	2.0	3.2	4.6	184	104	64	45
000997.SZ	新大陆	204	10.1	12.8	15.4	17.9	20	16	13	11
002410.SZ	广联达	187	2.5	4.1	6.0	7.4	75	46	31	25
002439.SZ	启明星辰	157	-2.3	-5.8	1.1	4.1			138	38
688088.SH	虹软科技	163	1.8	2.6	3.2	4.2	92	63	51	38
688326.SH	经纬恒润-W	140	-5.5	1.0	3.2	5.5		141	44	25
688327.SH	云从科技-UW	134	-7.0	-5.4	-3.6	-1.7				
300624.SZ	万兴科技	135	-1.6	-0.8	0.8	1.4			171	95
002368.SZ	太极股份	121	1.9	-4.1	3.8	4.9	63		32	25
301488.SZ	豪恩汽电	122	1.0	0.7	1.1	1.6	121	163	107	77
688583.SH	思看科技	107	1.2	1.0	1.8	2.3	89	112	60	46
300378.SZ	鼎捷数智	109	1.6	1.6	2.1	2.6	70	67	51	42
603859.SH	能科科技	94	1.9	2.4	2.9	3.6	49	39	32	26

0354.HK	中国软件国际	84	5.1	3.2	6.3	6.9	16	26	13	12
300525.SZ	博思软件	79	3.0	1.6	3.8	4.3	26	50	21	18
603108.SH	润达医疗	77	0.6	-5.2			139			
688507.SH	索辰科技	76	0.4	0.3	1.1	1.4	184	236	69	53
300687.SZ	赛意信息	77	1.4	-0.9	1.6	2.0	56		48	40
300451.SZ	创业慧康	73	-1.7	-3.6	0.7	1.8			110	41
688095.SH	福昕软件	67	0.3	0.3	1.0	1.4	248	243	69	49
688246.SH	嘉和美康	26	-2.6	-2.5	0.4	1.0			62	27

资料来源：Wind，申万宏源研究；注：盈利预测取 Wind 一致预期，已披露业绩的公司 2025 年净利润为披露值，其他公司盈利预测取 Wind 一致预期，港股数据采用人民币

信息披露

证券分析师承诺

本报告署名分析师具有中国证券业协会授予的证券投资咨询执业资格并注册为证券分析师，以勤勉的职业态度、专业审慎的研究方法，使用合法合规的信息，独立、客观地出具本报告,并对本报告的内容和观点负责。本人不曾因，不因，也将不会因本报告中的具体推荐意见或观点而直接或间接收到任何形式的补偿。

与公司有关的信息披露

本公司隶属于申万宏源证券有限公司。本公司经中国证券监督管理委员会核准，取得证券投资咨询业务许可。本公司关联机构在法律许可情况下可能持有或交易本报告提到的投资标的，还可能为或争取为这些标的提供投资银行服务。本公司在知晓范围内依法合规地履行披露义务。客户可通过 compliance@swsresearch.com 索取有关披露资料或登录 www.swsresearch.com 信息披露栏目查询从业人员资质情况、静默期安排及其他有关的信息披露。

机构销售团队联系人

华东团队	茅炯	021-33388488	maojiong@swhysc.com
华北团队	肖霞	15724767486	xiaoxia@swhysc.com
华南团队	王维宇	0755-82990590	wangweiyu@swhysc.com
华北创新团队	潘烨明	15201910123	panyeming@swhysc.com
华东创新团队	朱晓艺	18702179817	zhuxiaoyi@swhysc.com

股票投资评级说明

证券的投资评级：
以报告日后的 6 个月内，证券相对于市场基准指数的涨跌幅为标准，定义如下：
买入（Buy）：相对强于市场表现 20%以上；
增持（Outperform）：相对强于市场表现 5%～20%；
中性（Neutral）：相对市场表现在－5%～＋5%之间波动；
减持（Underperform）：相对弱于市场表现 5%以下。
行业的投资评级：
以报告日后的 6 个月内，行业相对于市场基准指数的涨跌幅为标准，定义如下：
看好（Overweight）：行业超越整体市场表现；
中性（Neutral）：行业与整体市场表现基本持平；
看淡 (Underweight)：行业弱于整体市场表现。
我们在此提醒您，不同证券研究机构采用不同的评级术语及评级标准。我们采用的是相对评级体系，表示投资的相对比重建议；投资者买入或者卖出证券的决定取决于个人的实际情况，比如当前的持仓结构以及其他需要考虑的因素。投资者应阅读整篇报告，以获取比较完整的观点与信息，不应仅仅依靠投资评级来推断结论。申银万国使用自己的行业分类体系，如果您对我们的行业分类有兴趣，可以向我们的销售员索取。
本报告采用的基准指数：沪深 300 指数（A 股）、恒生中国企业指数（H 股）、纳斯达克指数（美股）

法律声明

本报告由上海申银万国证券研究所有限公司（隶属于申万宏源证券有限公司，以下简称“本公司”）在中华人民共和国内地（香港、澳门、台湾除外）发布，仅供本公司的客户（包括合格的境外机构投资者等合法合规的客户）使用。本公司不会因接收人收到本报告而视其为客户。客户应当认识到有关本报告的短信提示、电话推荐等只是研究观点的简要沟通，需以本公司 http://www.swsresearch.com 网站刊载的完整报告为准，本公司接受客户的后续问询。本报告是基于已公开信息撰写，但本公司不保证该等信息的真实性、准确性或完整性。本报告所载的资料、工具、意见及推测只提供给客户作参考之用，并非作为或被视为出售或购买证券或其他投资标的的邀请。本报告所载的资料、意见及推测仅反映本公司于发布本报告当日的判断，本报告所指的证券或投资标的的价格、价值及投资收入可能会波动。在不同时期，本公司可发出与本报告所载资料、意见及推测不一致的报告。客户应当考虑到本公司可能存在可能影响本报告客观性的利益冲突，不应视本报告为作出投资决策的惟一因素。客户应自主作出投资决策并自行承担投资风险。本公司特别提示，本公司不会与任何客户以任何形式分享证券投资收益或分担证券投资损失，任何形式的分享证券投资收益或者分担证券投资损失的书面或口头承诺均为无效。本报告中所指的投资及服务可能不适合个别客户，不构成客户私人咨询建议。本公司未确保本报告充分考虑到个别客户特殊的投资目标、财务状况或需要。本公司强烈建议客户应考虑本报告的任何意见或建议是否符合其特定状况，以及（若有必要）咨询独立投资顾问。在任何情况下，本报告中的信息或所表述的意见并不构成对任何人的投资建议。在任何情况下，本公司不对任何人因使用本报告中的任何内容所引致的任何损失负任何责任。市场有风险，投资需谨慎。若本报告的接收人非本公司的客户，应在基于本报告作出任何投资决定或就本报告要求任何解释前咨询独立投资顾问。
本报告的版权归本公司所有，属于非公开资料。本公司对本报告保留一切权利。除非另有书面显示，否则本报告中的所有材料的版权均属本公司。未经本公司事先书面授权，本报告的任何部分均不得以任何方式制作任何形式的拷贝、复印件或复制品，或再次分发给任何其他人，或以任何侵犯本公司版权的其他方式使用。所有本报告中使用的商标、服务标记及标记均为本公司的商标、服务标记及标记，未获本公司同意，任何人均无权在任何情况下使用他们。